Statistik für Ökonomen

Teil 3: Regression

Prof. Dr. Christoph Weisser

HSBI

Themen der Veranstaltung (1/2)

Teil	**Inhalt**
1 – Deskriptive Statistik	Grundbegriffe, Skalenniveaus, Häufigkeiten, Lage- und Streuungsmaße
2 – Grafische Darstellungen	Grafische Darstellungen
3 – Regression	Regression
4 – Wahrscheinlichkeitsrechnung	Grundlagen, Kombinatorik, Wahrscheinlichkeitsbegriffe, Kolmogorovsche Axiome, Bedingte Wahrscheinlichkeiten, Satz von Bayes

Themen der Veranstaltung (2/2)

Teil	**Inhalt**
5 – Wahrscheinlichkeitsverteilungen	Diskrete Verteilungen, Stetige Verteilungen, Normalverteilung, Grenzwertsätze
6 – Induktive Statistik	Schätzverfahren, Konfidenzintervalle, Hypothesentests

Symbolverzeichnis (1)

Symbol	Bedeutung	Symbol	Bedeutung
ω	Statistische Einheit	h_j	Absolute Häufigkeit
n	Anzahl der statistischen Einheiten	f_j	Relative Häufigkeit
X	Merkmal	H_j	Kumulierte absolute Häufigkeit
x	Merkmalsausprägung	$F(x)$	Empirische Verteilungsfunktion
x_i	Merkmalswert (beobachteter Wert)	a_j	Merkmalsausprägung (Klasse j)
$x_{(i)}$	i-ter Wert der geordneten Stichprobe	$\tilde{x}$	Median
$\bar{x}$	Arithmetisches Mittel	$\bar{x}_{\text{geo}}$	Geometrisches Mittel
$\bar{x}_{\text{harm}}$	Harmonisches Mittel		

Symbolverzeichnis (2)

Symbol	Bedeutung	Symbol	Bedeutung
s^2	Varianz (Stichprobe)	s_{xy}	Kovarianz von X und Y
s	Standardabweichung	r	Korrelationskoeffizient (Bravais-Pearson)
R	Spannweite	β_0, β_1	Regressionskoeffizienten (wahr)
IQR	Interquartilsabstand	$\hat{\beta}_0$, $\hat{\beta}_1$	Geschätzte Regressionskoeffizienten
$x_{0,25}$, $x_{0,75}$	25 %- und 75 %-Quantil	y_i	Beobachtete y-Werte
Q_1, Q_3	1. und 3. Quartil	$\hat{y}_i$	Geschätzte y-Werte
SQT	Quadratsumme total	u_i	Störterm (Fehler)
SQE	Quadratsumme erklärt	$\hat{u}_i$	Residuum
SQR	Quadratsumme der Residuen	R^2	Bestimmtheitsmaß

Überblick

1. Regression
   - Streuungsdiagramm
   - Beste Gerade
   - Kleinste Quadrate
   - Interpretation
   - Residuenanalyse
   - Bestimmtheitsmaß
   - Umformungen

Zusammenhang zweier metrischer Merkmale

Fragestellung

Untersucht werden soll der Zusammenhang zwischen zwei metrisch skalierten Merkmalen.

- **Exogene Variable** X: von außen gegeben, unabhängig angenommen – auch *erklärende Variable*.
- **Endogene Variable** Y: abhängiges Merkmal – auch *zu erklärende Variable*.

Regression – ein Beispiel

Szenario

Eine neue Leuchte wird zum Test in mehreren Geschäften zu unterschiedlichen Preisen angeboten. Beobachtet werden Preis (in Euro) und Absatzmenge.

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120
Menge y_i	20	17	15	9	11	8	4	4	2

Zuordnung der Variablen

Der Preis war in jedem Geschäft fest vorgegeben und nicht verhandelbar. Daher ist

- der **Preis** das *exogene* Merkmal X,
- die **Menge** das *endogene* Merkmal Y (Ergebnis des Kaufverhaltens, abhängig vom Preis).

Preis-Absatz- und Nachfragefunktion

Preis-Absatzfunktion

Der gesuchte funktionale Zusammenhang $Y = f(X)$ heißt *Preis-Absatzfunktion*. Sie beantwortet die Frage: *Welche Menge wird zu einem vorgegebenen Preis abgesetzt?*

Nachfragefunktion

Die Umkehrfunktion $X = f^{-1}(Y)$ heißt *Nachfragefunktion*. Sie beantwortet die umgekehrte Frage: *Zu welchem Preis kann eine festgelegte Menge verkauft werden?*

Regression – Beispiel (Warnung)

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120
Absatz y_i	20	17	15	9	11	8	4	4	2

Warnung

- **Nicht sortieren!**
  Die Werte x_i und y_i dürfen *nicht* unabhängig voneinander umsortiert werden.
- **Paare gehören zusammen.**
  Jedes Paar (x_i, y_i) stammt aus *derselben Beobachtung* (hier: aus demselben Geschäft) – die Zuordnung Preis $\leftrightarrow$ Absatz darf nicht verloren gehen.

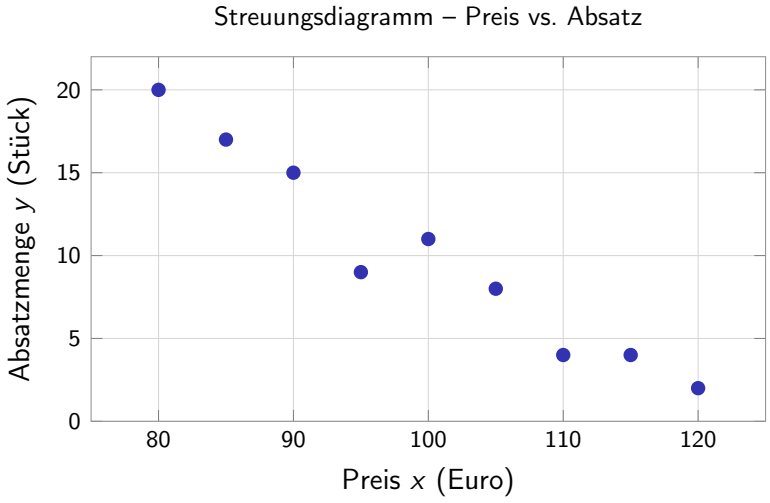
Streuungsdiagramm

Idee

Ein *Streuungsdiagramm* (auch: *Scatterplot*) verschafft einen ersten visuellen Überblick über den Zusammenhang zweier metrischer Merkmale X und Y.

- Jede Beobachtung (x_i, y_i) wird als **ein Punkt** eingezeichnet.
- Der **exogene Wert** x_i (hier: Preis) steht auf der x-Achse.
- Der **endogene Wert** y_i (hier: Absatzmenge) steht auf der y-Achse.
- Aus der Punktewolke lassen sich *Richtung*, *Stärke* und *Form* des Zusammenhangs ablesen.

Streuungsdiagramm



Kovarianz

Idee

Die *Kovarianz* s_{xy} misst die **gemeinsame Variabilität** zweier metrischer Merkmale X und Y.

Berechnung (Stichprobenkovarianz)

$$s_{xy} = \text{Cov}(X, Y) = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$

mit Wertebereich $-\infty < s_{xy} < +\infty$.

Kovarianz – Interpretation

Vorzeichen zeigt die Richtung des Zusammenhangs

$s_{xy} > 0$ **Positiver (gleichläufiger) Zusammenhang.**
Größere Werte von X gehen tendenziell mit größeren Werten von Y einher – im Streuungsdiagramm eine *positiv gerichtete* Punktewolke.

$s_{xy} < 0$ **Negativer (gegenläufiger) Zusammenhang.**
Größere Werte von X gehen tendenziell mit kleineren Werten von Y einher – eine *negativ gerichtete* Punktewolke.

$s_{xy} = 0$ **Kein linearer Zusammenhang.**
Die gemeinsame Variabilität weist keine Richtung auf; die Punktewolke zeigt keine erkennbare lineare Struktur.

Betrag nicht direkt interpretierbar

Die Kovarianz s_{xy} hat die Einheit „Einheit von X · Einheit von Y“ und hängt von der Skalierung der Daten ab.

Korrelationskoeffizient

Idee

Der Korrelationskoeffizient r_{xy} ist eine **normierte Kovarianz**: er misst die Stärke und Richtung des *linearen* Zusammenhangs zwischen X und Y – aber im Gegensatz zur Kovarianz *unabhängig von den Maßeinheiten*.

Berechnung

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \mathrm{Cov}(X^*, Y^*) = \mathrm{Cov}\left(\frac{X-\bar{x}}{s_x}, \frac{Y-\bar{y}}{s_y}\right)$$

mit Wertebereich $-1 \leq r_{xy} \leq +1$.

Lesart

r_{xy} ist die Kovarianz der *z-standardisierten* Variablen $X^* = (X-\bar{x})/s_x$ und $Y^* = (Y-\bar{y})/s_y$. Durch die Division durch $s_x s_y$ werden die Einheiten herausgekürzt.

Korrelationskoeffizient – Stärke des Zusammenhangs

Was r_{xy} misst

Der Korrelationskoeffizient misst den **Grad der linearen Abhängigkeit** zwischen X und Y.

Stärke des Zusammenhangs (Faustregel)

Bereich	**Interpretation**
$\lvert r_{xy}\rvert > 0{,}8$	starke Korrelation
$0{,}5 \leq \lvert r_{xy}\rvert \leq 0{,}8$	mittlere Korrelation
$\lvert r_{xy}\rvert < 0{,}5$	schwache Korrelation

Korrelationskoeffizient – Grenzen

Kein Erklärungszusammenhang

Aus r_{xy} allein lässt sich *nicht* ableiten, welches Merkmal unabhängig (X) und welches abhängig (Y) ist. Die Korrelation ist **symmetrisch**: $r_{xy} = r_{yx}$.

Scheinkorrelation möglich

r_{xy} kann $\neq 0$ sein, **ohne** dass ein inhaltlicher Zusammenhang zwischen X und Y besteht – z. B. wenn beide Variablen durch eine gemeinsame Drittvariable beeinflusst werden.

Merke

Ein hoher Wert von $|r_{xy}|$ ist ein *statistischer Befund*, keine *kausale Aussage*.

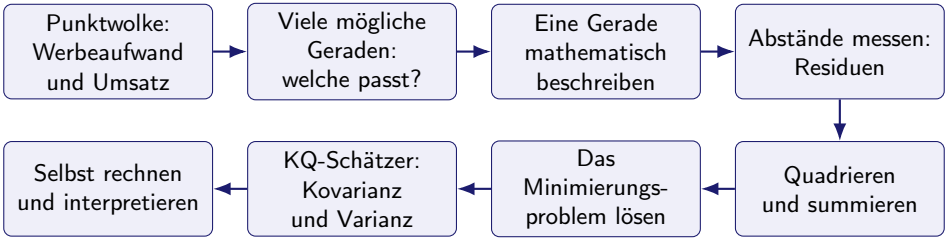
Kovarianz und Korrelation mit R

```r
# Kovarianz
cov(x, y)

# Korrelationskoeffizient
cor(x, y)

# Nach Pearson (Standard)
cor(x, y, method = "pearson")
```

Fahrplan: Wie finden wir die beste Gerade durch eine Punktwolke?



Kernaussage

Die Methode der kleinsten Quadrate ist keine isolierte Formel, sondern die nachvollziehbare Antwort auf eine einfache Frage: *Wie finden wir die beste Gerade durch eine Punktwolke?*

Ausgangsfrage: Wie hängt der Werbeaufwand mit dem Umsatz zusammen?

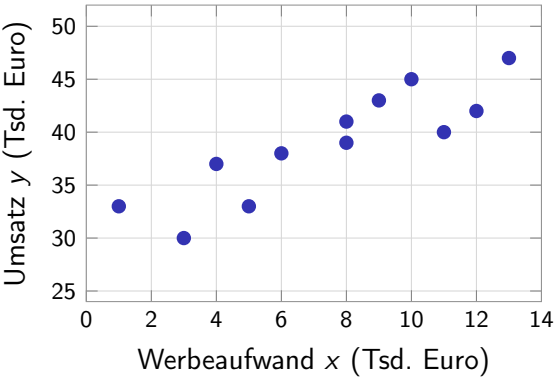
Situation

Ein Handelsunternehmen betreibt zwölf Filialen. Für jede Filiale sind der Werbeaufwand und der Umsatz des letzten Quartals bekannt (jeweils in Tsd. Euro).

Filiale i	1	2	3	4	5	6	7	8	9	10	11	12
Werbeaufwand x_i (Tsd. Euro)	1	3	4	5	6	8	8	9	10	11	12	13
Umsatz y_i (Tsd. Euro)	33	30	37	33	38	41	39	43	45	40	42	47

- x: Werbeaufwand – *exogene* (erklärende) Variable
- y: Umsatz – *endogene* (zu erklärende) Variable
- Jedes Paar (x_i, y_i) gehört zu *derselben* Filiale.

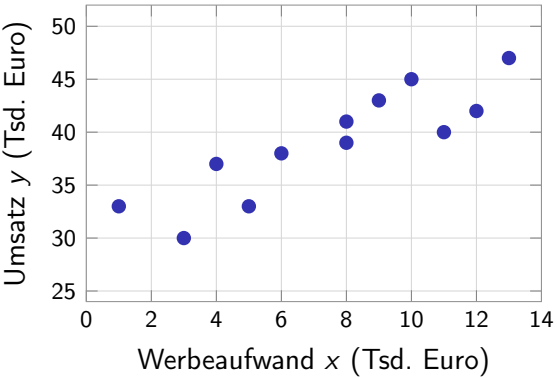
Zwei Variablen und ihr Zusammenhang



Was zeigt das Streuungsdiagramm?

- Mehr Werbung, tendenziell mehr Umsatz: ein **positiver Zusammenhang**.
- Die Punkte streuen, sie liegen nicht auf einer Linie.

Zwei Variablen und ihr Zusammenhang



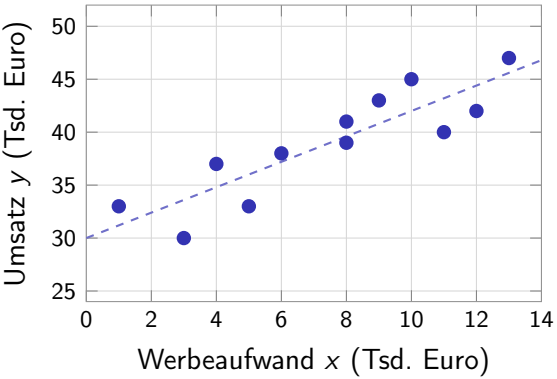
Was zeigt das Streuungsdiagramm?

- Mehr Werbung, tendenziell mehr Umsatz: ein **positiver Zusammenhang**.
- Die Punkte streuen, sie liegen nicht auf einer Linie.

Leitfrage

Wie könnten wir diesen Zusammenhang möglichst einfach beschreiben?

Zwei Variablen und ihr Zusammenhang



Was zeigt das Streuungsdiagramm?

- Mehr Werbung, tendenziell mehr Umsatz: ein **positiver Zusammenhang**.
- Die Punkte streuen, sie liegen nicht auf einer Linie.

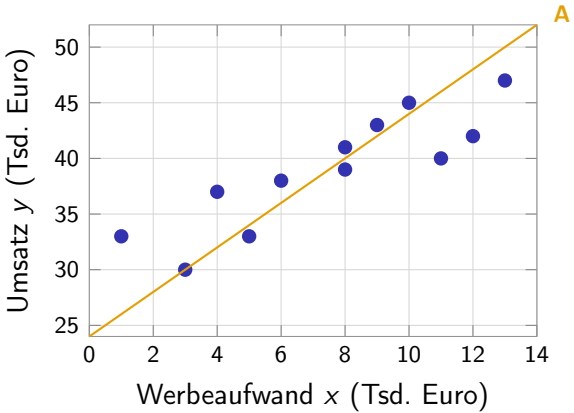
Leitfrage

Wie könnten wir diesen Zusammenhang möglichst einfach beschreiben?

Idee

Mit einer **Geraden**: Sie fasst die Tendenz der Punktwolke in einer Linie zusammen.

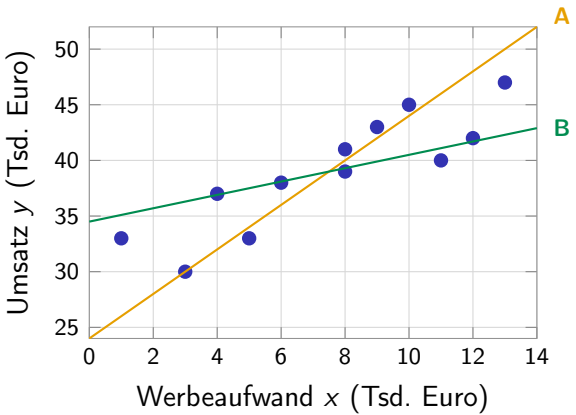
Welche Gerade beschreibt die Daten am besten?



Vier Kandidaten

A zu steil

Welche Gerade beschreibt die Daten am besten?

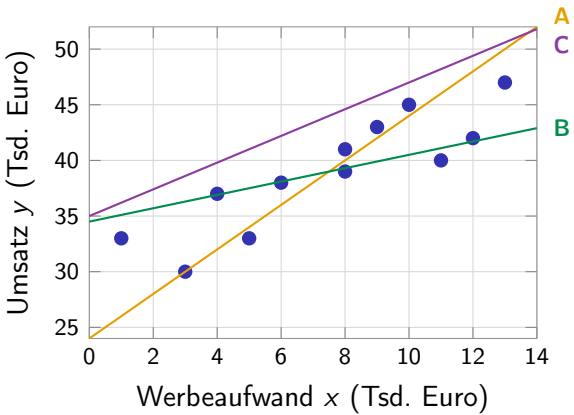


Vier Kandidaten

A zu steil

B zu flach

Welche Gerade beschreibt die Daten am besten?



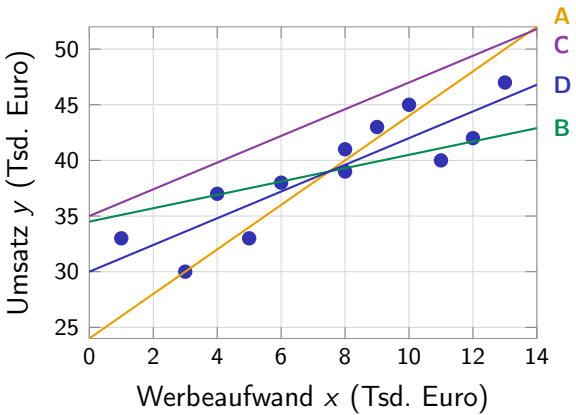
Vier Kandidaten

A zu steil

B zu flach

C zu hoch

Welche Gerade beschreibt die Daten am besten?



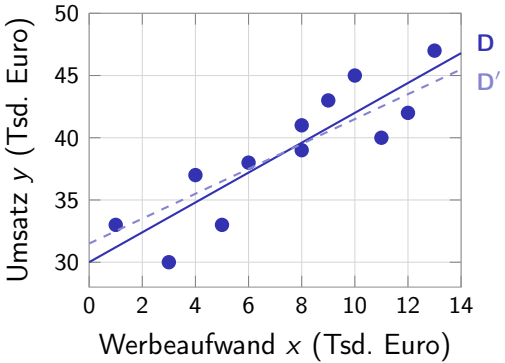
Vier Kandidaten

- A zu steil
- B zu flach
- C zu hoch
- D passt augenscheinlich gut

Fragen an Sie

- Welche Gerade würden Sie wählen – und warum?
- Wie könnten wir das *objektiv* entscheiden?

Augenmaß reicht nicht



D oder D′ – wer hat Recht?

Problem

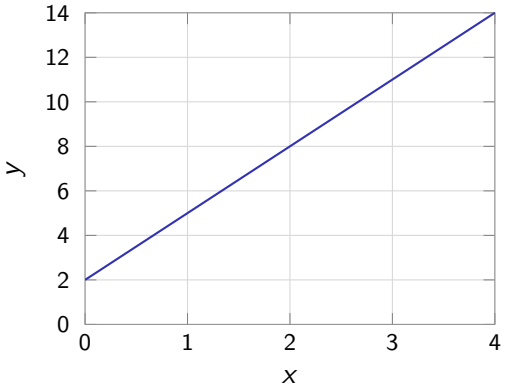
Augenmaß ist **subjektiv**: Zwei Personen zeichnen zwei verschiedene „gute“ Geraden und können nicht begründen, welche besser ist.

Kernaussage

Wir benötigen ein nachvollziehbares **mathematisches Kriterium**, um die Qualität verschiedener Geraden zu vergleichen.

▷ *Geplante interaktive Anwendung: App 1 „Die beste Gerade finden“: Steigung und Achsenabschnitt per Schieberegler ausprobieren.*

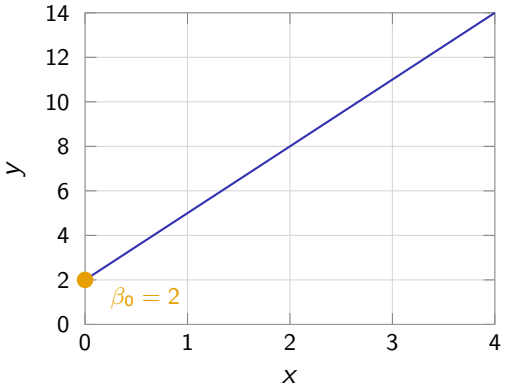
Wie beschreiben wir eine Gerade mathematisch?



Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Wie beschreiben wir eine Gerade mathematisch?



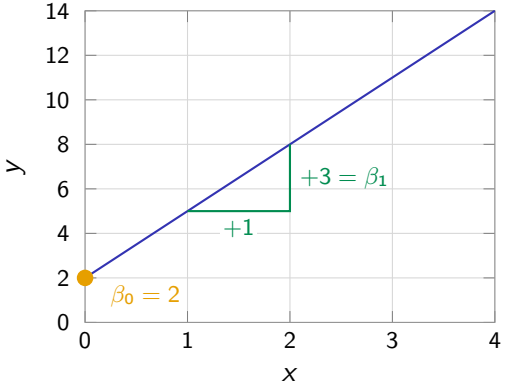
Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Achsenabschnitt β_0

Wert von y bei $x = 0$: Dort schneidet die Gerade die y-Achse. Beispiel: $y = 2 + 3 \cdot 0 = 2$.

Wie beschreiben wir eine Gerade mathematisch?



Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Achsenabschnitt β_0

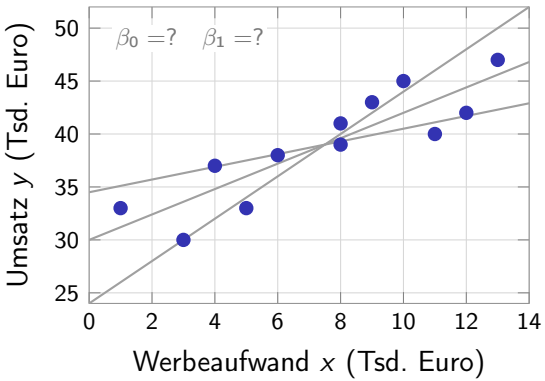
Wert von y bei $x = 0$: Dort schneidet die Gerade die y-Achse. Beispiel: $y = 2 + 3 \cdot 0 = 2$.

Steigung β_1

Steigt x um eine Einheit, so ändert sich y auf der Geraden um β_1. Beispiel: von $x = 1$ ($y = 5$) zu $x = 2$ ($y = 8$), also $+3$.

Zwei Zahlen legen die Gerade vollständig fest.

Was müssen wir eigentlich bestimmen?



Bekannt

Die **Form** der Beschreibung: eine Gerade $\beta_0 + \beta_1 x$.

Unbekannt

Die **Lage** der Geraden: Achsenabschnitt β_0 und Steigung β_1. Jede Wahl ergibt eine andere Gerade.

Leitfrage

Welche Werte müssen wir für β_0 und β_1 wählen, damit die Gerade möglichst gut zu unseren Beobachtungen passt?

Beobachtete Werte und Werte auf der Geraden

Die geschätzte Regressionsgerade

Werden β_0 und β_1 aus den Daten bestimmt (*geschätzt*), kennzeichnen wir das mit einem „Hut“:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

- y_i tatsächlich **beobachteter** Umsatz der Filiale i
- $\hat{y}_i$ Umsatz, den die Gerade für den Werbeaufwand x_i liefert: **angepasster** (vorhergesagter) Wert
- $\hat{\beta}_0$, $\hat{\beta}_1$ aus den Daten **geschätzte** Parameter

Nicht verwechseln

y_i und $\hat{y}_i$ sind in der Regel *verschieden*: Die Beobachtung liegt neben der Geraden, nicht auf ihr. Deshalb schreiben wir *nicht* $y_i = \beta_0 + \beta_1 x_i$.

Beispiel mit Gerade D ($\hat{\beta}_0 = 30$, $\hat{\beta}_1 = 1{,}2$): Filiale 9 hat $x_9 = 10$ und $y_9 = 45$, die Gerade liefert $\hat{y}_9 = 30 + 1{,}2 \cdot 10 = 42$.

Wie lässt sich die beste Gerade systematisch bestimmen?



Carl Friedrich Gauß
(1777–1855)
G. Biermann nach C. A. Jensen, gemeinfrei

Methode der kleinsten Quadrate (KQ-Methode)

Das klassische Verfahren, um die Parameter einer Geraden aus Daten zu bestimmen – englisch **Ordinary Least Squares (OLS)**.

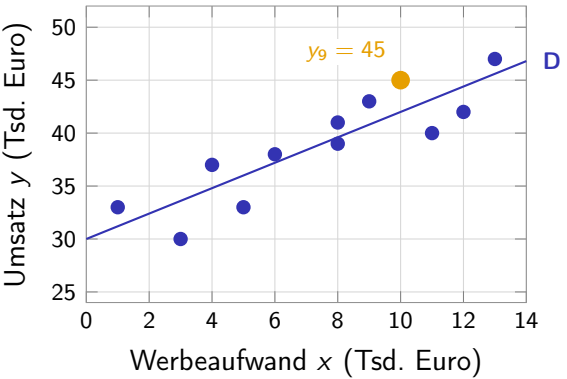
Historische Einordnung

Gauß (Göttingen) nutzte die Methode nach eigener Angabe schon 1795. Zuerst *veröffentlicht* hat sie Legendre (1805), Gauß erst 1809 – ein berühmter Prioritätsstreit.

Grundgedanke

Miss, wie weit jede Beobachtung von der Geraden entfernt liegt, und wähle die Gerade, bei der diese Abstände *insgesamt* am kleinsten sind. Die „Quadrate“ im Namen: jetzt Schritt für Schritt.

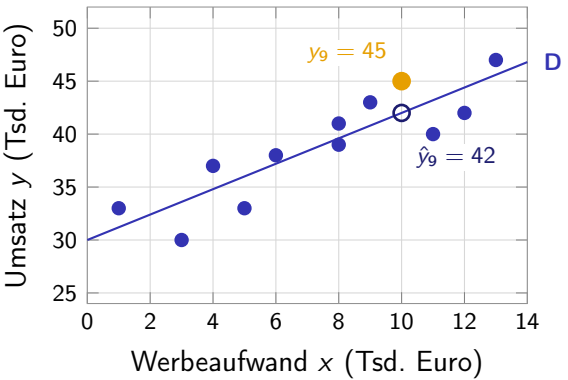
Nicht alle Punkte liegen auf der Geraden



Filiale 9: $x_9 = 10$

- beobachtet: $y_9 = 45$

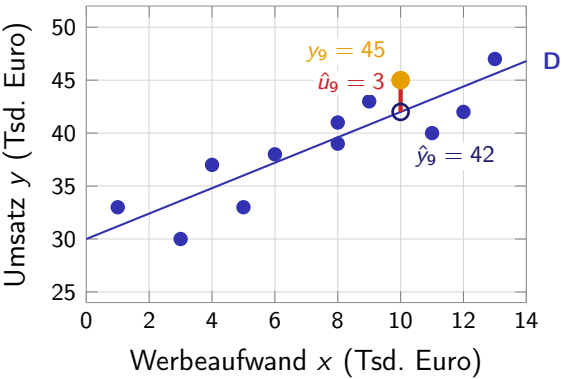
Nicht alle Punkte liegen auf der Geraden



Filiale 9: $x_9 = 10$

- beobachtet: $y_9 = 45$
- auf der Geraden: $\hat{y}_9 = 30 + 1{,}2 \cdot 10 = 42$

Nicht alle Punkte liegen auf der Geraden



Filiale 9: $x_9 = 10$

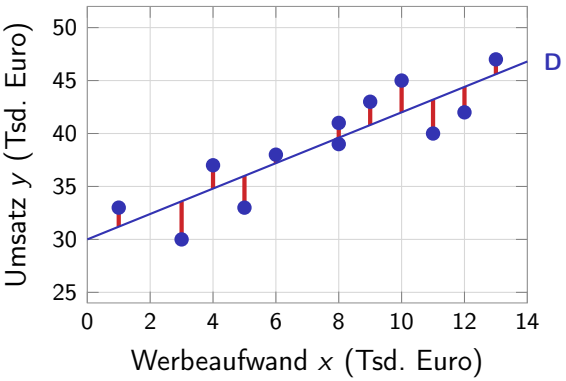
- beobachtet: $y_9 = 45$
- auf der Geraden: $\hat{y}_9 = 30 + 1{,}2 \cdot 10 = 42$
- Abstand: $45 - 42 = 3$

Residuum

$$\hat{u}_i \;=\; y_i - \hat{y}_i$$

Der **vertikale** Abstand zwischen Beobachtung und Gerade (nicht der kürzeste Abstand senkrecht zur Geraden). In Lehrbüchern auch e_i statt $\hat{u}_i$.

Die Residuen aller Beobachtungen



Vorzeichen der Residuen

- Punkt **oberhalb** der Geraden: $y_i > \hat{y}_i$, also $\hat{u}_i > 0$
- Punkt **unterhalb**: $\hat{u}_i < 0$
- Punkt **auf** der Geraden: $\hat{u}_i = 0$

Gerade D: 1,8; $-3{,}6$; 2,2; $-3{,}0$; 0,8; 1,4; $-0{,}6$; 2,2; 3,0; $-3{,}2$; $-2{,}4$; 1,4

Kernaussage

Gesucht ist die Gerade, bei der die Abweichungen zwischen beobachteten und angepassten Werten *insgesamt* möglichst klein sind.

Warum addieren wir nicht einfach die Residuen?

Naheliegende Idee

„Insgesamt klein“ könnte heißen: Die Summe der Residuen $\sum_{i=1}^{n} \hat{u}_i$ soll möglichst klein sein.

Das Problem

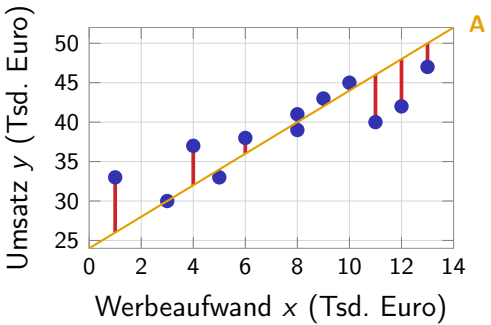
Positive und negative Residuen **heben sich auf**. Für Gerade D:
$1{,}8 - 3{,}6 + 2{,}2 - 3{,}0 + \ldots + 1{,}4 = 0$. Die Summe ist null, obwohl kein Punkt auf der Geraden liegt.

Bekannt von der Varianz

Abweichungen vom Mittelwert summieren sich stets zu null: $\sum_{i=1}^{n}(x_i - \bar{x}) = 0$. Beispiel: 2, 4, 9 mit $\bar{x} = 5$, Abweichungen -3, -1, $+4$.

Deshalb wurden bei der Varianz die Abweichungen **quadriert**. Zuvor prüfen wir: Gilt das Problem auch für andere Geraden?

Die Residuensumme unterscheidet gute und schlechte Geraden nicht



Gerade A: Residuen 7, 0, 5, −1, 2, 1, −1, 1, 1, −6, −6, −3 – Summe 0

Gerade		$\sum \hat{u}_i$
A	zu steil	0
B	zu flach	0
C	zu hoch	−60
D	passt gut	0

Zwei Befunde

- A, B und D: dieselbe Summe 0, obwohl A und B schlecht passen.
- Je höher eine Gerade liegt, desto negativer die Summe: „kleinste Summe“ wäre absurd.

Die Lösung: Wir quadrieren die Abweichungen

Quadrierte Residuen

$$\hat{u}_i^2 \;=\; \left(y_i - \hat{y}_i\right)^2$$

Gerade D	1	2	3	4	5	6	7	8	9	10	11	12	Summe
$\hat{u}_i$	1,8	−3,6	2,2	−3,0	0,8	1,4	−0,6	2,2	3,0	−3,2	−2,4	1,4	0
$\hat{u}_i^2$	3,24	12,96	4,84	9,00	0,64	1,96	0,36	4,84	9,00	10,24	5,76	1,96	64,8

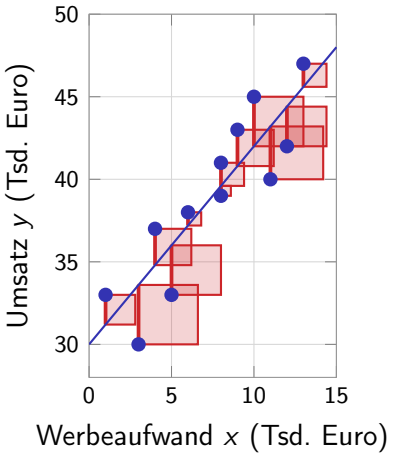
Vorteile des Quadrierens

- Alle Summanden sind ≥ 0: Nichts hebt sich auf.
- Große Abweichungen zählen *überproportional*: $3{,}6^2 = 12{,}96$, aber $0{,}6^2 = 0{,}36$.
- Die Summe lässt sich gut minimieren (Differentialrechnung).

Derselbe Trick wie bei der Varianz

$s^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$ nutzt *quadrierte* Abweichungen vom Mittel. Hier: quadrierte Abweichungen von einer *Geraden*.

Quadrierte Residuen als Flächen



Konstruktion

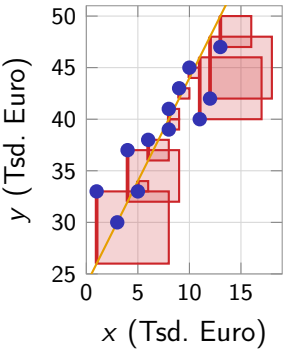
- Jedes rote Residuum wird zur Seite eines Quadrats: Seitenlänge $|\hat{u}_i|$, Fläche $\hat{u}_i^2$.
- Die Summe aller Flächen ist die Residuenquadratsumme, für Gerade D: $\sum \hat{u}_i^2 = 64{,}8$.

Kernaussage

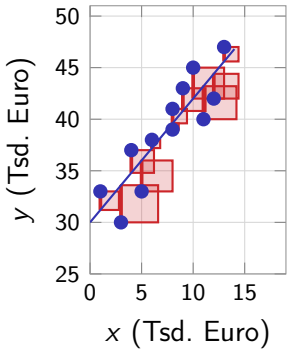
Die beste Gerade ist diejenige, bei der die **Summe dieser Quadratflächen** möglichst klein ist.

Skalierung: Beide Achsen in Tsd. Euro, eine Einheit ist auf beiden Achsen gleich lang. Nur so sind die Quadrate wirklich Quadrate und ihre Flächen vergleichbar.

Vergleich: schlecht passende Gerade und beste Gerade



A: $\sum \hat{u}_i^2 = 164{,}0$



D: $\sum \hat{u}_i^2 = 64{,}8$

Gerade	$\sum \hat{u}_i^2$
A	164,0
B	120,6
C	364,8
D	64,8

Kernaussage

Die Quadratsumme trennt gute von schlechten Geraden. Gibt es eine noch bessere als D?

▷ *Geplante interaktive Anwendung: App 2: Quadrate und Summe live beim Verschieben.*

Das Minimierungsproblem: Die Zielfunktion

Residuenquadratsumme für beliebige Werte β_0 und β_1

$$S(\beta_0, \beta_1) \;=\; \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i \big)^2 \;=\; \sum_{i=1}^{n} \hat{u}_i^2$$

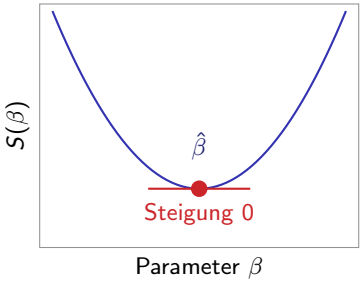
y_i: beobachteter Wert; $\beta_0 + \beta_1 x_i$: Wert auf der Geraden bei x_i; Klammer: Residuum $\hat{u}_i$ dieser Geraden, quadriert und über alle n Beobachtungen summiert.

Gesucht: das Minimum

$$(\hat{\beta}_0, \hat{\beta}_1) \;=\; \underset{\beta_0,\, \beta_1}{\arg\min} \; \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i \big)^2$$

In Worten: die Parameterwerte mit der kleinsten Residuenquadratsumme. Beispiel: $S(24;\, 2) = 164{,}0$ (A), $S(30;\, 1{,}2) = 64{,}8$ (D).

Wie lässt sich das Problem lösen?



Schema: nach oben geöffnete Parabel, im Minimum ist die Ableitung null.

Beobachtung

$S(\beta_0, \beta_1)$ ist eine **quadratische Funktion** der beiden Unbekannten: eine nach oben geöffnete „Schüssel“ mit genau einem Minimum (sofern die x_i nicht alle gleich sind).

Lösungsweg mit Differentialrechnung

1. S nach β_0 ableiten.
2. S nach β_1 ableiten.
3. Beide partiellen Ableitungen gleich null setzen.
4. Das entstehende Gleichungssystem lösen.

Bedingungen erster Ordnung

Ableiten mit der Kettenregel

Für einen einzelnen Summanden gilt $\frac{\partial}{\partial \beta_0}\big(y_i - \beta_0 - \beta_1 x_i\big)^2 = 2\big(y_i - \beta_0 - \beta_1 x_i\big) \cdot (-1)$; bei β_1 lautet die innere Ableitung $-x_i$.

Summieren und gleich null setzen

$$\frac{\partial S}{\partial \beta_0} = -2 \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i\big) \;=\; 0$$

$$\frac{\partial S}{\partial \beta_1} = -2 \sum_{i=1}^{n} x_i \big(y_i - \beta_0 - \beta_1 x_i\big) \;=\; 0$$

In Worten: Im Minimum verschwinden beide partiellen Ableitungen. Die Klammern sind die Residuen: Die beste Gerade hat die Residuensumme null und zusätzlich $\sum x_i \hat{u}_i = 0$.

Von den Ableitungen zu den Normalgleichungen

Erste Bedingung: durch -2 teilen, Summe aufspalten

$$\sum_{i=1}^{n} y_i \;=\; n\,\beta_0 + \beta_1 \sum_{i=1}^{n} x_i \qquad \Longrightarrow \qquad \beta_0 \;=\; \bar{y} - \beta_1\,\bar{x}$$

(beide Seiten durch n geteilt; $\bar{x} = \frac{1}{n}\sum x_i$, $\bar{y} = \frac{1}{n}\sum y_i$)

Zweite Bedingung: ebenso

$$\sum_{i=1}^{n} x_i y_i \;=\; \beta_0 \sum_{i=1}^{n} x_i + \beta_1 \sum_{i=1}^{n} x_i^2$$

Normalgleichungen

Zwei lineare Gleichungen für die zwei Unbekannten β_0 und β_1. Die erste liefert den Achsenabschnitt, sobald die Steigung bekannt ist.

Auflösen nach der Steigung

Achsenabschnitt einsetzen

$\beta_0 = \bar{y} - \beta_1 \bar{x}$ in die zweite Normalgleichung einsetzen und $\sum x_i = n\bar{x}$ nutzen:

$$\sum x_i y_i = (\bar{y} - \beta_1 \bar{x})\, n\bar{x} + \beta_1 \sum x_i^2$$

$$\sum x_i y_i - n\,\bar{x}\bar{y} = \beta_1 \left(\sum x_i^2 - n\,\bar{x}^2 \right)$$

Ergebnis

Mit $\sum x_i y_i - n\bar{x}\bar{y} = \sum (x_i - \bar{x})(y_i - \bar{y})$ und $\sum x_i^2 - n\bar{x}^2 = \sum (x_i - \bar{x})^2$ folgt

$$\hat{\beta}_1 \;=\; \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2} \qquad \text{und} \qquad \hat{\beta}_0 \;=\; \bar{y} - \hat{\beta}_1\, \bar{x}.$$

Voraussetzung: Die x_i sind nicht alle gleich (sonst Nenner null). Da S nach oben geöffnet ist, liegt hier tatsächlich das Minimum.

Der KQ-Schätzer für die Steigung

Lösung des Minimierungsproblems

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Zähler

Produkte der Abweichungen vom jeweiligen Mittelwert, aufsummiert.

- beide über oder beide unter dem Mittel: Produkt > 0
- eines über, eines unter dem Mittel: Produkt < 0

Positiv, wenn die Punktwolke ansteigt.

Nenner

Quadrierte Abweichungen der x_i vom Mittel, aufsummiert.

- stets > 0 (wenn die x_i nicht alle gleich sind)
- misst die Streuung der erklärenden Variable

Kommen Ihnen Zähler und Nenner bekannt vor?

Die Verbindung zu Kovarianz und Varianz

Empirische Kovarianz

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

Empirische Varianz von x

$$s_x^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Der Schätzer, mit $\frac{1}{n-1}$ erweitert

$$\hat{\beta}_1 = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$

Der Faktor $\frac{1}{n-1}$ steht in Zähler *und* Nenner und kürzt sich heraus. Was bleibt, sind zwei bekannte Kennzahlen.

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$$

Steigung = Kovarianz durch Varianz

Kernaussage

Die Steigung der Regressionsgeraden lässt sich unmittelbar aus zwei bereits bekannten Kennzahlen bestimmen: der **Kovarianz** von x und y und der **Varianz** von x.

Intuition

- s_{xy} beschreibt die *gemeinsame* Variation von x und y: Vorzeichen = Richtung des Zusammenhangs.
- s_x^2 berücksichtigt, wie stark x selbst streut.
- Ihr Verhältnis: Wie viel Mitbewegung von y entfällt auf eine Einheit Streuung von x? Das ist die Steigung.

Zwölf Filialen

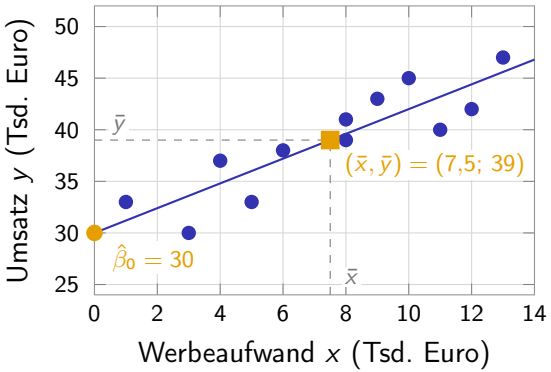
$\sum(x_i - \bar{x})(y_i - \bar{y}) = 186$,
$\sum(x_i - \bar{x})^2 = 155$

$\hat{\beta}_1 = 186/155 = 1{,}2$

Über die Kennzahlen: $s_{xy} = 186/11 = 16{,}91$, $s_x^2 = 155/11 = 14{,}09$ und damit ebenfalls $\hat{\beta}_1 = 16{,}91/14{,}09 = 1{,}2$.

Für die Steigung genügen die reinen Summen.

Der KQ-Schätzer für den Achsenabschnitt



Aus der ersten Normalgleichung

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \quad \Longleftrightarrow \quad \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$$

Der Punkt $(\bar{x}, \bar{y})$ liegt **auf** der KQ-Geraden.

Schwerpunkt der Punktwolke

Die KQ-Gerade verläuft stets durch den Schwerpunkt $(\bar{x}, \bar{y})$; mit der Steigung ist sie damit festgelegt. Beispiel: $\hat{\beta}_0 = 39 - 1{,}2 \cdot 7{,}5 = 30$.

Rückblick: Jede Gerade durch $(\bar{x}, \bar{y})$ hat die Residuensumme 0, auch A und B. Das erklärt die Tabelle von vorhin.

Beide Schätzer im Überblick

Die Lösung des Minimierungsproblems

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Die geschätzte Regressionsgerade

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \qquad \text{für die zwölf Filialen:} \quad \hat{y}_i = 30 + 1{,}2\, x_i$$

Gerade D *war* die KQ-Gerade: Keine andere hat eine kleinere Residuenquadratsumme als 64,8.

Kernaussage

Das Ausgangsproblem ist gelöst: Aus $\bar{x}$, $\bar{y}$, s_{xy} und s_x^2 erhalten wir die eindeutig beste Gerade – beste im Sinne der kleinsten Residuenquadratsumme.

Die Steigung hat stets das Vorzeichen der Kovarianz; für $s_{xy} = 0$ ist die Gerade waagerecht.

Schritt für Schritt zur Regressionsgeraden

Rechenschema

1. Mittelwerte $\bar{x}$, $\bar{y}$
2. Kovarianz $s_{xy} = \frac{1}{n-1}\sum(x_i - \bar{x})(y_i - \bar{y})$
3. Varianz $s_x^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2$
4. Steigung $\hat{\beta}_1 = s_{xy}/s_x^2$
5. Achsenabschnitt $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$
6. Gerade $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

Die Mittelwerte zuerst: Alle weiteren Schritte benötigen sie.

Arbeitstabelle für die Schritte 2 und 3

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1						
2						
$\vdots$						
n						
$\sum$			0	0	$\to s_{xy}$	$\to s_x^2$

Kontrolle: Die Spalten $x_i - \bar{x}$ und $y_i - \bar{y}$ summieren sich zu 0.

Übungsaufgabe: Eine Regressionsgerade selbst bestimmen

Daten

Werbeaufwand und Umsatz eines Online-Shops in fünf Monaten (jeweils in Tsd. Euro):

Monat i	1	2	3	4	5
Werbeaufwand x_i (Tsd. Euro)	1	2	3	4	5
Umsatz y_i (Tsd. Euro)	21	26	24	30	29

Aufgaben

a) Mittelwerte beider Variablen berechnen.

b) Empirische Kovarianz s_{xy} berechnen.

c) Empirische Varianz s_x^2 berechnen.

d) KQ-Schätzer für die Steigung bestimmen.

e) KQ-Schätzer für den Achsenabschnitt bestimmen.

f) Geschätzte Regressionsgerade angeben.

Lösung (1/3): Mittelwerte und Arbeitstabelle

a) Mittelwerte

$$\bar{x} = \frac{1+2+3+4+5}{5} = \frac{15}{5} = 3 \qquad \bar{y} = \frac{21+26+24+30+29}{5} = \frac{130}{5} = 26$$

Arbeitstabelle

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	1	21	-2	-5	10	4
2	2	26	-1	0	0	1
3	3	24	0	-2	0	0
4	4	30	1	4	4	1
5	5	29	2	3	6	4
$\sum$	15	130	0	0	20	10

Lösung (2/3): Kovarianz, Varianz und Schätzer

b) Kovarianz

$$s_{xy} = \frac{1}{n-1}\sum(x_i - \bar{x})(y_i - \bar{y}) = \frac{20}{4} = 5$$

c) Varianz von x

$$s_x^2 = \frac{1}{n-1}\sum(x_i - \bar{x})^2 = \frac{10}{4} = 2{,}5$$

d) Steigung

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = \frac{5}{2{,}5} = 2$$

Kontrolle über die Summen: $20/10 = 2$.

e) Achsenabschnitt

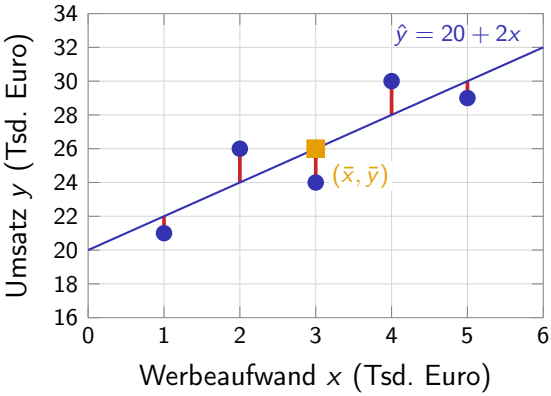
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\,\bar{x} = 26 - 2 \cdot 3 = 20$$

f) Geschätzte Regressionsgerade

$$\hat{y} \;=\; 20 + 2\,x$$

Einheiten: $\hat{\beta}_1 = 2$ Tsd. Euro Umsatz je Tsd. Euro Werbeaufwand; $\hat{\beta}_0 = 20$ Tsd. Euro.

Lösung (3/3): Die Gerade im Streuungsdiagramm



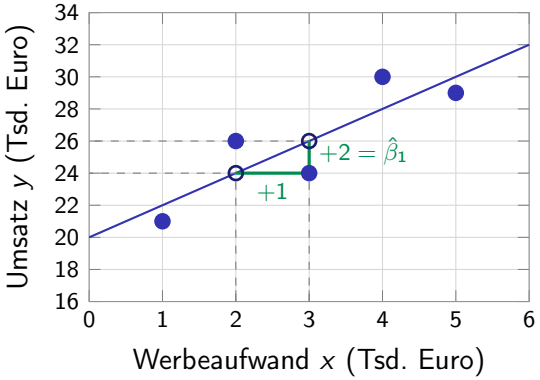
Kontrolle

- Die Gerade verläuft durch den Schwerpunkt (3; 26).
- Residuen $\hat{u}_i = y_i - \hat{y}_i$: $-1,\ 2,\ -2,\ 2,\ -1$ – Summe 0.
- Residuenquadratsumme: $1 + 4 + 4 + 4 + 1 = 14$.

Probe mit anderen Geraden

$\hat{y} = 19 + 2x$: Residuen $0, 3, -1, 3, 0$, Quadratsumme $19 > 14$. $\hat{y} = 20 + 2{,}5x$: Quadratsumme $27{,}75 > 14$.

Wie interpretieren wir die Steigung?



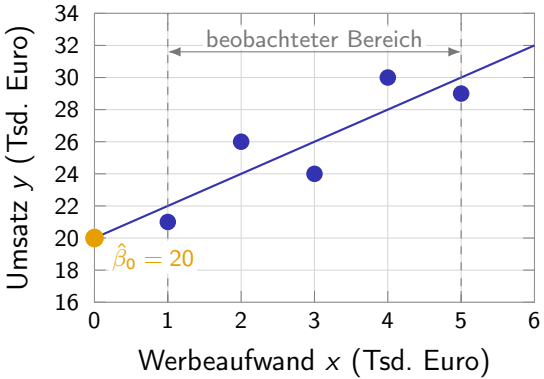
Steigung $\hat{\beta}_1 = 2$

Steigt x um eine Einheit, so ändert sich der durch die Gerade beschriebene Wert von y um $\hat{\beta}_1$ Einheiten. Hier: Werbeaufwand $2 \rightarrow 3$ Tsd. Euro, $\hat{y}$ steigt von 24 auf 26. **Je zusätzlichem Tsd. Euro Werbeaufwand ist laut Gerade ein um** 2 **Tsd. Euro höherer Umsatz zu erwarten.**

Keine kausale Aussage

Die Gerade beschreibt einen statistischen Zusammenhang. Dass mehr Werbung den Umsatz *verursacht*, folgt daraus nicht – etwa, wenn in umsatzstarken Monaten ohnehin mehr geworben wird.

Wie interpretieren wir den Achsenabschnitt?



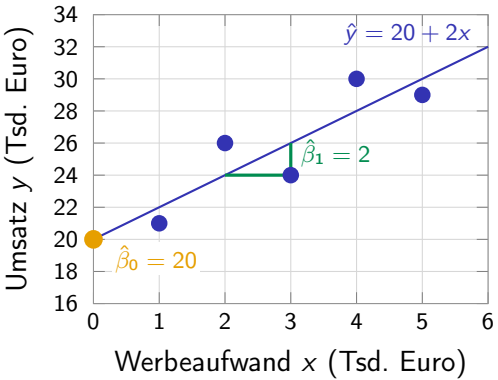
Achsenabschnitt $\hat{\beta}_0 = 20$

$\hat{\beta}_0 = \hat{y}\,|_{x=0}$: der Wert der Geraden bei $x = 0$. Hier: laut Gerade 20 Tsd. Euro Umsatz in einem Monat ohne Werbung.

Vorsicht bei der Deutung

- $x = 0$ wurde *nicht beobachtet* (Daten: 1 bis 5): Die Gerade wird dorthin *extrapoliert*.
- Liegt $x = 0$ weit außerhalb des Datenbereichs, hat $\hat{\beta}_0$ oft keine inhaltliche Bedeutung; er legt dann nur die Höhe der Geraden fest.

Interpretation im Überblick



$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x = 20 + 2x$

$\hat{\beta}_0 = 20$ Höhe der Geraden bei $x = 0$: Umsatz laut Gerade ohne Werbung (Extrapolation).

$\hat{\beta}_1 = 2$ Je Tsd. Euro mehr Werbung 2 Tsd. Euro mehr Umsatz laut Gerade; kein Kausalbeweis.

Aufgabe

Für ein anderes Unternehmen wurde $\hat{y} = 12 + 0{,}8\,x$ geschätzt (gleiche Variablen und Einheiten, beobachtet: x von 5 bis 40). Erläutern Sie beide Parameter in eigenen Worten.

Zweites Beispiel: Preis und Absatz der Leuchte

Daten aus dem Einstieg ($n = 9$ Geschäfte) und Arbeitstabelle

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120	$\sum$
Menge y_i	20	17	15	9	11	8	4	4	2	
$x_i - \bar{x}$	-20	-15	-10	-5	0	5	10	15	20	0
$y_i - \bar{y}$	10	7	5	-1	1	-2	-6	-6	-8	0
$(x_i - \bar{x})(y_i - \bar{y})$	-200	-105	-50	-5	0	-10	-60	-90	-160	-670
$(x_i - \bar{x})^2$	400	225	100	25	0	25	100	225	400	1500

Schritte 1 bis 3

$\bar{x} = 900/9 = 100, \quad \bar{y} = 90/9 = 10$

$s_{xy} = -670/8 = -83{,}75, \quad s_x^2 = 1500/8 = 187{,}5$

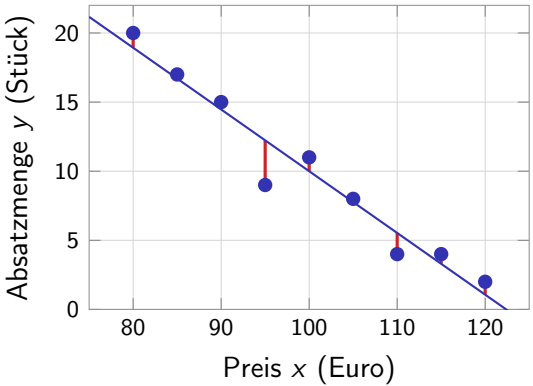
Schritte 4 bis 6

$\hat{\beta}_1 = -83{,}75/187{,}5 = -0{,}4467$

$\hat{\beta}_0 = 10 - (-0{,}4467) \cdot 100 = 54{,}67$

$\hat{y} = 54{,}67 - 0{,}4467\, x$

Preis und Absatz: Interpretation der Koeffizienten



Steigung $\hat{\beta}_1 = -0{,}4467$

Steigt der Preis um 1 Euro, so sinkt die laut Gerade erwartete Absatzmenge um 0,4467 Stück: eine fallende **Preis-Absatz-Funktion**.

Achsenabschnitt $\hat{\beta}_0 = 54{,}67$

Rechnerisch der Absatz bei einem Preis von 0 Euro. Dieser Wert liegt *weit* außerhalb des beobachteten Bereichs (80 bis 120 Euro): $\hat{\beta}_0$ ist hier **inhaltlich nicht interpretierbar**. Allgemein sind Aussagen außerhalb des Datenbereichs (*Extrapolation*) unsicher.

Lineare Regression mit R

Koeffizienten manuell (Schritte 2 bis 5)

```
(beta1 ← cov(preis, menge) / var(preis))
(beta0 ← mean(menge) - beta1 * mean(preis))
```

Dasselbe mit der Funktion `lm()` (*linear model*)

```
reg ← lm(menge ∼ preis)
coef(reg)                          # Achsenabschnitt und Steigung
```

Streuungsdiagramm mit Regressionsgeraden

```
plot(preis, menge, xlim = c(0, 125), ylim = c(0, 22))
abline(reg)
```

Übungsaufgabe: Koeffizienten deuten und Prognosen ableiten

Daten: Möbelhaus, sechs Wochen $i = 1, \ldots, 6$ (jeweils in Tsd. Euro)

Werbeausgaben x_i (Tsd. Euro)	2	4	6	8	10	12
Wochenumsatz y_i (Tsd. Euro)	44	49	58	62	61	71

Mit R geschätzte KQ-Gerade: $\hat{y} = 40 + 2{,}5\,x$.

Aufgaben

a) $\hat{\beta}_0 = 40$ und $\hat{\beta}_1 = 2{,}5$ inhaltlich deuten (mit Einheiten). Ist $\hat{\beta}_0$ sinnvoll interpretierbar?

b) Erwarteter Wochenumsatz bei Werbeausgaben von 5 bzw. 30 Tsd. Euro? Wie belastbar sind die beiden Prognosen?

c) Um wie viel ändert sich der erwartete Umsatz bei 2 Tsd. Euro mehr Werbung – von 4 auf 6 und von 10 auf 12 Tsd. Euro?

d) Werbeausgaben in Euro statt in Tsd. Euro gemessen: Wie lauten $\hat{\beta}_0$ und $\hat{\beta}_1$ dann? Und wenn zusätzlich der Umsatz in Euro gemessen wird?

Lösung (1/3): Koeffizienten deuten und Änderungen berechnen

Regel: $\hat{\beta}_1$ ist die Änderung von $\hat{y}$ je Einheit x; $\hat{\beta}_0$ der Wert von $\hat{y}$ bei $x = 0$; bei Δx gilt $\Delta\hat{y} = \hat{\beta}_1 \cdot \Delta x$.

a) Steigung $\hat{\beta}_1 = 2{,}5$

Je Tsd. Euro mehr Werbung ist laut Gerade ein um 2,5 **Tsd. Euro höherer Wochenumsatz** zu erwarten – statistischer Zusammenhang, kein Kausalbeweis.

a) Achsenabschnitt $\hat{\beta}_0 = 40$

Umsatz laut Gerade in einer Woche *ohne* Werbung: 40 **Tsd. Euro**. $x = 0$ wurde nicht beobachtet (Daten: 2 bis 12), liegt aber nahe daran: grobe Orientierung, streng genommen Extrapolation.

c) Änderung um $\Delta x = 2$

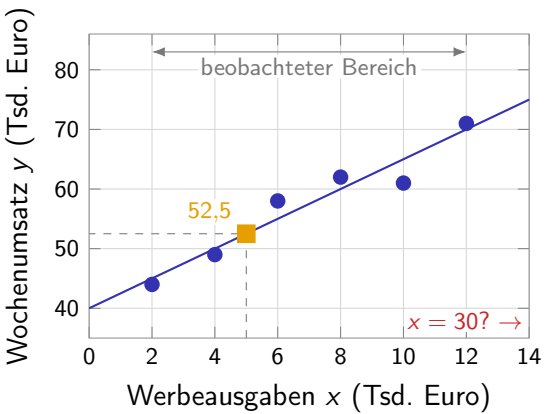
$\Delta\hat{y} = 2{,}5 \cdot 2 = 5$ Tsd. Euro – in beiden Fällen:

$4 \to 6$: $\hat{y}$ von $40 + 2{,}5 \cdot 4 = 50$ auf 55

$10 \to 12$: $\hat{y}$ von 65 auf 70

Eine Gerade hat überall dieselbe Steigung: Der Zuwachs hängt nicht vom Ausgangsniveau ab, $\hat{\beta}_0$ spielt dafür keine Rolle.

Lösung (2/3): Prognosen und ihre Grenzen



b) Regel: x in die Gerade einsetzen

$x = 5$: $\hat{y} = 40 + 2{,}5 \cdot 5 = 52{,}5$ Tsd. Euro

$x = 30$: $\hat{y} = 40 + 2{,}5 \cdot 30 = 115$ Tsd. Euro

$x = 5$: Interpolation

Im beobachteten Bereich (2 bis 12): plausibel – als Erwartung, nicht als sicherer Wert (Residuen bis ± 4).

$x = 30$: Extrapolation

Weit außerhalb der Daten: Ob der Zusammenhang dort noch linear ist (Sättigung?), wurde nie beobachtet. **Nicht belastbar.**

Lösung (3/3): Andere Einheiten – und die Kontrolle mit R

d) Regel: Die Einheit von x ändert die Steigung, die Einheit von y beide Koeffizienten

Werbeausgaben in Euro: $x_{\text{Euro}} = 1000\,x$, also $\hat{y} = 40 + 2{,}5\,x = 40 + \frac{2{,}5}{1000}\,x_{\text{Euro}}$: $\hat{\beta}_1 = 0{,}0025$ (Tsd. Euro je Euro), $\hat{\beta}_0 = 40$ unverändert.
Zusätzlich Umsatz in Euro (beide Seiten mal 1000): $\hat{y}_{\text{Euro}} = 40\,000 + 2{,}5\,x_{\text{Euro}}$ – je Euro Werbung 2,50 Euro mehr Umsatz: **dieselbe Aussage**.

Kontrolle mit R

```
reg ← lm(umsatz ~ werbung)
coef(reg)                                          # 40.0   2.5
predict(reg, newdata = data.frame(werbung = c(5, 30)))   # 52.5 115.0
coef(lm(umsatz ~ I(1000 * werbung)))               # 40.0000   0.0025
```

Kernaussage

Der Zahlenwert von $\hat{\beta}_1$ hängt von den Einheiten ab, die inhaltliche Aussage nicht.

Rückblick: Können Sie diese Fragen beantworten?

1. Warum beschreiben wir den Zusammenhang zweier metrischer Variablen mit einer Geraden?
2. Wie wird eine Gerade mathematisch dargestellt?
3. Was bedeuten Achsenabschnitt und Steigung?
4. Warum brauchen wir ein objektives Kriterium für die beste Gerade?
5. Was sind Residuen, und weshalb werden sie quadriert?
6. Welches Minimierungsproblem löst die KQ-Methode?
7. Wie liefert die Differentialrechnung die KQ-Schätzer?
8. Weshalb ist die Steigung der Quotient aus Kovarianz und Varianz?
9. Wie berechnet man eine Regression für wenige Beobachtungen von Hand?
10. Wie interpretiert man die geschätzten Parameter – und was nicht?

Kernaussage

Die KQ-Gerade ist die Gerade mit der kleinsten Residuenquadratsumme – berechnet aus $\bar{x}$, $\bar{y}$, s_{xy} und s_x^2.

Übergang: Vom Beschreiben der Daten zum Regressionsmodell

Jetzt: eine Vorstellung davon, wie die Daten entstehen

Bisher *beschreibt* die KQ-Gerade die Punktwolke so gut wie möglich. Nun nehmen wir an, dass die Daten so entstehen:

$$y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\text{systematischer Teil}} + \underbrace{u_i}_{\text{Störterm}}$$

$\beta_0,\ \beta_1$ *wahre*, unbekannte Parameter; $\hat{\beta}_0$, $\hat{\beta}_1$ sind ihre Schätzungen aus den Daten.

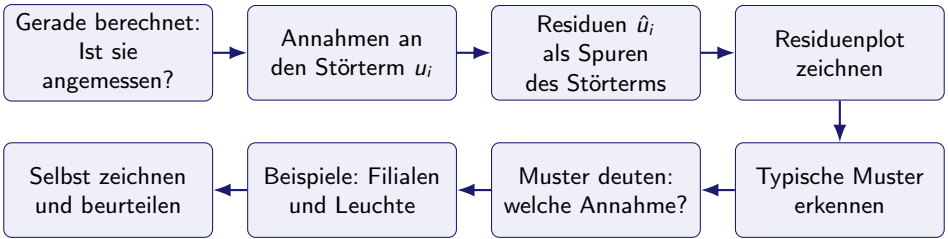
u_i alles, was x nicht erklärt (andere Einflüsse, Zufall); *nicht beobachtbar*.

$\hat{u}_i = y_i - \hat{y}_i$ das Residuum: die aus den Daten berechnete Schätzung für u_i.

Was folgt

Verlässliche Schätzungen setzen Annahmen über den Störterm voraus. Prüfen können wir sie nur anhand der Residuen $\hat{u}_i$: die **Residuenanalyse**.

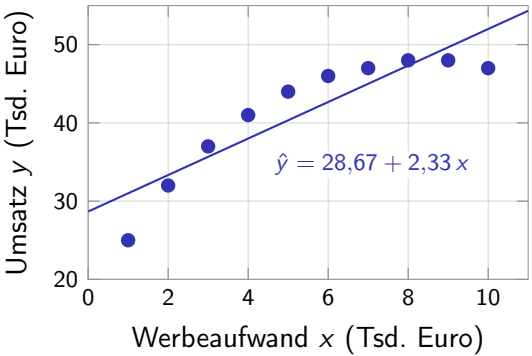
Fahrplan: Passt eine Gerade überhaupt zu den Daten?



Kernaussage

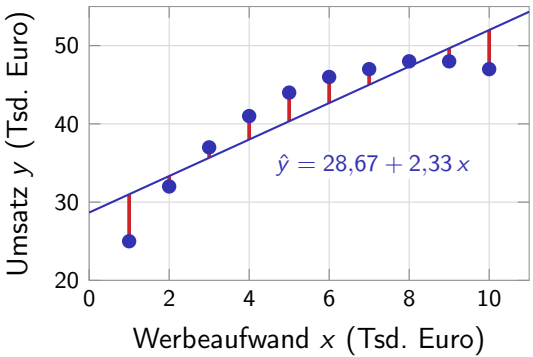
Die KQ-Gerade lässt sich für *jede* Punktwolke berechnen. Ob eine Gerade die Daten angemessen beschreibt, verraten erst die **Residuen**.

Eine Gerade lässt sich immer berechnen – aber passt sie?



Zehn Regionen, KQ-Gerade wie gewohnt berechnet.
Beschreibt sie die Daten gut?

Eine Gerade lässt sich immer berechnen – aber passt sie?

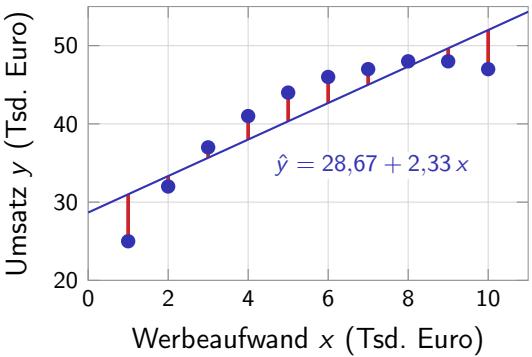


Zehn Regionen, KQ-Gerade wie gewohnt berechnet.
Beschreibt sie die Daten gut?

Beobachtung

An den Rändern liegen die Punkte *unter* der Geraden, in der Mitte *darüber*. Residuen: $-6{,}0$; $-1{,}3$; $1{,}3$; $3{,}0$; $3{,}7$; $3{,}3$; $2{,}0$; $0{,}7$; $-1{,}7$; $-5{,}0$.

Eine Gerade lässt sich immer berechnen – aber passt sie?



Zehn Regionen, KQ-Gerade wie gewohnt berechnet. Beschreibt sie die Daten gut?

Beobachtung

An den Rändern liegen die Punkte *unter* der Geraden, in der Mitte *darüber*. Residuen: $-6{,}0$; $-1{,}3$; $1{,}3$; $3{,}0$; $3{,}7$; $3{,}3$; $2{,}0$; $0{,}7$; $-1{,}7$; $-5{,}0$.

Ursache

Sättigung: Zusätzliche Werbung wirkt immer schwächer. Der Zusammenhang ist nicht linear.

Leitfrage

Wie erkennen wir solche Muster *systematisch* – auch wenn sie weniger offensichtlich sind?

Was nehmen wir über den Störterm an?

Modell $y_i = \beta_0 + \beta_1 x_i + u_i$: Die Standardannahmen betreffen den *nicht beobachtbaren* Störterm u_i.

Annahme	**Formal**	**In Worten**
Erwartungswert null	$E(u_i) = 0$	Kein systematischer Fehler: Im Mittel liegen die Beobachtungen auf der wahren Geraden, für jedes x.
Homoskedastizität	$\mathrm{Var}(u_i) = \sigma^2$	Die Streuung um die Gerade ist überall gleich groß.
Keine Autokorrelation	$\mathrm{Cov}(u_i, u_j) = 0 \ (i \neq j)$	Die Störungen hängen nicht voneinander ab (z. B. von Monat zu Monat).
Normalverteilung	$u_i \sim \mathcal{N}(0, \sigma^2)$	Die Störungen streuen glockenförmig um null.

Das Problem

u_i ist nicht beobachtbar. Prüfen können wir die Annahmen nur über die **Residuen** $\hat{u}_i = y_i - \hat{y}_i$, unsere Schätzungen für u_i.

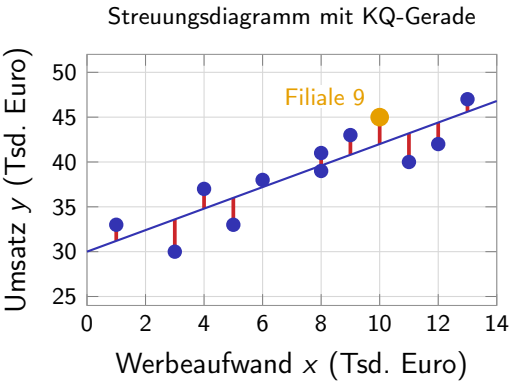
Was passiert, wenn eine Annahme verletzt ist?

Annahme	**Typisch verletzt bei**	**Folge**	**Prüfwerkzeug**
Erwartungswert null	nichtlinearem Zusammenhang, fehlender Einflussgröße	Gerade systematisch falsch, Schätzungen **verzerrt**	Residuenplot: **Bogen**
Homoskedastizität	Streuung wächst mit x (große Filialen schwanken stärker)	Schätzer unverzerrt, aber Standardfehler und Tests **unzuverlässig**	Residuenplot: **Trichter**
Keine Autokorrelation	Zeitreihen (Monatsumsätze)	wie bei Heteroskedastizität	Residuen über die Zeit: **Wellen**
Normalverteilung	schiefen Verteilungen, Ausreißern	Konfidenzintervalle und Tests bei kleinem n unzuverlässig	**QQ-Plot** (Anhang)

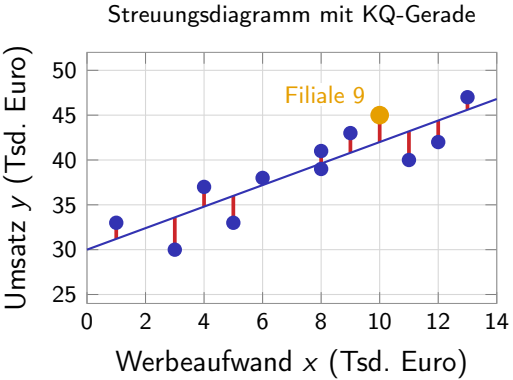
Kernaussage

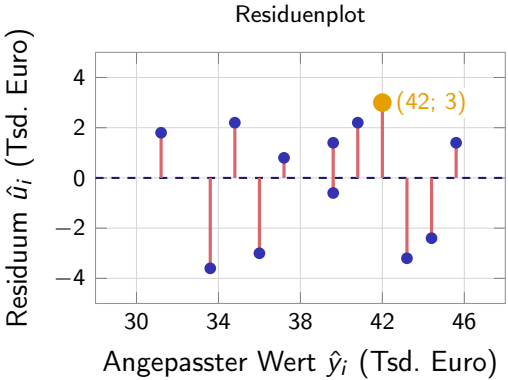
Berechnen lässt sich die KQ-Gerade immer. Die Annahmen entscheiden, wie verlässlich die Schlüsse auf die *wahren* Parameter β_0, β_1 sind.

Vom Streuungsdiagramm zum Residuenplot



Vom Streuungsdiagramm zum Residuenplot





Jeder Punkt wandert an die Stelle $(\hat{y}_i, \hat{u}_i)$: Filiale 9 mit $\hat{y}_9 = 42$ und $\hat{u}_9 = 3$. **Die Gerade wird zur Nulllinie**, die Abweichungen werden vergrößert sichtbar.

Der Residuenplot

Aufbau

x-Achse angepasste Werte $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$

y-Achse Residuen $\hat{u}_i = y_i - \hat{y}_i$

Nulllinie entspricht der KQ-Geraden

Gezeichnet werden die Punkte $(\hat{y}_i,\ \hat{u}_i)$, $i = 1, \ldots, n$.

Warum $\hat{y}_i$ und nicht x_i?

$\hat{y}_i$ ist nur eine lineare Umrechnung von x_i: Das Muster bleibt gleich (bei $\hat{\beta}_1 < 0$ gespiegelt). Mit $\hat{y}_i$ funktioniert der Plot auch bei mehreren erklärenden Variablen.

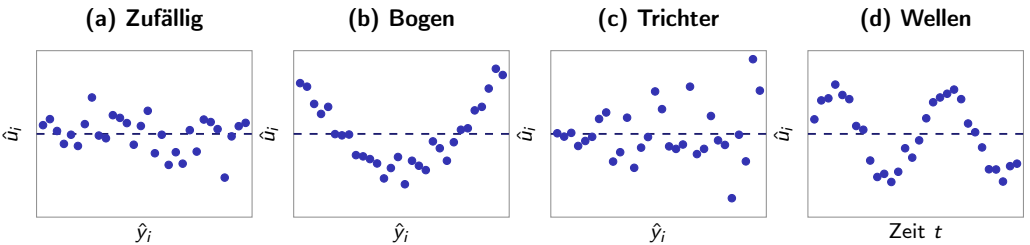
Was immer gilt

Die KQ-Residuen summieren sich zu null (Bedingung erster Ordnung): $\sum \hat{u}_i = 0$. Die Punkte liegen also *insgesamt* stets um die Nulllinie. Aussagekraft hat nur ihre **Struktur**.

Kernaussage

Ideal ist eine **strukturlose** Punktwolke in einem gleichmäßig breiten Band um die Nulllinie: Dann hat die Gerade alles Systematische erfasst.

Vier typische Muster im Residuenplot



gleichmäßiges Band

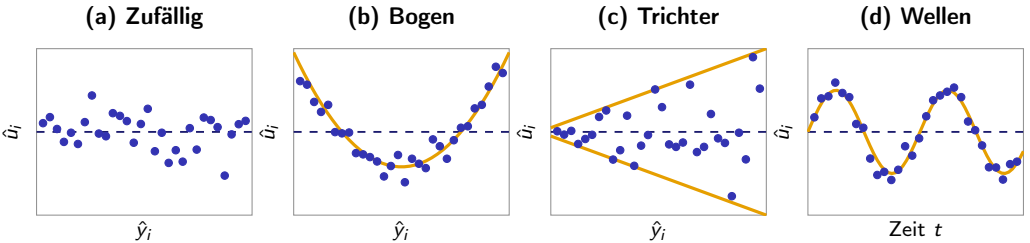
erst positiv, dann negativ, dann positiv

Streuung wächst mit $\hat{y}$

lange Phasen gleichen Vorzeichens

Bei Zeitreihen werden die Residuen zusätzlich in zeitlicher Reihenfolge gezeichnet: Nur so werden Wellen sichtbar.

Vier typische Muster im Residuenplot



gleichmäßiges Band

Modell passt

erst positiv, dann negativ, dann positiv

falsche Funktionsform

Streuung wächst mit $\hat{y}$

Heteroskedastizität

lange Phasen gleichen Vorzeichens

Autokorrelation

Bei Zeitreihen werden die Residuen zusätzlich in zeitlicher Reihenfolge gezeichnet: Nur so werden Wellen sichtbar.

Muster deuten: Was steckt dahinter?

Muster	Was man sieht	Hinweis auf	Mögliche Abhilfe (Ausblick)
Zufällig	unregelmäßige Wolke, überall gleich breit	Modell angemessen	–
Bogen	Residuen in Gruppen: erst über, dann unter null (oder umgekehrt)	nichtlinearer Zusammenhang, fehlende Einflussgröße	andere Funktionsform, z. B. Logarithmus oder quadratischer Term
Trichter	Streuung wächst (oder schrumpft) mit $\hat{y}$	Heteroskedastizität	Transformation, robuste Standardfehler
Wellen	lange Phasen gleichen Vorzeichens in zeitlicher Folge	Autokorrelation	Zeitreihenmethoden

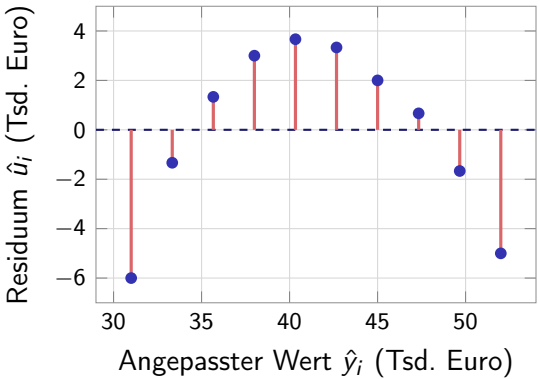
Einzelne Ausreißer

Ursache prüfen (Tippfehler? Sonderaktion?), *nicht* automatisch löschen.

Wenige Beobachtungen

Bei kleinem n entstehen zufällig scheinbare Muster: nur deutliche Strukturen ernst nehmen.

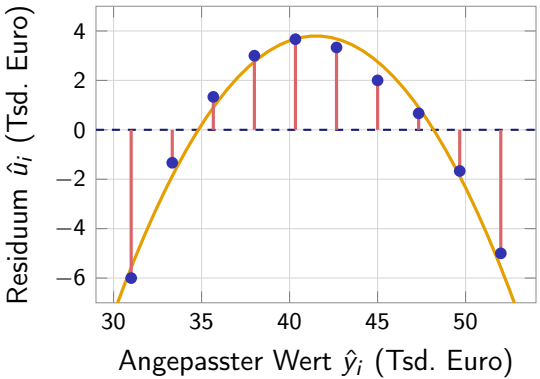
Zurück zum Sättigungsbeispiel



Befund

Die Residuen bilden einen deutlichen **Bogen**: negativ, positiv, negativ.

Zurück zum Sättigungsbeispiel



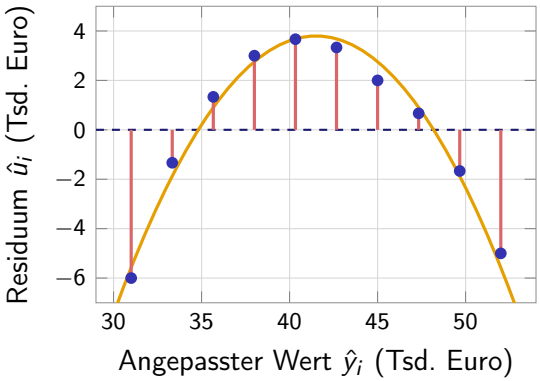
Befund

Die Residuen bilden einen deutlichen **Bogen**: negativ, positiv, negativ.

Deutung

Die Gerade unterschätzt den Umsatz in der Mitte und überschätzt ihn an den Rändern: **falsche Funktionsform**. Angemessener wäre eine Kurve mit abnehmendem Zuwachs.

Zurück zum Sättigungsbeispiel



Befund

Die Residuen bilden einen deutlichen **Bogen**: negativ, positiv, negativ.

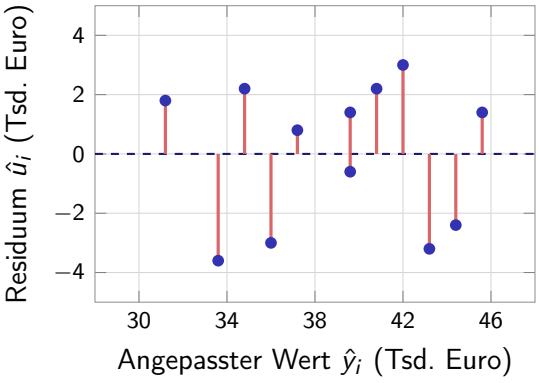
Deutung

Die Gerade unterschätzt den Umsatz in der Mitte und überschätzt ihn an den Rändern: **falsche Funktionsform**. Angemessener wäre eine Kurve mit abnehmendem Zuwachs.

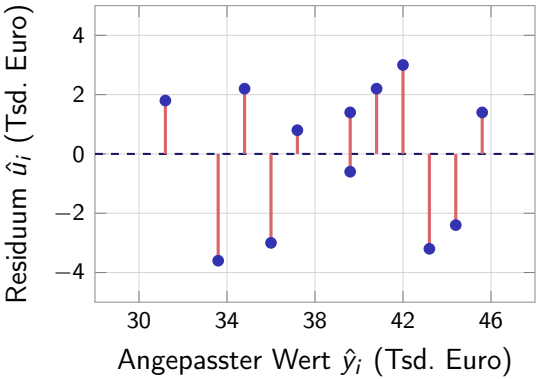
Kernaussage

Der Residuenplot zeigt, was die Gerade allein nicht verrät.

Beispiel zwölf Filialen: Residuenplot beurteilen



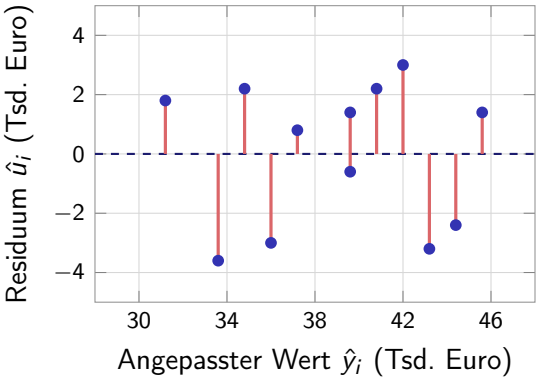
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein** – positive und negative Residuen wechseln unregelmäßig.

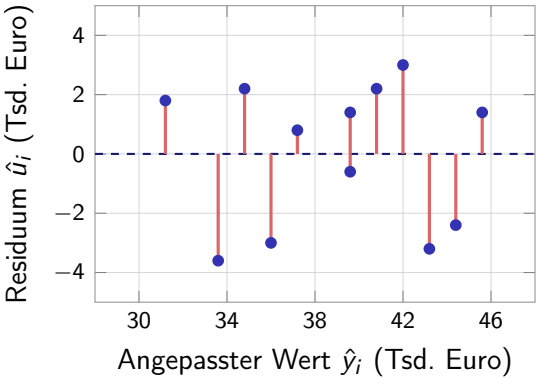
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein** – positive und negative Residuen wechseln unregelmäßig.
- Trichter? **Nein** – die Streuung ist links und rechts ähnlich groß.

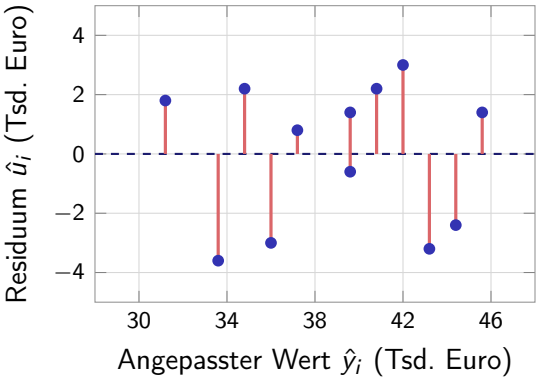
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein** – positive und negative Residuen wechseln unregelmäßig.
- Trichter? **Nein** – die Streuung ist links und rechts ähnlich groß.
- Ausreißer? **Nein** – das größte Residuum ist $|\hat{u}_2| = 3{,}6$, kein Punkt fällt aus dem Rahmen.

Beispiel zwölf Filialen: Residuenplot beurteilen



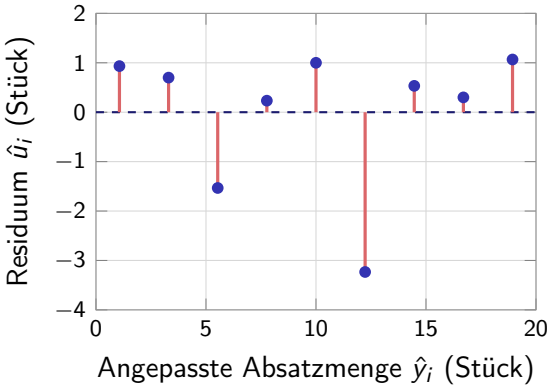
Prüfliste

- Bogen? **Nein** – positive und negative Residuen wechseln unregelmäßig.
- Trichter? **Nein** – die Streuung ist links und rechts ähnlich groß.
- Ausreißer? **Nein** – das größte Residuum ist $|\hat{u}_2| = 3{,}6$, kein Punkt fällt aus dem Rahmen.

Fazit

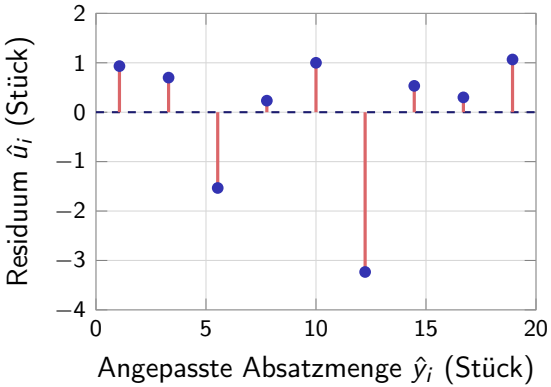
Keine Systematik erkennbar: Die Gerade ist für diese Daten angemessen. Vorsicht: Mit $n = 12$ lassen sich nur deutliche Muster erkennen.

Beispiel Leuchte: Residuenplot beurteilen



$\hat{y} = 54{,}67 - 0{,}4467\,x$; hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Beispiel Leuchte: Residuenplot beurteilen

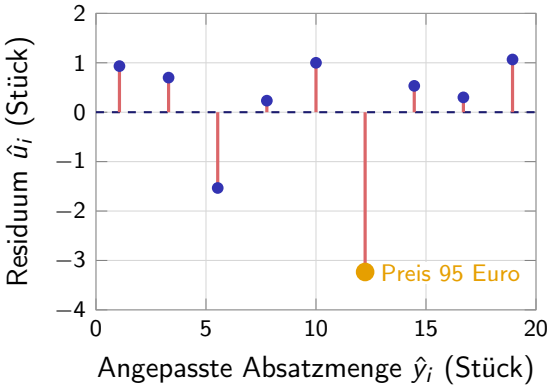


$\hat{y} = 54{,}67 - 0{,}4467\,x$; hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen oder Trichter? Keine klare Struktur erkennbar.

Beispiel Leuchte: Residuenplot beurteilen

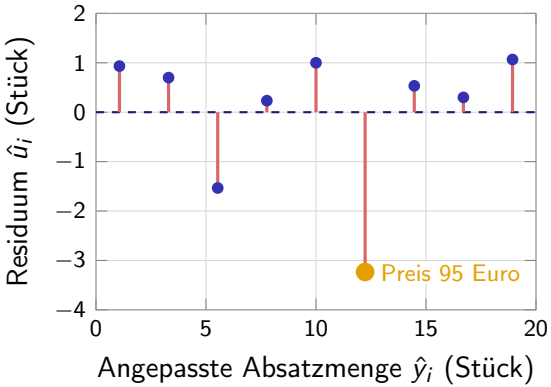


$\hat{y} = 54{,}67 - 0{,}4467\,x$; hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen oder Trichter? Keine klare Struktur erkennbar.
- Ausreißer? Ein **auffälliges Residuum**: Beim Preis von 95 Euro wurden 9 statt der erwarteten 12,2 Stück verkauft ($\hat{u}_4 = -3{,}23$).

Beispiel Leuchte: Residuenplot beurteilen



$\hat{y} = 54{,}67 - 0{,}4467\,x$; hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen oder Trichter? Keine klare Struktur erkennbar.
- Ausreißer? Ein **auffälliges Residuum**: Beim Preis von 95 Euro wurden 9 statt der erwarteten 12,2 Stück verkauft ($\hat{u}_4 = -3{,}23$).

Fazit

Keine eindeutige Systematik. Den auffälligen Wert inhaltlich prüfen (Lieferengpass? Erfassungsfehler?). Bei $n = 9$ ist jedes Urteil unsicher.

Residuenplot mit R erstellen

R-Befehle (Beispiel Leuchte)

```
reg ← lm(menge ∼ preis)
plot(fitted(reg), resid(reg),
     xlab = "angepasste Werte", ylab = "Residuen", main = "Residuenplot")
abline(h = 0, lty = 2)                    # Nulllinie als Orientierung
```

Hilfsfunktionen

`fitted(reg)` angepasste Werte $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ – Werte auf der x-Achse

`resid(reg)` Residuen $\hat{u}_i = y_i - \hat{y}_i$ – Werte auf der y-Achse

Kontrolle

```
sum(resid(reg))       # praktisch 0 (Rundung): Bedingung erster Ordnung
```

Übungsaufgabe: Einen Residuenplot selbst zeichnen

Online-Shop: KQ-Gerade $\hat{y} = 20 + 2\,x$

Monat i	1	2	3	4	5
x_i	1	2	3	4	5
y_i	21	26	24	30	29

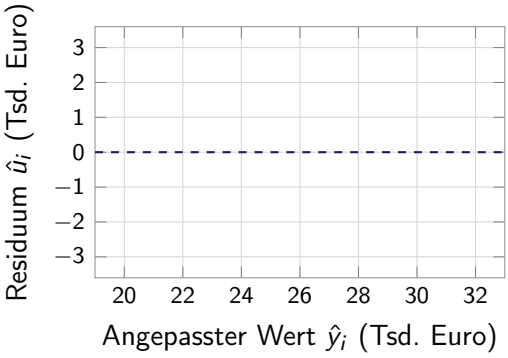
Aufgaben

a) Angepasste Werte $\hat{y}_i$ berechnen.

b) Residuen $\hat{u}_i$ berechnen; Summe kontrollieren.

c) Residuenplot zeichnen.

d) Beurteilen: Ist ein Muster erkennbar?



Vorlage zum Einzeichnen

Lösung: Residuenplot für den Online-Shop

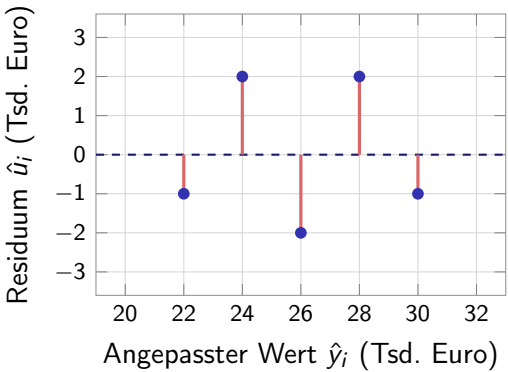
a) und b) Arbeitstabelle

i	x_i	y_i	$\hat{y}_i = 20 + 2x_i$	$\hat{u}_i = y_i - \hat{y}_i$
1	1	21	22	-1
2	2	26	24	2
3	3	24	26	-2
4	4	30	28	2
5	5	29	30	-1
$\sum$				0

d) Beurteilung

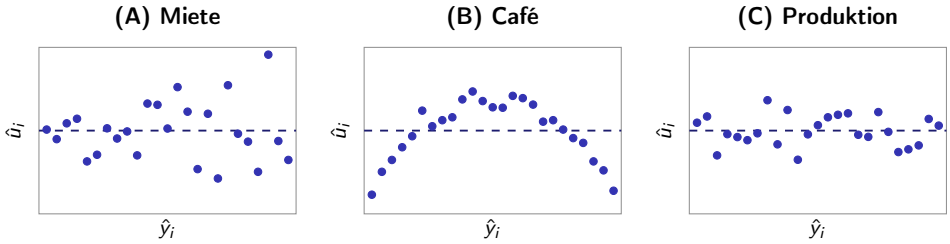
Kein Bogen, kein Trichter. Die Vorzeichen wechseln ab – bei nur fünf Werten **kein belastbares Muster**.

c) Residuenplot



Übungsaufgabe: Residuenplots diagnostizieren

Drei Regressionen (jeweils $n = 25$): **(A)** Monatsmiete (Euro) auf Wohnfläche (m^2); **(B)** Tagesumsatz eines Cafés (Euro) auf Außentemperatur (°C); **(C)** Produktionskosten (Euro) auf Stückzahl.



Aufgaben

a) Welches Muster zeigt jeder Residuenplot?

b) Welche Annahme über den Störterm ist jeweils verletzt – oder keine? Nennen Sie einen inhaltlichen Grund.

c) Was folgt daraus für die Verlässlichkeit der KQ-Geraden, und was wäre zu tun?

Lösung: Residuenplots diagnostizieren

Regel: Ideal ist ein strukturloses Band um die Nulllinie. Bogen $\rightarrow E(u_i) = 0$ verletzt; Trichter $\rightarrow$ Homoskedastizität verletzt.

Plot	a) Muster	b) Verletzte Annahme, Grund	c) Folge, Abhilfe
(A) Miete	**Trichter**: Streuung wächst mit $\hat{y}$	**Homoskedastizität** ($\mathrm{Var}(u_i) = \sigma^2$): Mieten großer Wohnungen streuen stärker (Lage, Ausstattung).	Gerade unverzerrt, Standardfehler und Tests unzuverlässig. Transformation (Logarithmus), robuste Standardfehler.
(B) Café	**Bogen**: negativ, positiv, negativ	**Erwartungswert null** ($E(u_i) = 0$): nicht linear – bei Hitze sinkt der Umsatz wieder; die Gerade unterschätzt die Mitte.	Gerade systematisch falsch, Schätzungen verzerrt. Andere Funktionsform, z. B. quadratischer Term.
(C) Produktion	**zufällig**: gleichmäßiges Band	**Keine** erkennbar verletzt: unsystematische Abweichungen.	Gerade angemessen; nichts zu ändern.

Erst das Muster benennen, dann die Annahme – und bei (C) auch den Mut haben zu sagen: **Das Modell passt.**

Rückblick Residuenanalyse

Können Sie diese Fragen beantworten?

1. Warum prüfen wir Annahmen über u_i mit $\hat{u}_i$?
2. Wie entsteht der Residuenplot aus dem Streuungsdiagramm?
3. Warum liegen die Residuen stets um die Nulllinie?
4. Welche Annahme ist bei Bogen, Trichter und Wellen verletzt?
5. Was tun Sie mit einem auffälligen Einzelwert?

Und die Normalverteilung?

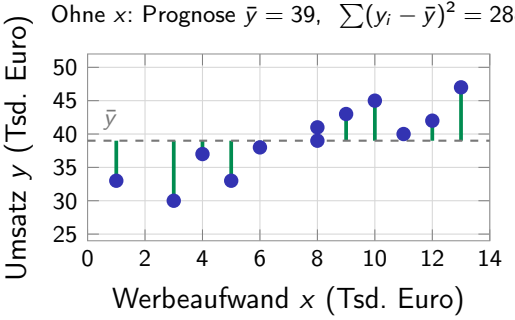
Sie wird erst für Konfidenzintervalle und Tests (Teil 6) benötigt. Geprüft wird sie mit dem **QQ-Plot**: siehe **Anhang**.

Kernaussage

Erst rechnen, dann prüfen: Ein strukturloser Residuenplot ist die Voraussetzung dafür, der KQ-Geraden zu vertrauen.

Wie viel erklärt die Gerade?

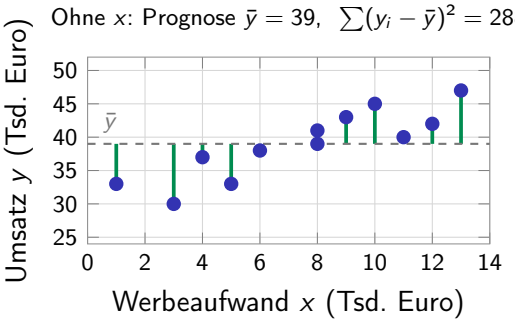
Ohne x: Prognose $\bar{y} = 39$, $\sum(y_i - \bar{y})^2 = 288$

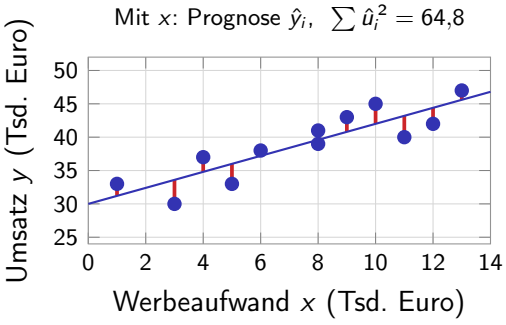


Leitfrage

Kennen wir den Werbeaufwand *nicht*, ist $\bar{y}$ die beste Schätzung für jeden Umsatz. Wie viel besser wird es *mit* der Geraden?

Wie viel erklärt die Gerade?

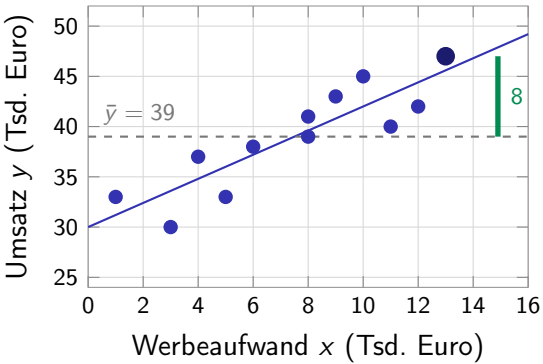




Kernaussage

Die Quadratsumme sinkt von 288 auf 64,8: Die Gerade „erklärt“ $223{,}2/288 = 77{,}5\,\%$ der Streuung der Umsätze.

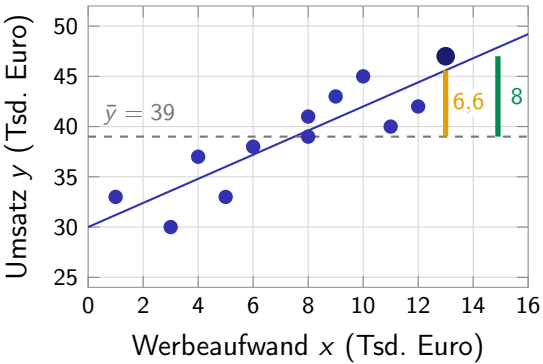
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- Gesamtabweichung: $y_{12} - \bar{y} = 47 - 39 = 8$

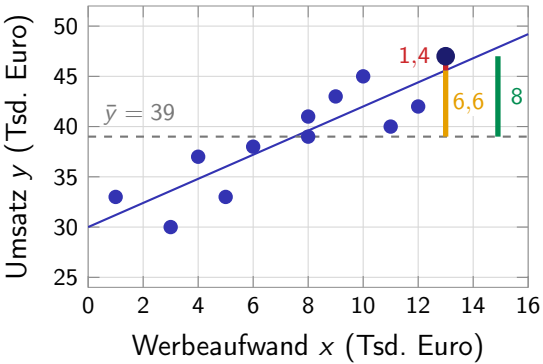
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- Gesamtabweichung: $y_{12} - \bar{y} = 47 - 39 = 8$
- durch die Gerade erklärt: $\hat{y}_{12} - \bar{y} = 45{,}6 - 39 = 6{,}6$

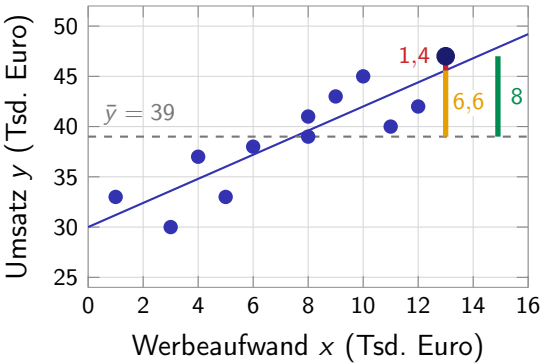
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- Gesamtabweichung: $y_{12} - \bar{y} = 47 - 39 = 8$
- durch die Gerade erklärt: $\hat{y}_{12} - \bar{y} = 45{,}6 - 39 = 6{,}6$
- nicht erklärt (Residuum): $y_{12} - \hat{y}_{12} = 47 - 45{,}6 = 1{,}4$

Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- Gesamtabweichung: $y_{12} - \bar{y} = 47 - 39 = 8$
- durch die Gerade erklärt: $\hat{y}_{12} - \bar{y} = 45{,}6 - 39 = 6{,}6$
- nicht erklärt (Residuum): $y_{12} - \hat{y}_{12} = 47 - 45{,}6 = 1{,}4$

Allgemein

$$\underbrace{y_i - \bar{y}}_{\text{gesamt}} = \underbrace{\hat{y}_i - \bar{y}}_{\text{erklärt}} + \underbrace{y_i - \hat{y}_i}_{\text{Residuum}}$$

In Worten: Abweichung vom Durchschnitt = durch den Werbeaufwand erklärter Teil + Rest.

Streuungszerlegung: Quadrieren und summieren

Quadratsummenzerlegung (gilt für die KQ-Gerade)

$$\underbrace{\sum_{i=1}^{n}(y_i-\bar{y})^2}_{\text{SQT (total)}} = \underbrace{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}_{\text{SQE (erklärt)}} + \underbrace{\sum_{i=1}^{n}\hat{u}_i^2}_{\text{SQR (Residuen)}}$$

Filiale i	1	2	3	4	5	6	7	8	9	10	11	12	Summe
$(y_i-\bar{y})^2$	36	81	4	36	1	4	0	16	36	1	9	64	288
$(\hat{y}_i-\bar{y})^2$	60,84	29,16	17,64	9,00	3,24	0,36	0,36	3,24	9,00	17,64	29,16	43,56	223,2
$\hat{u}_i^2$	3,24	12,96	4,84	9,00	0,64	1,96	0,36	4,84	9,00	10,24	5,76	1,96	64,8

Zwölf Filialen

$288 = 223{,}2 + 64{,}8$ ✓

Achtung

Die Zerlegung gilt für die *Summen*, nicht für jede Filiale einzeln: Filiale 1 hat $36 \neq 60{,}84 + 3{,}24$.

Streuungszerlegung und Kleinste Quadrate

Warum geht die Zerlegung auf?

Quadriert man $a + b$ mit $a = \hat{y}_i - \bar{y}$, $b = \hat{u}_i$, entsteht $a^2 + 2ab + b^2$. Der gemischte Term verschwindet in der Summe:

$$\sum (\hat{y}_i - \bar{y})\,\hat{u}_i \;=\; \hat{\beta}_1 \sum (x_i - \bar{x})\,\hat{u}_i \;=\; 0,$$

denn die KQ-Residuen erfüllen $\sum \hat{u}_i = 0$ und $\sum x_i \hat{u}_i = 0$ (Bedingungen erster Ordnung).

Für andere Geraden (z. B. A) gilt sie *nicht*.

Was die KQ-Methode bewirkt

$$\underbrace{\text{SQT}}_{\text{fest}} = \underbrace{\text{SQE}}_{\text{maximal}} + \underbrace{\text{SQR}}_{\text{minimal}}$$

- SQT hängt nur von den y_i ab.
- Die KQ-Gerade macht SQR minimal.
- Also ist der erklärte Teil SQE maximal.

Kernaussage

Keine andere Gerade erklärt einen größeren Teil der Streuung als die KQ-Gerade.

Das Bestimmtheitsmaß R^2

Definition

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = 1 - \frac{\text{SQR}}{\text{SQT}} \qquad 0 \leq R^2 \leq 1$$

In Worten: der *Anteil* der Streuung von y, den die Regression auf x erklärt.

Zwölf Filialen

$$R^2 = \frac{223{,}2}{288} = 1 - \frac{64{,}8}{288} = 0{,}775$$

77,5 % der Streuung der Umsätze erklärt der Werbeaufwand (linear), 22,5 % bleiben unerklärt.

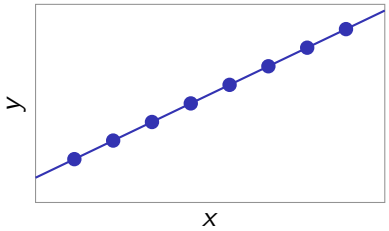
Auch über Varianzen

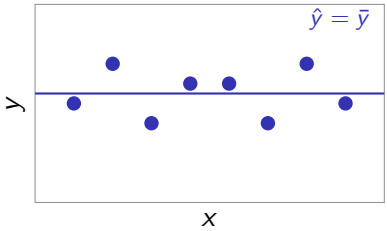
Alle Quadratsummen durch $n - 1$ geteilt:

$$s_y^2 = s_{\hat{y}}^2 + s_{\hat{u}}^2, \qquad R^2 = \frac{s_{\hat{y}}^2}{s_y^2}$$

Der Faktor kürzt sich (auch bei $\frac{1}{n}$).

Die Extremfälle: $R^2 = 1$ und $R^2 = 0$





$R^2 = 1$: perfekte Anpassung

Alle Punkte liegen *auf* der Geraden: SQR $= 0$. Die gesamte Streuung von y wird erklärt.

$R^2 = 0$: nichts erklärt

$\hat{\beta}_1 = 0$: Die Gerade verläuft waagerecht in Höhe von $\bar{y}$, SQE $= 0$. Das Wissen über x verbessert die Prognose nicht.

Bestimmtheitsmaß und Korrelationskoeffizient

Schritt 1: Erklärte Abweichung

Aus $\bar{y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{x}$ (Gerade durch den Schwerpunkt) folgt $\hat{y}_i - \bar{y} = \hat{\beta}_1 (x_i - \bar{x})$, also $\mathrm{SQE} = \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$.

Schritt 2: Einsetzen von $\hat{\beta}_1 = \sum (x_i - \bar{x})(y_i - \bar{y}) / \sum (x_i - \bar{x})^2$

$$R^2 = \frac{\mathrm{SQE}}{\mathrm{SQT}} = \frac{\hat{\beta}_1^2 \sum (x_i - \bar{x})^2}{\sum (y_i - \bar{y})^2} = \frac{\left(\sum (x_i - \bar{x})(y_i - \bar{y})\right)^2}{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2} = r_{xy}^2$$

Kernaussage

In der Einfachregression ist das Bestimmtheitsmaß das **Quadrat des Korrelationskoeffizienten**.

Zwölf Filialen

$r_{xy} = \frac{186}{\sqrt{155 \cdot 288}} = 0{,}8803$

$r_{xy}^2 = 0{,}775 = R^2$ ✓

Ebenso: $\mathrm{SQE} = 1{,}2^2 \cdot 155 = 223{,}2$.

Was R^2 verrät – und was nicht

Keine Richtung

$\sqrt{R^2} = |r_{xy}|$: Beim Quadrieren geht das Vorzeichen verloren. Ob der Zusammenhang positiv oder negativ ist, zeigen nur r_{xy} und $\hat{\beta}_1$.

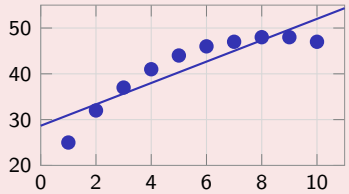
Nur der *lineare* Zusammenhang

Ein kleines R^2 heißt nicht, dass y nicht von x abhängt – nur, dass eine *Gerade* wenig erklärt.

Keine Kausalität

Ein hohes R^2 belegt keinen Ursache-Wirkungs-Zusammenhang.

Hohes R^2, trotzdem falsches Modell



Sättigungsbeispiel: $R^2 = 0{,}81$ – und doch zeigt der Residuenplot einen deutlichen Bogen.

Kernaussage

R^2 ersetzt den Residuenplot nicht.

Bestimmtheitsmaß beurteilen

Faustregel dieser Veranstaltung

Wert von R^2	Beurteilung
$R^2 < 0{,}6$	schwache Anpassung
$0{,}6 \leq R^2 < 0{,}8$	mäßige Anpassung
$R^2 \geq 0{,}8$	gute Anpassung

$R^2 = r_{xy}^2$ wächst *überproportional* mit $|r_{xy}|$: $r_{xy} = 0{,}7$ ergibt nur $R^2 = 0{,}49$.

Unsere Beispiele

Zwölf Filialen	$R^2 = 0{,}775$	mäßig
Leuchte	$R^2 = 0{,}947$	gut
Sättigungsbeispiel	$R^2 = 0{,}81$	gut – aber Bogen!

Mit Augenmaß verwenden

Was als „hoch“ gilt, hängt vom Fach und den Daten ab: Bei Zeitreihen sind Werte über 0,9 üblich, bei Daten über einzelne Personen oft schon Werte um 0,3 beachtlich.

Beispiel Leuchte: Bestimmtheitsmaß berechnen

Bekannt aus der Arbeitstabelle

$\sum(x_i - \bar{x})(y_i - \bar{y}) = -670, \quad \sum(x_i - \bar{x})^2 = 1500,$
$\hat{\beta}_1 = -0{,}4467$

Quadratsummen

- $\text{SQT} = \sum(y_i - \bar{y})^2 =$
  $10^2 + 7^2 + \ldots + (-8)^2 = 316$
- $\text{SQE} = \hat{\beta}_1^2 \sum(x_i - \bar{x})^2 = \left(\frac{-670}{1500}\right)^2 \cdot 1500 =$
  $299{,}27$
- $\text{SQR} = 316 - 299{,}27 = 16{,}73$

Bestimmtheitsmaß

$$R^2 = \frac{299{,}27}{316} = 1 - \frac{16{,}73}{316} = 0{,}9470$$

Kontrolle: $r_{xy} = \frac{-670}{\sqrt{1500 \cdot 316}} = -0{,}9732,$
$r_{xy}^2 = 0{,}9470$ ✓

Interpretation

94,7 % der Streuung der Absatzmengen werden durch den Preis (linear) erklärt: **gute Anpassung**. Das Vorzeichen (fallende Preis-Absatz-Funktion) steckt in $\hat{\beta}_1 < 0$, nicht in R^2.

Bestimmtheitsmaß von R ausgeben lassen

Komplette Ausgabe

```
reg ← lm(menge ∼ preis)
summary(reg)                # Zeile "Multiple R-squared: 0.947"
```

Drei Wege zum selben Wert

```
summary(reg)$r.squared                                  # direkt
1 - sum(resid(reg)^2) / sum((menge - mean(menge))^2)    # 1 - SQR/SQT
cor(preis, menge)^2                                     # r^2 (Einfachregression)
```

Die Ausgabe von `summary()` enthält weitere Größen (Standardfehler, t-Werte, p-Werte); sie werden in Teil 6 erklärt.

Übungsaufgabe: Bestimmtheitsmaß selbst berechnen

Daten: Online-Shop (fünf Monate), $\hat{y} = 20 + 2\,x$

Monat i	1	2	3	4	5
x_i	1	2	3	4	5
y_i	21	26	24	30	29
$\hat{u}_i$	-1	2	-2	2	-1

Bekannt: $\bar{y} = 26$, $\sum(x_i - \bar{x})(y_i - \bar{y}) = 20$, $\sum(x_i - \bar{x})^2 = 10$.

Aufgaben

a) SQT und SQR berechnen.

b) R^2 berechnen und mit r_{xy}^2 kontrollieren.

c) R^2 interpretieren und beurteilen.

d) Für ein anderes Modell wird $R^2 = 0{,}6897$ ausgegeben. Was bedeutet das, und wie ist der Wert zu beurteilen?

Lösung: Bestimmtheitsmaß für den Online-Shop

a) Quadratsummen

$y_i - \bar{y}$: $-5,\ 0,\ -2,\ 4,\ 3$

$\text{SQT} = 25 + 0 + 4 + 16 + 9 = 54$

$\text{SQR} = 1 + 4 + 4 + 4 + 1 = 14$

Kontrolle: $\text{SQE} = 2^2 \cdot 10 = 40 = 54 - 14$ ✓

b) Bestimmtheitsmaß

$R^2 = 1 - \frac{14}{54} = \frac{40}{54} = 0{,}741$

$r_{xy} = \frac{20}{\sqrt{10 \cdot 54}} = 0{,}8607, \quad r_{xy}^2 = 0{,}741$ ✓

c) Interpretation

74 % der Streuung der Monatsumsätze werden durch den Werbeaufwand (linear) erklärt, 26 % nicht. Nach der Faustregel eine **mäßige** Anpassung.

d) $R^2 = 0{,}6897$

Das Modell erklärt rund 69 % der Streuung der Endogenen; 31 % bleiben unerklärt. Beurteilung: **mäßig** ($0{,}6 \leq R^2 < 0{,}8$).

Übungsaufgabe: Von den Quadratsummen zum Korrelationskoeffizienten

Daten: Heizkosten eines Ladenlokals in fünf Wochen

Woche i	1	2	3	4	5
Mittlere Außentemperatur x_i (°C)	0	3	6	9	12
Heizkosten y_i (Euro je Tag)	82	65	63	41	49

Aus R bekannt: KQ-Gerade $\hat{y} = 78 - 3\,x$, $\quad$ SQT $= 1000$, $\quad$ SQR $= 190$.

Aufgaben

a) SQE und R^2 berechnen; R^2 interpretieren.

b) r_{xy} aus R^2 bestimmen – Vorzeichen begründen.

c) Anpassung nach der Faustregel beurteilen.

d) Kontrolle: SQE über $\hat{\beta}_1^2 \sum (x_i - \bar{x})^2$ nachrechnen.

Lösung (1/2): Quadratsummen, R^2 und Korrelationskoeffizient

a) Regel: SQT = SQE + SQR

$\text{SQE} = \text{SQT} - \text{SQR} = 1000 - 190 = 810$

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = \frac{810}{1000} = 1 - \frac{190}{1000} = 0{,}81$$

81 % der Streuung der Heizkosten werden durch die Außentemperatur (linear) erklärt, 19 % bleiben unerklärt.

b) Regel: $R^2 = r_{xy}^2$, Vorzeichen von $\hat{\beta}_1$

$|r_{xy}| = \sqrt{R^2} = \sqrt{0{,}81} = 0{,}9$

r_{xy} und $\hat{\beta}_1$ haben stets dasselbe Vorzeichen; $\hat{\beta}_1 = -3 < 0$, also

$$r_{xy} = -0{,}9$$

c) Beurteilung

$R^2 = 0{,}81 \geq 0{,}8$: **gute Anpassung**. Bei nur $n = 5$ Wochen ist das Urteil allerdings unsicher.

Typischer Fehler

Aus R^2 allein folgt nur $|r_{xy}|$. Das Vorzeichen steckt in $\hat{\beta}_1$ (oder s_{xy}): Je wärmer, desto *niedriger* die Heizkosten – ein starker negativer Zusammenhang.

Lösung (2/2): Kontrolle von Hand und mit R

d) Regel: SQE $= \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$

$\bar{x} = \frac{0+3+6+9+12}{5} = 6$; $\quad x_i - \bar{x}$: $-6,\ -3,\ 0,\ 3,\ 6$; $\quad \sum (x_i - \bar{x})^2 = 36 + 9 + 0 + 9 + 36 = 90$

SQE $= (-3)^2 \cdot 90 = 810$ ✓ $\quad$ Ebenso SQT: $\bar{y} = 60$, $\ 22^2 + 5^2 + 3^2 + (-19)^2 + (-11)^2 = 1000$ ✓

Mit R

```
reg ← lm(kosten ∼ temp)
summary(reg)                # Zeile "Multiple R-squared:  0.81"
summary(reg)$r.squared      # 0.81
cor(temp, kosten)           # -0.9
sum(resid(reg)^2)           # 190  (SQR)
```

Kernaussage

Drei Zahlen genügen: Aus SQT und SQR folgen SQE und R^2; mit dem Vorzeichen von $\hat{\beta}_1$ auch r_{xy}.

Rückblick Bestimmtheitsmaß

Können Sie diese Fragen beantworten?

1. In welche zwei Teile zerfällt $y_i - \bar{y}$?
2. Warum gilt $\text{SQT} = \text{SQE} + \text{SQR}$ nur bei KQ?
3. Was misst R^2, warum gilt $0 \leq R^2 \leq 1$?
4. Warum ist $R^2 = r_{xy}^2$ in der Einfachregression?
5. Warum reicht ein hohes R^2 nicht als Gütesiegel?

Formeln

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = 1 - \frac{\text{SQR}}{\text{SQT}} = r_{xy}^2$$

Kernaussage

R^2 ist der Anteil der Streuung von y, den die Gerade erklärt – zusammen mit dem Residuenplot das Urteil über die Gerade.

Rechenabkürzung: Drei Summen genügen

Leitfrage

Für eine Regression von Hand brauchen wir s_{xy}, s_x, s_y, r_{xy}, $\hat{\beta}_1$, $\hat{\beta}_0$ und R^2. Geht das mit weniger Rechenaufwand und weniger Rundungsfehlern?

Die drei Grundsummen (aus der Arbeitstabelle)

$\mathrm{SQ}_x = \sum(x_i - \bar{x})^2$	Abweichungsquadratsumme von x	Nenner der Varianz s_x^2
$\mathrm{SQ}_y = \sum(y_i - \bar{y})^2$	Abweichungsquadratsumme von y	$=$ SQT
$\mathrm{SP}_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})$	Abweichungsproduktsumme	Zähler der Kovarianz s_{xy}

Kernaussage

Alle Kennzahlen der Einfachregression lassen sich aus SQ_x, SQ_y und SP_{xy} berechnen – die Faktoren $\frac{1}{n-1}$ kürzen sich heraus.

Warum sich der Faktor $\frac{1}{n-1}$ herauskürzt

Steigung (bekannt)

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = \frac{\frac{1}{n-1}\,\mathrm{SP}_{xy}}{\frac{1}{n-1}\,\mathrm{SQ}_x} = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$$

Korrelationskoeffizient

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{\frac{1}{n-1}\,\mathrm{SP}_{xy}}{\sqrt{\frac{1}{n-1}\mathrm{SQ}_x} \cdot \sqrt{\frac{1}{n-1}\mathrm{SQ}_y}}$$

Wurzeln zusammenziehen

$$\sqrt{\tfrac{1}{n-1}\mathrm{SQ}_x} \cdot \sqrt{\tfrac{1}{n-1}\mathrm{SQ}_y} = \sqrt{\tfrac{1}{(n-1)^2}\,\mathrm{SQ}_x\,\mathrm{SQ}_y} = \tfrac{1}{n-1}\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y} \quad \Longrightarrow \quad r_{xy} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y}}$$

In Worten: Zähler und Nenner enthalten denselben Faktor; er kürzt sich – ganz gleich, ob mit $\frac{1}{n-1}$ oder $\frac{1}{n}$ gerechnet wird.

Alle Kennzahlen aus drei Summen

Größe	**über Kennzahlen**	**über Summen**
Steigung	$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$	$\hat{\beta}_1 = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$
Achsenabschnitt	$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$	(gleich)
Korrelation	$r_{xy} = \frac{s_{xy}}{s_x\, s_y}$	$r_{xy} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\, \mathrm{SQ}_y}}$
Bestimmtheitsmaß	$R^2 = r_{xy}^2$	$R^2 = \frac{\mathrm{SP}_{xy}^2}{\mathrm{SQ}_x\, \mathrm{SQ}_y}$
Erklärte Quadratsumme	$\mathrm{SQE} = \hat{\beta}_1^2\, \mathrm{SQ}_x$	$\mathrm{SQE} = \hat{\beta}_1\, \mathrm{SP}_{xy}$
Residuenquadratsumme	$\mathrm{SQR} = \mathrm{SQT} - \mathrm{SQE}$	$\mathrm{SQR} = \mathrm{SQ}_y - \hat{\beta}_1\, \mathrm{SP}_{xy}$

$\mathrm{SQE} = \hat{\beta}_1^2 \mathrm{SQ}_x = \hat{\beta}_1 \cdot \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x} \cdot \mathrm{SQ}_x = \hat{\beta}_1 \mathrm{SP}_{xy}$. Die Formeln mit $R^2 = r_{xy}^2$ gelten nur in der Einfachregression.

Beispiel: Die zwölf Filialen aus drei Summen

Grundsummen

$$\mathrm{SP}_{xy} = 186$$
$$\mathrm{SQ}_x = 155$$
$$\mathrm{SQ}_y = 288$$
$$\bar{x} = 7{,}5, \quad \bar{y} = 39$$

Alles Weitere in wenigen Zeilen

$$\hat{\beta}_1 = 186/155 = 1{,}2$$
$$\hat{\beta}_0 = 39 - 1{,}2 \cdot 7{,}5 = 30$$
$$r_{xy} = 186/\sqrt{155 \cdot 288} = 0{,}8803$$
$$R^2 = 186^2/(155 \cdot 288) = 34\,596/44\,640 = 0{,}775$$
$$\mathrm{SQE} = 1{,}2 \cdot 186 = 223{,}2$$
$$\mathrm{SQR} = 288 - 223{,}2 = 64{,}8$$

Kernaussage

Dieselben Werte wie zuvor – ohne $\frac{1}{n-1}$-Faktoren und ohne Wurzeln aus gerundeten Varianzen.

Summen ohne Abweichungstabelle: der Verschiebungssatz

Verschiebungssatz (bekannt aus der Herleitung der Steigung)

$$\mathrm{SP}_{xy} = \sum x_i y_i - n\,\bar{x}\,\bar{y} \qquad \mathrm{SQ}_x = \sum x_i^2 - n\,\bar{x}^2 \qquad \mathrm{SQ}_y = \sum y_i^2 - n\,\bar{y}^2$$

In Worten: Statt jede Abweichung einzeln zu bilden, summiert man die Rohwerte (Produkte, Quadrate) und zieht einmal den Mittelwertteil ab.

Probe am Online-Shop ($n = 5$, $\bar{x} = 3$, $\bar{y} = 26$)

$\sum x_i y_i = 21 + 52 + 72 + 120 + 145 = 410$
$\mathrm{SP}_{xy} = 410 - 5 \cdot 3 \cdot 26 = 20$ ✓
$\mathrm{SQ}_x = 55 - 5 \cdot 3^2 = 10$ ✓
$\mathrm{SQ}_y = 3434 - 5 \cdot 26^2 = 54$ ✓

Vorsicht: Rundung

Die Differenz zweier großer Zahlen reagiert empfindlich auf gerundete Mittelwerte.
Daher $n\,\bar{x}\,\bar{y} = \frac{\sum x_i \sum y_i}{n}$ rechnen oder mit ungerundeten Mittelwerten arbeiten.

Korrelation als standardisierte Steigung

Umformung

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{s_{xy}}{s_x^2} \cdot \frac{s_x}{s_y} = \hat{\beta}_1 \cdot \frac{s_x}{s_y}$$

Zwölf Filialen

$$\frac{s_x}{s_y} = \sqrt{\frac{\mathrm{SQ}_x}{\mathrm{SQ}_y}} = \sqrt{\frac{155}{288}} = 0{,}7336$$

$$r_{xy} = 1{,}2 \cdot 0{,}7336 = 0{,}8803 \checkmark$$

In Worten

Misst man x und y jeweils in Standardabweichungen, wird aus der Steigung $\hat{\beta}_1$ der Korrelationskoeffizient: der **standardisierte Regressionskoeffizient**.

Folgerungen

- r_{xy} und $\hat{\beta}_1$ haben stets dasselbe Vorzeichen.
- $\hat{\beta}_1$ hängt von den Einheiten ab, r_{xy} nicht.
- Quadrieren: $R^2 = \hat{\beta}_1^2 \frac{s_x^2}{s_y^2} = r_{xy}^2$.

Übung: Körpergröße und Schuhgröße

Daten: $n = 15$ Personen

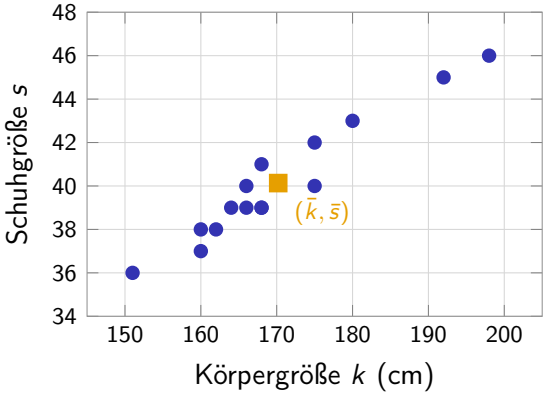
Person i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Körpergröße k_i (cm)	164	162	168	198	166	166	192	160	151	175	180	160	168	175	168
Schuhgröße s_i	39	38	39	46	40	39	45	37	36	42	43	38	41	40	39

Hilfssummen: $\sum k_i = 2553$, $\sum s_i = 602$, $\sum k_i s_i = 102\,932$, $\sum k_i^2 = 436\,643$, $\sum s_i^2 = 24\,272$

Aufgaben (Modell: $s_i = \beta_0 + \beta_1 k_i + u_i$)

1. Streuungsdiagramm zeichnen und beschreiben.
2. Kovarianz und Korrelationskoeffizient berechnen.
3. KQ-Gerade schätzen, einzeichnen, deuten.
4. Residuenplot zeichnen und beurteilen.
5. Bestimmtheitsmaß berechnen und beurteilen.
6. QQ-Plot der Residuen: siehe **Anhang**.

Lösung (1/5): Streuungsdiagramm und Mittelwerte



Mittelwerte

$\bar{k} = \frac{2553}{15} = 170{,}2$ cm

$\bar{s} = \frac{602}{15} = 40{,}1\overline{3}$

1. Beschreibung

Größere Personen haben tendenziell größere Füße: ein deutlich **positiver**, nahezu **linearer** Zusammenhang. Die Punkte streuen nur wenig.

Gleiche Körpergrößen (z. B. dreimal 168 cm) liegen senkrecht übereinander.

Lösung (2/5): Kovarianz und Korrelationskoeffizient

Grundsummen mit dem Verschiebungssatz (ohne gerundete Mittelwerte)

$$\mathrm{SP}_{ks} = \sum k_i s_i - \frac{\sum k_i \sum s_i}{n} = 102\,932 - \frac{2553 \cdot 602}{15} = 102\,932 - 102\,460{,}4 = 471{,}6$$

$$\mathrm{SQ}_k = \sum k_i^2 - \frac{(\sum k_i)^2}{n} = 436\,643 - 434\,520{,}6 = 2122{,}4$$

$$\mathrm{SQ}_s = \sum s_i^2 - \frac{(\sum s_i)^2}{n} = 24\,272 - 24\,160{,}27 = 111{,}73$$

Kovarianz

$s_{ks} = \frac{471{,}6}{14} = 33{,}69$ (cm · Schuhgröße)

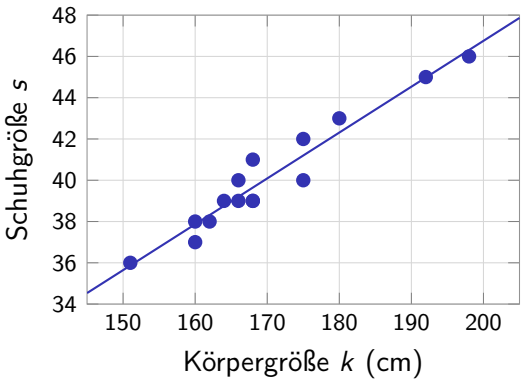
zum Vergleich: $s_k^2 = \frac{2122{,}4}{14} = 151{,}6$,
$s_s^2 = \frac{111{,}73}{14} = 7{,}981$

Korrelationskoeffizient

$r_{ks} = \frac{471{,}6}{\sqrt{2122{,}4 \cdot 111{,}73}} = 0{,}9684$

Sehr starker positiver linearer Zusammenhang ($|r| > 0{,}8$).

Lösung (3/5): KQ-Gerade schätzen und interpretieren



Schätzer

$\hat{\beta}_1 = \frac{471{,}6}{2122{,}4} = 0{,}2222$

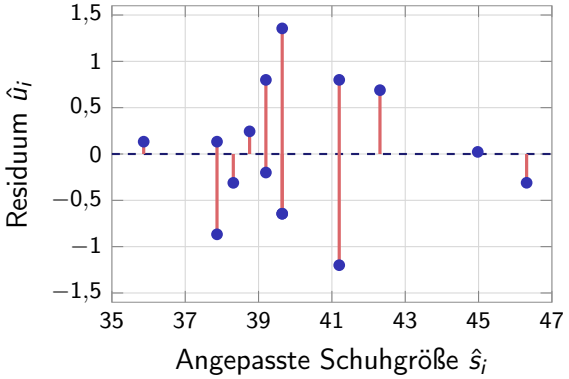
$\hat{\beta}_0 = 40{,}1\overline{3} - 0{,}2222 \cdot 170{,}2 = 2{,}3147$

(mit ungerundetem $\hat{\beta}_1$ gerechnet)

Interpretation

- Je cm Körpergröße ist eine um 0,22 größere Schuhgröße zu erwarten – eine Schuhgröße entspricht rund 4,5 cm.
- $\hat{\beta}_0$: Schuhgröße bei 0 cm Körpergröße – weit außerhalb der Daten, **nicht interpretierbar**.

Lösung (4/5): Residuenplot



Residuen $\hat{u}_i = s_i - \hat{s}_i$

Zwischen $-1{,}20$ (Person 14) und $1{,}36$ (Person 13) – also höchstens etwa eine Schuhgröße.
Beispiel Person 13: $\hat{s}_{13} = 39{,}64$,
$\hat{u}_{13} = 41 - 39{,}64 = 1{,}36$.

Beurteilung

- kein Bogen, kein Trichter
- kein auffälliger Einzelwert

Keine Systematik erkennbar: Die Gerade ist angemessen.

Gleiche Körpergröße $\Rightarrow$ gleiches $\hat{s}_i$: Diese Punkte liegen senkrecht übereinander.

Lösung (5/5): Bestimmtheitsmaß

Über die Quadratsummen

$\text{SQE} = \hat{\beta}_1 \cdot \text{SP}_{ks} = 0{,}2222 \cdot 471{,}6 = 104{,}79$

$\text{SQR} = 111{,}73 - 104{,}79 = 6{,}94$

$R^2 = \frac{104{,}79}{111{,}73} = 0{,}9379$

Kontrolle über die Korrelation

$R^2 = r_{ks}^2 = 0{,}9684^2 \approx 0{,}938$ ✓

Interpretation und Beurteilung

Rund 93,8 % der Streuung der Schuhgrößen werden durch die Körpergröße (linear) erklärt. $R^2 \geq 0{,}8$: **gute Anpassung**.

Kernaussage

Gutes R^2 *und* strukturloser Residuenplot: Die Gerade beschreibt den Zusammenhang hier angemessen.

Zusammenfassung 1: Grafische Darstellungen

Methode	**Beschreibung**	**Charakteristika**
Emp. Verteilungsfkt.	Treppenfunktion der kum. Häufigkeiten	Sehr detailliert, aufwendig
Histogramm	Säulendiagramm mit Dichte	Grober Überblick, klassenabhängig
Boxplot	Quartile, Whisker, Ausreißer	Guter Überblick

Wichtige Formeln

Dichte (Histogramm): $\text{Dichte} = \frac{\text{relative Häufigkeit}}{\text{Klassenbreite}}$

Whisker-Min: $\min\{x_i \mid x_i \geq Q_1 - 1{,}5 \cdot \text{IQR}\}$

Whisker-Max: $\max\{x_i \mid x_i \leq Q_3 + 1{,}5 \cdot \text{IQR}\}$

Zusammenfassung 2: Regression

Regressionsmodell

$$y_i = \beta_0 + \beta_1 x_i + u_i \qquad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Größe	**Formel**
Kovarianz	$s_{xy} = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$
Korrelationskoeffizient	$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y} \qquad -1 \leq r_{xy} \leq 1$
Steigung	$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$
Achsenabschnitt	$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$
Bestimmtheitsmaß	$R^2 = \frac{\text{SQE}}{\text{SQT}} = 1 - \frac{\text{SQR}}{\text{SQT}} = r_{xy}^2$

Zusammenfassung 3: Modelldiagnostik

Residuen

$$\hat{u}_i = y_i - \hat{y}_i \qquad \sum \hat{u}_i = 0$$

Residuenplot $(\hat{y}_i,\ \hat{u}_i)$: Keine Systematik $\rightarrow$ Gerade ist angemessen

- Bogen: falsche Funktionsform Trichter: Heteroskedastizität Wellen: Autokorrelation
- Auffällige Einzelwerte prüfen, nicht automatisch löschen

Bestimmtheitsmaß $R^2 = \text{SQE/SQT}$: Anteil der erklärten Streuung

$$R^2 < 0{,}6\text{: schwach} \quad 0{,}6 \leq R^2 < 0{,}8\text{: mäßig} \quad R^2 \geq 0{,}8\text{: gut}$$

Ein hohes R^2 ersetzt den Residuenplot nicht.

QQ-Plot (Anhang): Prüfung der Normalverteilung der Residuen

- Ideal: Punkte nahe der Referenzgeraden durch die Quartile
- S-Form oder Bogen deuten auf Nicht-Normalverteilung hin

Zusammenfassung: Wichtige R-Befehle (1/2)

Grafische Darstellungen

```
plot(ecdf(daten))                    # Empirische VF
hist(daten, freq = FALSE)            # Histogramm (Dichte)
hist(daten, breaks = c(37,39,41))    # Eigene Klassen
boxplot(daten)                       # Boxplot
```

Kovarianz und Korrelation

```
cov(x, y)                            # Kovarianz
cor(x, y)                            # Korrelationskoeffizient
```

Zusammenfassung: Wichtige R-Befehle (2/2)

Regression

```
reg ← lm(y ~ x)                    # Lineares Modell
summary(reg)                       # Ergebnisse inkl. R^2
```

Modelldiagnostik

```
plot(fitted(reg), resid(reg))      # Residuenplot
abline(h = 0, col = "red")         # Nulllinie
qqnorm(resid(reg))                 # QQ-Plot
qqline(resid(reg))                 # Referenzlinie
```

Überblick

2 Anhang
- QQ-Plot

Anhang: Ist der Störterm normalverteilt? Der QQ-Plot

Ausgangslage

Die vierte Standardannahme lautet $u_i \sim \mathcal{N}(0, \sigma^2)$. Gebraucht wird sie erst für **Konfidenzintervalle und Tests** (Teil 6) – für Berechnung und Interpretation der KQ-Geraden spielt sie keine Rolle.

Leitfrage

Wie prüft man, ob Daten – hier die Residuen $\hat{u}_i$ – aus einer Normalverteilung stammen könnten?

Histogramm?

Bei $n = 9$ oder $n = 15$ Werten hängt das Bild stark von den Klassen ab: kaum beurteilbar.

Besser: Quantile vergleichen

Der **QQ-Plot** vergleicht die sortierten Werte mit den bei Normalverteilung erwarteten.

Die Idee: Quantile gegeneinander abtragen

Konstruktion

1. Von beiden Verteilungen gleich viele Quantile bestimmen (bei Stichproben: die **sortierten Werte**).
2. Das i-te Quantil der einen gegen das i-te Quantil der anderen Verteilung als Punkt eintragen.

Lesart

Punkte auf einer **Geraden**: Beide Verteilungen haben dieselbe *Form*. Unterschiedliche Lage und Streuung verschieben und kippen nur die Gerade.

Referenzgerade

Gerade durch die Punkte der beiden **25 %-Quantile** und der beiden **75 %-Quantile**: robust, Ausreißer verschieben sie kaum.

Kernaussage

Je weiter die Punkte systematisch von der Geraden abweichen, desto unähnlicher sind die Verteilungsformen.

Einstiegsbeispiel: Preise und Absatzmengen der Leuchte

Daten aus dem Regressionsbeispiel

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120
Absatz y_i (Stück)	20	17	15	9	11	8	4	4	2

Schritt 1: Jedes Merkmal *für sich* aufsteigend sortieren

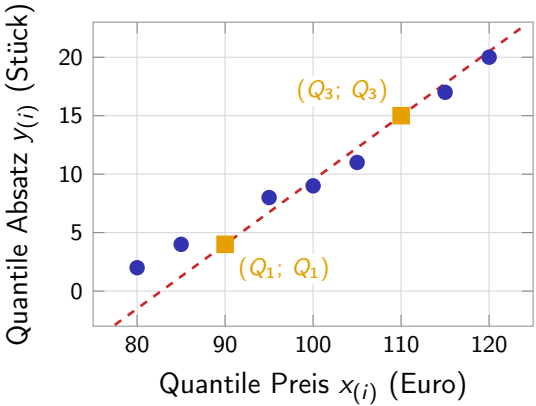
$x_{(i)}$	80	85	90	95	100	105	110	115	120
$y_{(i)}$	2	4	4	8	9	11	15	17	20

Schritt 2: die Paare $\left(x_{(i)}, y_{(i)}\right)$ eintragen.

Achtung: Die Paare werden aufgelöst

(80; 2) ist keine Beobachtung! Im Streuungsdiagramm verboten, im QQ-Plot gewollt: Verglichen werden nur die *Verteilungen*, nicht der Zusammenhang.

QQ-Plot: Preise gegen Absatzmengen



Referenzgerade

Quartile: Preis 90 und 110 Euro, Absatz 4 und 15 Stück. Gerade durch (90; 4) und (110; 15):

$$y = -45{,}5 + 0{,}55\,x$$

Lesart

Die Punkte liegen nahe der Geraden: Preise und Absatzmengen sind **ähnlich verteilt** – beide streuen recht gleichmäßig über ihren Bereich. Lage und Streuung unterscheiden sich (Euro gegen Stück), das verändert nur die Lage der Geraden.

QQ-Plot zweier Stichproben mit R

QQ-Plot zeichnen

```
qqplot(preis, menge)
```

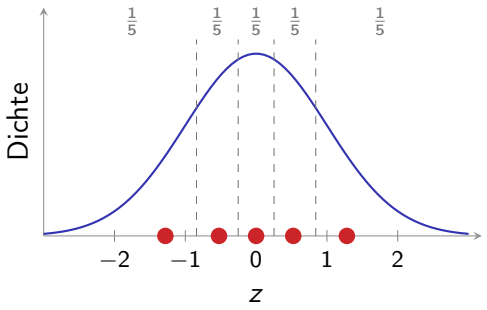
Referenzgerade durch die Quartile

```
qqline(menge,
       distribution = function(p) quantile(preis, prob = p),
       lty = 2)
```

Was die Befehle tun

`qqplot()` sortiert beide Stichproben und zeichnet die Paare $\left(x_{(i)}, y_{(i)}\right)$; `qqline()` legt die Gerade durch die Paare der 25 %- und 75 %-Quantile.

Residuen gegen die Normalverteilung: theoretische Quantile



$n = 5$: fünf Streifen mit je Wahrscheinlichkeit $\frac{1}{5}$; rot: z_i in der Mitte jedes Streifens

Vorgehen

1. Residuen sortieren: $\hat{u}_{(1)} \leq \ldots \leq \hat{u}_{(n)}$.
2. Jedem Rang i den Anteil $p_i = \frac{i-0{,}5}{n}$ zuordnen.
3. Theoretisches Quantil der Standardnormalverteilung: $z_i = \Phi^{-1}(p_i)$, d. h. $P(Z \leq z_i) = p_i$.
4. Punkte $\left(z_i,\ \hat{u}_{(i)}\right)$ zeichnen.

In Worten

z_i ist der Wert, an dem der i-kleinste von n Werten bei einer Normalverteilung „zu erwarten“ wäre.
Beispiel $n = 5$: $z_i = -1{,}28;\ -0{,}52;\ 0;\ 0{,}52;\ 1{,}28$.

Beispiel Leuchte: Quantile berechnen

Rang i	$\hat{u}_{(i)}$	Preis	$p_i = \frac{i-0{,}5}{9}$	$z_i = \Phi^{-1}(p_i)$
1	−3,2333	95	0,0556	−1,5932
2	−1,5333	110	0,1667	−0,9674
3	0,2333	105	0,2778	−0,5895
4	0,3000	85	0,3889	−0,2822
5	0,5333	90	0,5000	0,0000
6	0,7000	115	0,6111	0,2822
7	0,9333	120	0,7222	0,5895
8	1,0000	100	0,8333	0,9674
9	1,0667	80	0,9444	1,5932

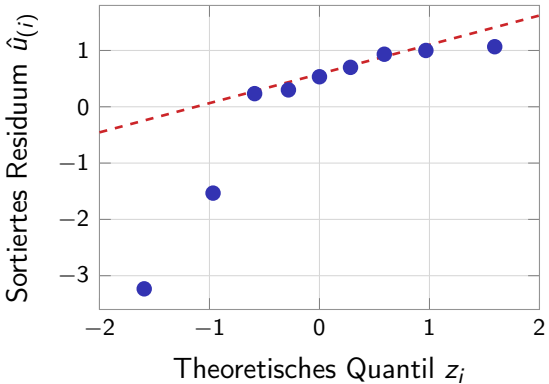
Residuen

aus $\hat{y} = 54{,}67 - 0{,}4467\,x$, z. B. Preis 95: $\hat{u} = 9 - 12{,}23 = -3{,}23$.

Symmetrie

z_i ist symmetrisch um 0: $z_9 = -z_1$, $z_8 = -z_2$, ... Die Werte stammen aus der Tabelle der Standardnormalverteilung oder aus R: `qnorm(p)`.

Beispiel Leuchte: QQ-Plot der Residuen

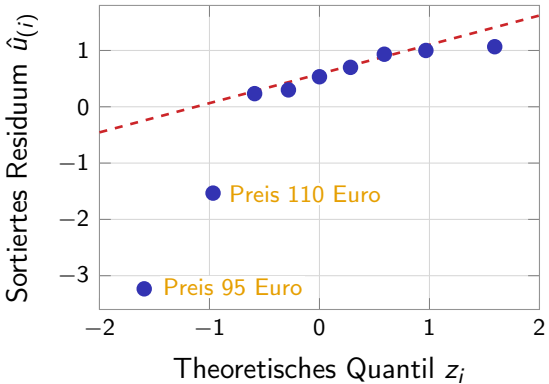


Referenzgerade durch die Quartile: $0{,}5833 + 0{,}5189\,z$

Beobachtung

- **In der Mitte** liegen die Punkte nahe der Geraden.

Beispiel Leuchte: QQ-Plot der Residuen

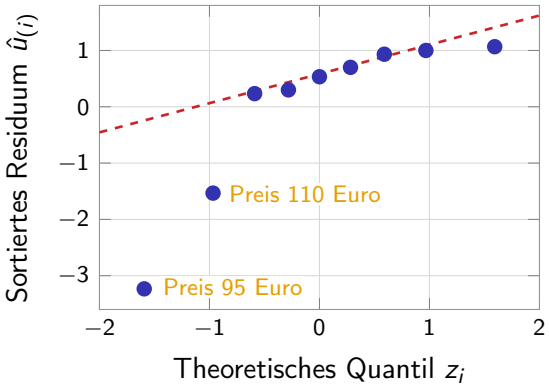


Referenzgerade durch die Quartile: $0{,}5833 + 0{,}5189\,z$

Beobachtung

- **In der Mitte** liegen die Punkte nahe der Geraden.
- **Am unteren Rand** liegen die beiden kleinsten Residuen (95 und 110 Euro) deutlich darunter: Der untere Rand ist länger, als die Normalverteilung erwarten lässt.

Beispiel Leuchte: QQ-Plot der Residuen



Referenzgerade durch die Quartile: $0{,}5833 + 0{,}5189\,z$

Beobachtung

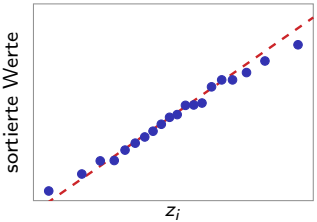
- **In der Mitte** liegen die Punkte nahe der Geraden.
- **Am unteren Rand** liegen die beiden kleinsten Residuen (95 und 110 Euro) deutlich darunter: Der untere Rand ist länger, als die Normalverteilung erwarten lässt.

Fazit

Hinweis auf eine Abweichung von der Normalverteilung (langer unterer Rand, linksschief). Aber: $n = 9$ sind sehr wenige Daten – **das Urteil ist unsicher**.

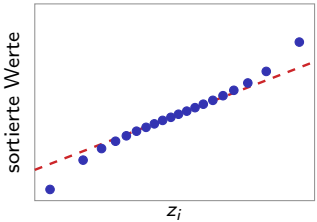
Typische Abweichungen im QQ-Plot

(a) Normalverteilt



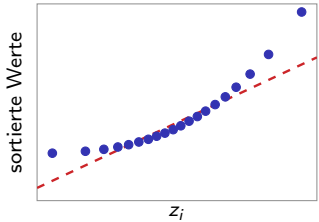
Punkte nahe der Geraden, kleine zufällige Abweichungen

(b) Schwere Ränder



S-Form: Ränder links unter, rechts über der Geraden – mehr extreme Werte (Ausreißer)

(c) Rechtsschief



Bogen: beide Enden über der Geraden – langer oberer Rand

Kernaussage

Kleine Abweichungen, besonders an den Rändern, sind bei kleinem n normal. Ernst zu nehmen sind *systematische* Formen wie S oder Bogen.

QQ-Plot der Residuen gegen die Normalverteilung in R

QQ-Plot erzeugen

```
reg ← lm(menge ∼ preis)
qqnorm(resid(reg))
```

Referenzgerade durch die Quartile

```
qqline(resid(reg))
```

Was die Befehle tun

`qqnorm()` sortiert die Residuen, berechnet die Normalquantile z_i und zeichnet die Paare $\left(z_i,\ \hat{u}_{(i)}\right)$. `qqline()` legt die Gerade durch das 25 %- und das 75 %-Quantil.

Für $n \leq 10$ verwendet R leicht andere Anteile, $p_i = \frac{i-3/8}{n+1/4}$; das Bild ändert sich dadurch kaum.

Übung (Aufgabe 6): QQ-Plot für Körper- und Schuhgrößen

Ausgangspunkt

Die Residuen $\hat{u}_i = s_i - \hat{s}_i$ der Regression $\hat{s} = 2{,}3147 + 0{,}2222\, k$ aus der Übung ($n = 15$).

Aufgabe

a) Residuen sortieren und $p_i = \frac{i-0{,}5}{15}$ sowie $z_i = \Phi^{-1}(p_i)$ bestimmen.

b) Den QQ-Plot zeichnen; die Referenzgerade verläuft durch die Punkte der Quartile.

c) Beurteilen: Spricht etwas gegen die Normalverteilungsannahme?

In R: `qqnorm(resid(reg)); qqline(resid(reg))` mit `reg <- lm(s ~ k)`.

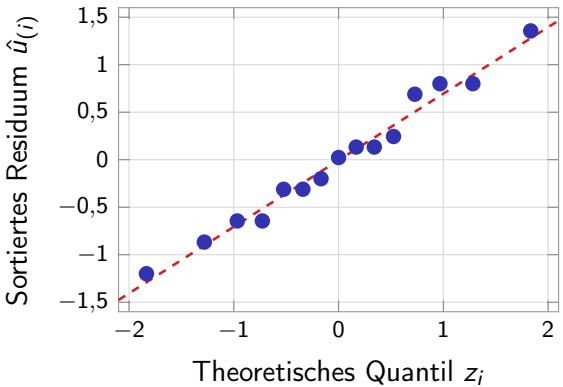
Lösung Aufgabe 6 (1/2): Sortierte Residuen und Normalquantile

i	$\hat{u}_{(i)}$	p_i	z_i
1	−1,1999	0,0333	−1,8339
2	−0,8669	0,1000	−1,2816
3	−0,6445	0,1667	−0,9674
4	−0,6445	0,2333	−0,7279
5	−0,3113	0,3000	−0,5244
6	−0,3105	0,3667	−0,3407
7	−0,2001	0,4333	−0,1679
8	0,0227	0,5000	0,0000

i	$\hat{u}_{(i)}$	p_i	z_i
9	0,1329	0,5667	0,1679
10	0,1331	0,6333	0,3407
11	0,2443	0,7000	0,5244
12	0,6891	0,7667	0,7279
13	0,7999	0,8333	0,9674
14	0,8001	0,9000	1,2816
15	1,3555	0,9667	1,8339

Kleinstes Residuum: Person 14 (175 cm, Schuhgröße 40); größtes: Person 13 (168 cm, Schuhgröße 41).

Lösung Aufgabe 6 (2/2): QQ-Plot und Beurteilung



Referenzgerade durch die Quartile: $-0{,}0056 + 0{,}7002\,z$

Beobachtung

Alle 15 Punkte liegen nahe der Geraden; weder S-Form noch Bogen. Kleine Stufen entstehen, weil Schuhgrößen ganze Zahlen sind.

Fazit

Kein Hinweis gegen die Normalverteilung der Störterme. Ein Beweis ist das nicht – mit $n = 15$ lassen sich nur deutliche Abweichungen erkennen.