Statistik für Ökonomen

Teil 3: Regression

Prof. Dr. Christoph Weisser

HSBI

Themen der Veranstaltung (1/2)

Teil	**Inhalt**
0 – Vorkurs	Mathematische Grundlagen, Notation und Formeln, Summenzeichen, Mengenlehre
1 – Deskriptive Statistik	Grundbegriffe, Skalenniveaus, Häufigkeiten, Lage- und Streuungsmaße
2 – Grafische Darstellungen	Säulen-, Balken-, Kreisdiagramm, Histogramm, Boxplot, Verteilungsfunktion
3 – Regression	Streuungsdiagramm, Korrelation, lineare Regression

Themen der Veranstaltung (2/2)

Teil	**Inhalt**
4 – Wahrscheinlichkeitsrechnung	Grundlagen, Kombinatorik, Wahrscheinlichkeitsbegriffe, Kolmogorovsche Axiome, Bedingte Wahrscheinlichkeiten, Satz von Bayes, Kategoriale Daten (Kontingenztabellen)
5 – Wahrscheinlichkeitsverteilungen	Diskrete und stetige Verteilungen, Normalverteilung, Schätzen, Grenzwertsätze
6 – Induktive Statistik	Konfidenzintervalle, Hypothesentests

Symbolverzeichnis (1)

Symbol	Bedeutung	Symbol	Bedeutung
ω	Statistische Einheit	h_j	Absolute Häufigkeit
n	Anzahl der statistischen Einheiten	f_j	Relative Häufigkeit
X	Merkmal	H_j	Kumulierte absolute Häufigkeit
x	Merkmalsausprägung	$F(x)$	Empirische Verteilungsfunktion
x_i	Merkmalswert (beobachteter Wert)	a_j	Merkmalsausprägung (Klasse j)
$x_{(i)}$	i-ter Wert der geordneten Stichprobe	$\tilde{x}$	Median
$\bar{x}$	Arithmetisches Mittel	$\bar{x}_{\text{geo}}$	Geometrisches Mittel
$\bar{x}_{\text{harm}}$	Harmonisches Mittel		

Symbolverzeichnis (2)

Symbol	Bedeutung	Symbol	Bedeutung
s^2	Varianz (Stichprobe)	s_{xy}	Kovarianz von X und Y
s	Standardabweichung	r	Korrelationskoeffizient (Bravais-Pearson)
R	Spannweite	β_0, β_1	Regressionskoeffizienten (wahr)
IQR	Interquartilsabstand	$\hat{\beta}_0$, $\hat{\beta}_1$	Geschätzte Regressionskoeffizienten
$x_{0,25}$, $x_{0,75}$	25 %- und 75 %-Quantil	y_i	Beobachtete y-Werte
Q_1, Q_3	1. und 3. Quartil	$\hat{y}_i$	Angepasste Werte (auf der Geraden)
SQT	Quadratsumme total	u_i	Störterm (Fehler)
SQE	Quadratsumme erklärt	$\hat{u}_i$	Residuum
SQR	Quadratsumme der Residuen	R^2	Bestimmtheitsmaß

Überblick

1. Regression
   - Streuungsdiagramm
   - Korrelation
   - Beste Gerade
   - Kleinste Quadrate
   - Interpretation
   - Bestimmtheitsmaß

Zusammenhang zweier metrischer Merkmale

Fragestellung

Wie hängen zwei metrisch skalierte Merkmale zusammen?

- **Exogene Variable** X: von außen gegeben – *erklärende* Variable
- **Endogene Variable** Y: hängt von X ab – *zu erklärende* Variable

Regression – ein Beispiel

Szenario

Eine neue Leuchte wird in neun Geschäften zu unterschiedlichen Preisen angeboten.

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120
Menge y_i (Stück)	20	17	15	9	11	8	4	4	2

Zuordnung der Variablen

- **Preis**: fest vorgegeben – *exogenes* Merkmal X
- **Menge**: Ergebnis des Kaufverhaltens – *endogenes* Merkmal Y

Leitfrage

Um wie viel sinkt der Absatz, wenn der Preis um 10 Euro steigt?

Preis-Absatz- und Nachfragefunktion

Preis-Absatz-Funktion $Y = f(X)$

Welche Menge wird zu einem vorgegebenen Preis abgesetzt?

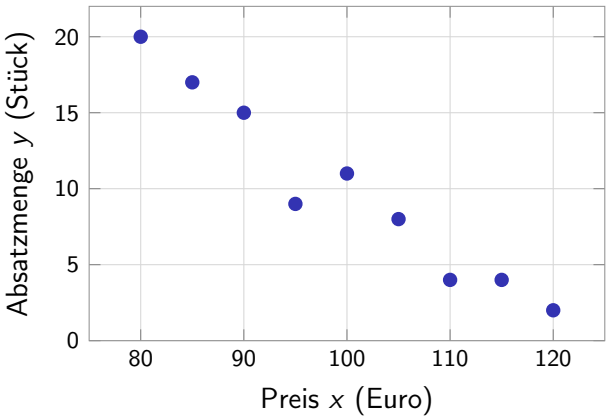
Nachfragefunktion $X = f^{-1}(Y)$

Zu welchem Preis lässt sich eine festgelegte Menge verkaufen?

Kernaussage

Die Fragestellung legt fest, welches Merkmal X und welches Y ist.

Streuungsdiagramm



Höherer Preis, geringerer Absatz.

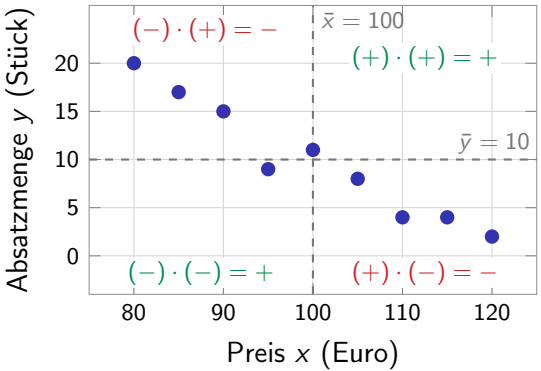
Idee

- Beobachtung (x_i, y_i) = **ein Punkt**
- x-Achse: exogen (Preis)
- y-Achse: endogen (Absatz)

Paare gehören zusammen

x_i und y_i nie getrennt sortieren.

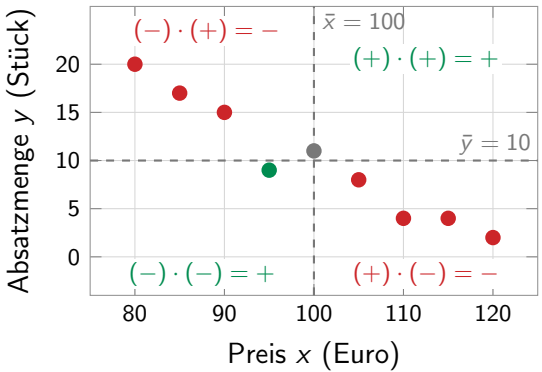
Kovarianz: Wie misst man die Richtung eines Zusammenhangs?



Idee

- $\bar{x} = 100$, $\bar{y} = 10$: vier Felder
- je Punkt: $(x_i - \bar{x})(y_i - \bar{y})$

Kovarianz: Wie misst man die Richtung eines Zusammenhangs?



Idee

- $\bar{x} = 100$, $\bar{y} = 10$: vier Felder
- je Punkt: $(x_i - \bar{x})(y_i - \bar{y})$

Kernaussage

Überwiegend negative Produkte: Die **Kovarianz** ist negativ.

Kovarianz: Definition und Interpretation

Empirische Kovarianz

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

In Worten: Abweichungsprodukte summieren und – wie bei der Varianz – durch $n-1$ teilen.

Abkürzungen für die beiden Summen

$\mathrm{SP}_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})$: **S**umme der Abweichungs**p**rodukte $\Rightarrow$ $s_{xy} = \mathrm{SP}_{xy}/(n-1)$

$\mathrm{SQ}_x = \sum(x_i - \bar{x})^2$: **S**umme der Abweichungs**q**uadrate $\Rightarrow$ $s_x^2 = \mathrm{SQ}_x/(n-1)$; SQ_y ebenso für y

Vorzeichen = Richtung

$s_{xy} > 0$ gleichläufig

$s_{xy} < 0$ gegenläufig

$s_{xy} = 0$ kein linearer Zusammenhang

Betrag nicht interpretierbar

Einheit Euro · Stück: hängt von den Maßeinheiten ab.

Ausweg: normieren $\rightarrow$ Korrelation

Beispiel Leuchte: Kovarianz berechnen

Arbeitstabelle ($n = 9$; $\bar{x} = 900/9 = 100$, $\bar{y} = 90/9 = 10$)

										$\sum$
Preis x_i (Euro)	80	85	90	95	100	105	110	115	120	
Menge y_i (Stück)	20	17	15	9	11	8	4	4	2	
$x_i - \bar{x}$	-20	-15	-10	-5	0	5	10	15	20	0
$y_i - \bar{y}$	10	7	5	-1	1	-2	-6	-6	-8	0
$(x_i - \bar{x})(y_i - \bar{y})$	-200	-105	-50	5	0	-10	-60	-90	-160	$\mathbf{-670}$
$(x_i - \bar{x})^2$	400	225	100	25	0	25	100	225	400	1500
$(y_i - \bar{y})^2$	100	49	25	1	1	4	36	36	64	316

Kovarianz

$$s_{xy} = \frac{\mathrm{SP}_{xy}}{n-1} = \frac{-670}{9-1} = \mathbf{-83{,}75} \quad \text{(Euro} \cdot \text{Stück)}$$

negativ: Preis und Absatz gegenläufig

Für später: die Varianzen

$$s_x^2 = \mathrm{SQ}_x/8 = 1500/8 = 187{,}5$$
$$s_y^2 = \mathrm{SQ}_y/8 = 316/8 = 39{,}5$$

Übung Online-Shop (1): Streuungsdiagramm und Kovarianz

Durchgehende Übung: Diese Daten begleiten das ganze Kapitel; die Übungen bauen aufeinander auf.

Daten: fünf Monate (jeweils in Tsd. Euro)

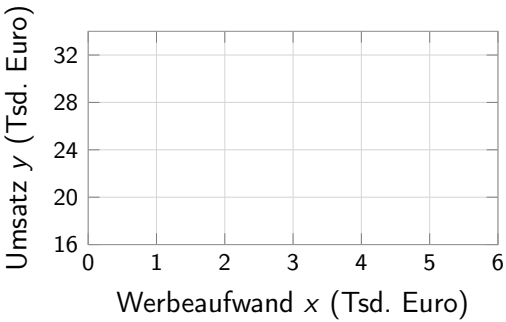
Monat i	1	2	3	4	5
Werbeaufwand x_i	1	2	3	4	5
Umsatz y_i	21	26	24	30	29

Aufgaben

a) Streuungsdiagramm zeichnen, Zusammenhang beschreiben.

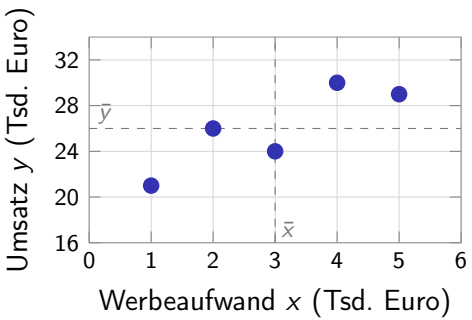
b) Mittelwerte $\bar{x}$ und $\bar{y}$ berechnen.

c) Kovarianz s_{xy} mit Arbeitstabelle berechnen.



Vorlage zum Einzeichnen

Lösung Online-Shop (1): Streuungsdiagramm und Kovarianz



a) Mehr Werbung, tendenziell mehr Umsatz: ein **positiver**, annähernd linearer Zusammenhang.

b) Mittelwerte

$\bar{x} = 15/5 = \mathbf{3}, \qquad \bar{y} = 130/5 = \mathbf{26}$

c) Regel: $s_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})/(n-1)$

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$
1	1	21	-2	-5	10
2	2	26	-1	0	0
3	3	24	0	-2	0
4	4	30	1	4	4
5	5	29	2	3	6
$\sum$	15	130	0	0	**20**

$s_{xy} = 20/(5-1) = \mathbf{5}$ (Tsd. Euro)^2: positiv, gleichläufig.

Korrelationskoeffizient

Idee

Eine **normierte Kovarianz**: Stärke und Richtung des *linearen* Zusammenhangs – unabhängig von den Maßeinheiten.

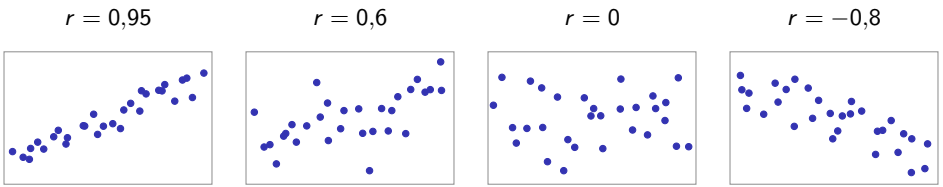
Berechnung (Bravais-Pearson)

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\, \mathrm{SQ}_y}} \qquad -1 \leq r_{xy} \leq +1$$

Lesart

Kovarianz der standardisierten Variablen $(X - \bar{x})/s_x$ und $(Y - \bar{y})/s_y$: Die Einheiten kürzen sich.

Korrelationskoeffizient – Stärke des Zusammenhangs



Faustregel

Bereich	Interpretation
$\lvert r_{xy}\rvert > 0{,}8$	starke Korrelation
$0{,}5 \leq \lvert r_{xy}\rvert \leq 0{,}8$	mittlere Korrelation
$\lvert r_{xy}\rvert < 0{,}5$	schwache Korrelation

Beispiel Leuchte

$$r_{xy} = \frac{-83{,}75}{\sqrt{187{,}5} \cdot \sqrt{39{,}5}} = \mathbf{-0{,}9732}$$

stark **negativ** $(\lvert r_{xy}\rvert > 0{,}8)$

Punkte liegen eng an einer fallenden Geraden.

Übung Online-Shop (2): Korrelationskoeffizient

Bekannt aus Übung (1)

$n = 5,\ \bar{x} = 3,\ \bar{y} = 26,\ s_{xy} = 5$

$\mathrm{SP}_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y}) = 20$

$x_i - \bar{x} = -2,\ -1,\ 0,\ 1,\ 2;\ \ y_i - \bar{y} = -5,\ 0,\ -2,\ 4,\ 3$

Aufgaben

a) SQ_x und SQ_y aus den Abweichungen berechnen.

b) s_x, s_y und r_{xy} berechnen; mit $\mathrm{SP}_{xy}/\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y}$ kontrollieren.

c) Stärke und Richtung des Zusammenhangs beurteilen.

Werkzeuge

Abweichungsquadrate: $\mathrm{SQ}_x = \sum(x_i - \bar{x})^2$

Standardabweichung: $s_x = \sqrt{\mathrm{SQ}_x/(n-1)}$

Korrelation: $r_{xy} = \dfrac{s_{xy}}{s_x\, s_y} = \dfrac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y}}$

Faustregel: $|r_{xy}| > 0{,}8$ stark, 0,5 bis 0,8 mittel

Lösung Online-Shop (2): Korrelationskoeffizient

a) Regel: $SQ_x = \sum(x_i - \bar{x})^2$

$SQ_x = (-2)^2 + (-1)^2 + 0^2 + 1^2 + 2^2 = \mathbf{10}$

$SQ_y = (-5)^2 + 0^2 + (-2)^2 + 4^2 + 3^2 = \mathbf{54}$

c) Beurteilung

$|r_{xy}| > 0{,}8$: ein **starker positiver** linearer Zusammenhang.

b) Regel: $r_{xy} = s_{xy}/(s_x\, s_y)$

$s_x = \sqrt{10/4} = 1{,}5811, \quad s_y = \sqrt{54/4} = 3{,}6742$

$$r_{xy} = \frac{5}{1{,}5811 \cdot 3{,}6742} = \mathbf{0{,}8607}$$

Kontrolle: $\dfrac{20}{\sqrt{10 \cdot 54}} = 0{,}8607$ ✓

Korrelationskoeffizient – Grenzen

Symmetrisch: $r_{xy} = r_{yx}$

Keine Aussage über Ursache und Wirkung.

Scheinkorrelation

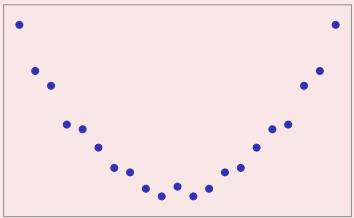
Drittvariable – z. B. Eisverkauf und Sonnenbrände.

Merke

Korrelation ist keine Kausalität.

Nur *lineare* Zusammenhänge

$r = 0$



u-förmig – und trotzdem $r_{xy} = 0$.

Kovarianz und Korrelation mit R

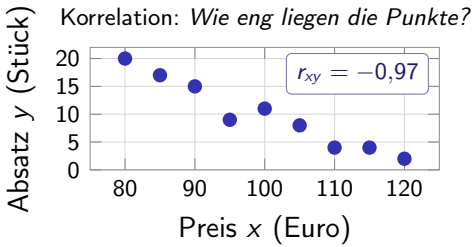
Beispiel Leuchte

```
preis ← c(80, 85, 90, 95, 100, 105, 110, 115, 120)
menge ← c(20, 17, 15,  9,  11,   8,   4,   4,   2)

plot(preis, menge)      # Streuungsdiagramm
cov(preis, menge)       # Kovarianz: -83.75
var(preis)              # Varianz: 187.5
cor(preis, menge)       # Korrelationskoeffizient: -0.9732
```

`cov()` und `var()` teilen durch $n - 1$ – wie auf den Folien.

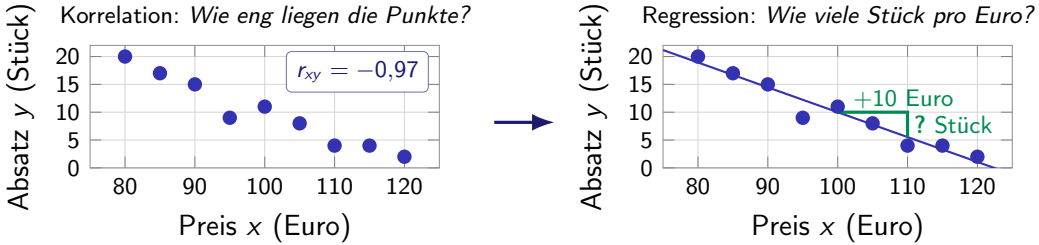
Von der Korrelation zur Regression



	Korrelation (bisher)	**Regression** (jetzt)
Frage	Wie eng ist der Zusammenhang?	Wie ändert sich Y mit X? Welches Y erwarten wir?
Rollen	symmetrisch: $r_{xy} = r_{yx}$	gerichtet: X erklärt Y
Ergebnis	eine Zahl *ohne* Einheit	eine Gerade $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, $\hat{\beta}_1$ in *Stück pro Euro*

Weil r_{xy} keine Einheit hat, kann er „*wie viele Stück?*“ nicht beantworten – das kann erst die Steigung $\hat{\beta}_1$.

Von der Korrelation zur Regression



	Korrelation (bisher)	**Regression** (jetzt)
Frage	Wie eng ist der Zusammenhang?	Wie ändert sich Y mit X? Welches Y erwarten wir?
Rollen	symmetrisch: $r_{xy} = r_{yx}$	gerichtet: X erklärt Y
Ergebnis	eine Zahl *ohne* Einheit	eine Gerade $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$, $\hat{\beta}_1$ in *Stück pro Euro*

Weil r_{xy} keine Einheit hat, kann er „*wie viele Stück?*“ nicht beantworten – das kann erst die Steigung $\hat{\beta}_1$.

Ausgangsfrage: Wie viel Umsatz bringt zusätzliche Werbung?

Situation

Zwölf Filialen: Werbeaufwand und Umsatz im letzten Quartal (Tsd. Euro). An ihnen entwickeln wir die Methode – die Leuchte-Frage beantworten wir danach.

Filiale i	1	2	3	4	5	6	7	8	9	10	11	12
Werbeaufwand x_i (Tsd. Euro)	1	3	4	5	6	8	8	9	10	11	12	13
Umsatz y_i (Tsd. Euro)	33	30	37	33	38	41	39	43	45	40	42	47

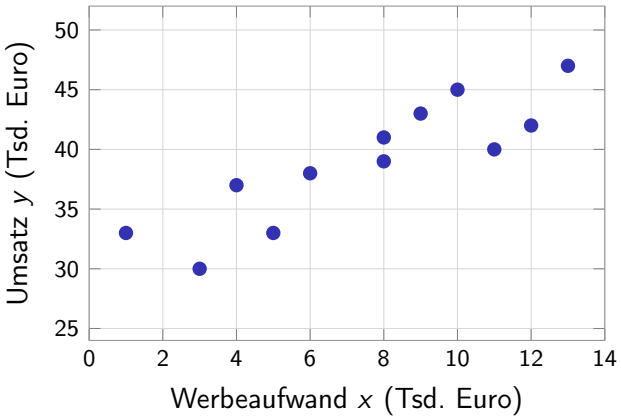
- x: exogen, y: endogen
- $r_{xy} = 0{,}88$: stark positiv

Hilfswerte: $\bar{x} = 7{,}5$, $\bar{y} = 39$, $\mathrm{SP}_{xy} = 186$, $\mathrm{SQ}_x = 155$, $\mathrm{SQ}_y = 288$

Leitfrage

Wie viel Umsatz bringt 1 Tsd. Euro mehr Werbung?
Welcher Umsatz ist bei 7 Tsd. Euro zu erwarten?

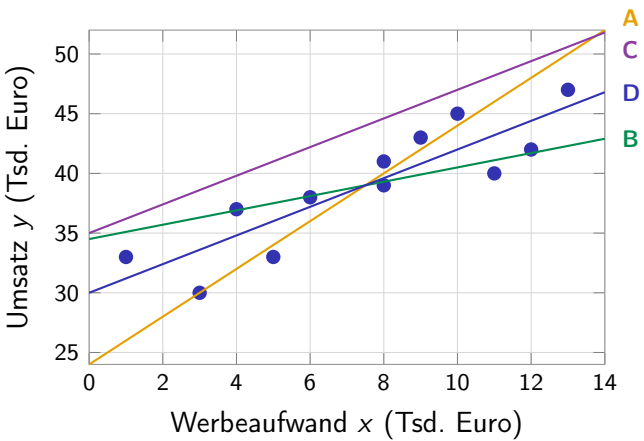
Welche Gerade beschreibt die Daten am besten?



Beobachtung

Mehr Werbung, tendenziell mehr Umsatz.

Welche Gerade beschreibt die Daten am besten?



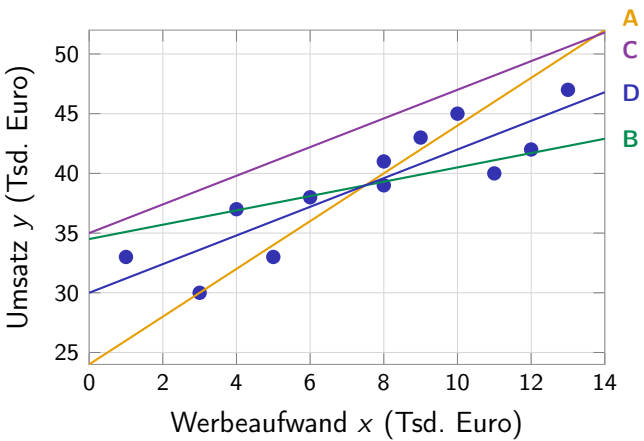
Beobachtung

Mehr Werbung, tendenziell mehr Umsatz.

Viele Geraden denkbar

Welche würden Sie wählen – und warum?

Welche Gerade beschreibt die Daten am besten?



Beobachtung

Mehr Werbung, tendenziell mehr Umsatz.

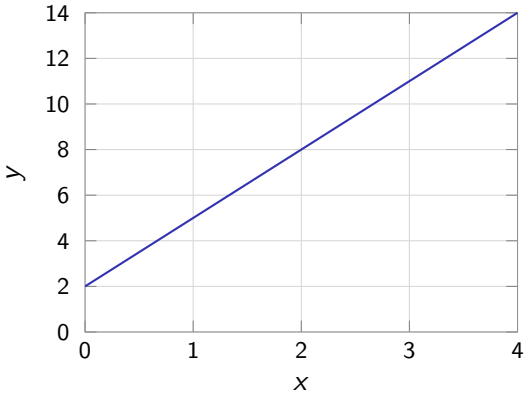
Viele Geraden denkbar

Welche würden Sie wählen – und warum?

Kernaussage

Augenmaß ist subjektiv: Wir brauchen ein **Kriterium**.

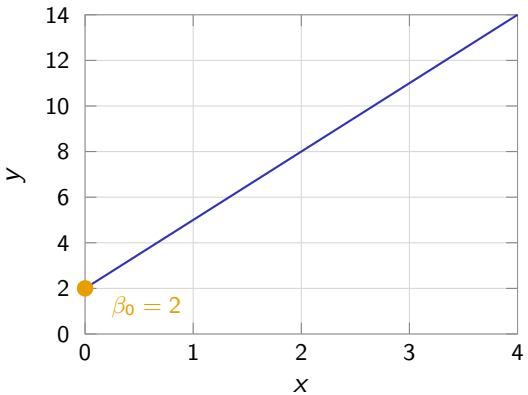
Wie beschreiben wir eine Gerade mathematisch?



Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Wie beschreiben wir eine Gerade mathematisch?



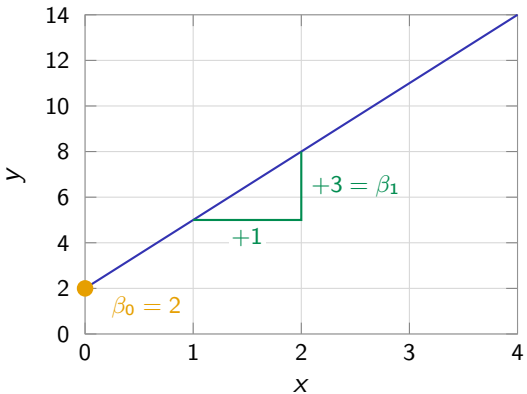
Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Achsenabschnitt β_0

y bei $x = 0$ (hier: 2)

Wie beschreiben wir eine Gerade mathematisch?



Geradengleichung

$$y = \beta_0 + \beta_1 x$$

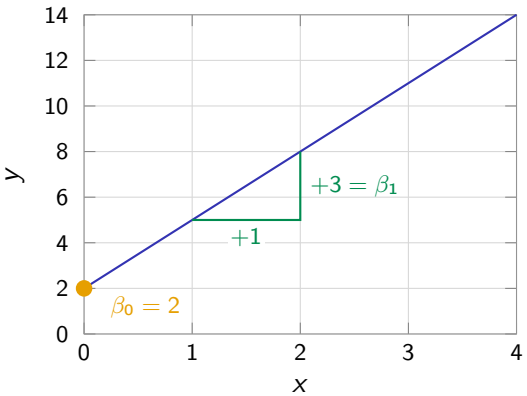
Achsenabschnitt β_0

y bei $x = 0$ (hier: 2)

Steigung β_1

Änderung von y, wenn x um 1 steigt
(hier: $+3$)

Wie beschreiben wir eine Gerade mathematisch?



Geradengleichung

$$y = \beta_0 + \beta_1 x$$

Achsenabschnitt β_0

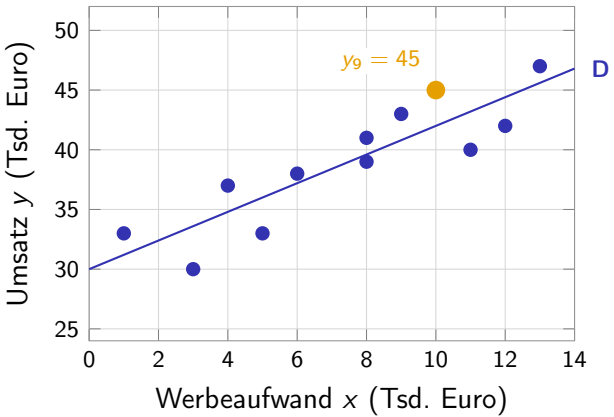
y bei $x = 0$ (hier: 2)

Steigung β_1

Änderung von y, wenn x um 1 steigt
(hier: $+3$)

Gesucht: β_0 und β_1 für die Filialdaten.

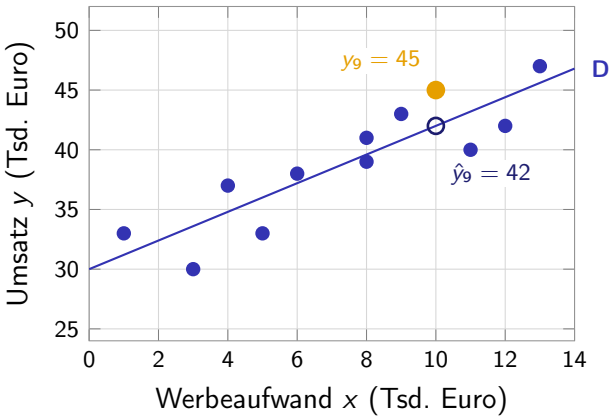
Beobachteter Wert, angepasster Wert und Residuum



Filiale 9 ($x_9 = 10$), Gerade D

- beobachtet: $y_9 = 45$

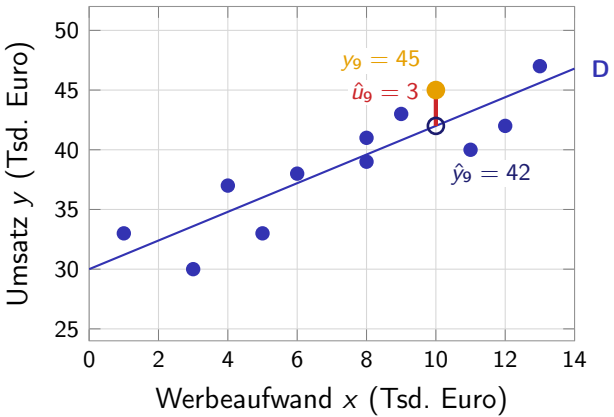
Beobachteter Wert, angepasster Wert und Residuum



Filiale 9 ($x_9 = 10$), Gerade D

- beobachtet: $y_9 = 45$
- angepasst: $\hat{y}_9 = 30 + 1{,}2 \cdot 10 = 42$

Beobachteter Wert, angepasster Wert und Residuum



Filiale 9 ($x_9 = 10$), Gerade D

- beobachtet: $y_9 = 45$
- angepasst: $\hat{y}_9 = 30 + 1{,}2 \cdot 10 = 42$
- Residuum: $\hat{u}_9 = 45 - 42 = 3$

Residuum

$$\hat{u}_i = y_i - \hat{y}_i$$

vertikaler Abstand Punkt – Gerade:
oberhalb $\hat{u}_i > 0$, unterhalb $\hat{u}_i < 0$

Übung Online-Shop (3): Residuen zweier Geraden

Zwei Vorschläge

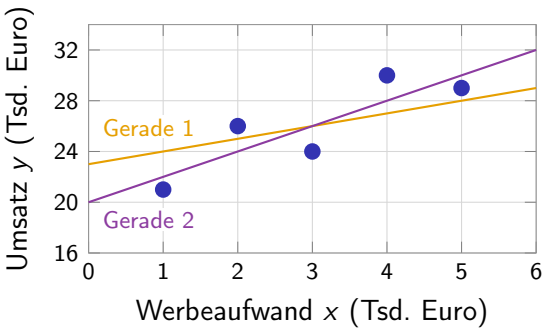
Gerade 1: $\hat{y} = 23 + x$
Gerade 2: $\hat{y} = 20 + 2\,x$

Aufgaben

a) $\hat{y}_i$ und $\hat{u}_i$ für beide Geraden berechnen.

b) Residuen je Gerade summieren.

c) Welche Gerade passt nach Augenmaß besser? Zeigt das die Summe?



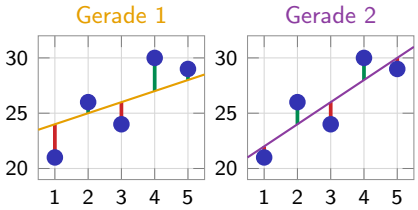
Monat i	1	2	3	4	5
x_i	1	2	3	4	5
y_i	21	26	24	30	29

Lösung Online-Shop (3): Residuen zweier Geraden

a), b) Regel: $\hat{u}_i = y_i - \hat{y}_i$, dann summieren

Monat i	1	2	3	4	5	$\sum$
y_i	21	26	24	30	29	
Gerade 1: $\hat{y}_i = 23 + x_i$	24	25	26	27	28	
$\hat{u}_i = y_i - \hat{y}_i$	-3	1	-2	3	1	**0**
Gerade 2: $\hat{y}_i = 20 + 2x_i$	22	24	26	28	30	
$\hat{u}_i = y_i - \hat{y}_i$	-1	2	-2	2	-1	**0**

grün: $\hat{u}_i > 0$, rot: $\hat{u}_i < 0$ – sie heben sich auf.



c) Gerade 2 passt sichtbar besser

Trotzdem sind beide Summen 0: Die Residuensumme erkennt den Unterschied **nicht**.

Übung Online-Shop (4): Residuen quadrieren

Residuen $\hat{u}_i$ aus Übung (3)

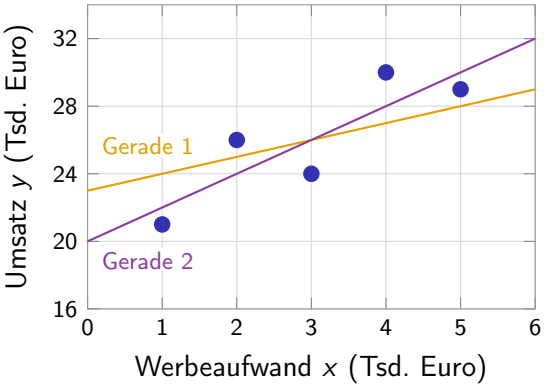
Monat i	1	2	3	4	5
Gerade 1 $(23 + x)$	-3	1	-2	3	1
Gerade 2 $(20 + 2x)$	-1	2	-2	2	-1

Aufgaben

a) Residuen quadrieren: $\hat{u}_i^2$.

b) Je Gerade summieren: $S = \sum \hat{u}_i^2$.

c) Welche Gerade hat die kleinere Summe? Passt das zum Augenmaß?



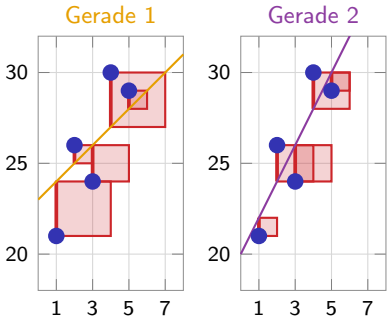
Lösung Online-Shop (4): Residuen quadrieren

a), b) Regel: quadrieren, dann summieren: $S = \sum \hat{u}_i^2$

Monat i		1	2	3	4	5	$\sum$
Gerade 1:	$\hat{u}_i$	-3	1	-2	3	1	0
	$\hat{u}_i^2$	9	1	4	9	1	**24**
Gerade 2:	$\hat{u}_i$	-1	2	-2	2	-1	0
	$\hat{u}_i^2$	1	4	4	4	1	**14**

c) Gerade 2 hat die kleinere Summe

$S_2 = 14 < 24 = S_1$ – wie nach Augenmaß. Quadriert hebt sich nichts auf: Die bessere Gerade hat die **kleinere Quadratsumme**.



Fläche eines Quadrats $= \hat{u}_i^2$

Das Verfahren von Gauß: die Methode der kleinsten Quadrate (KQ)



Carl Friedrich Gauß (1777–1855)
G. Biermann nach C. A. Jensen

Die Idee von Gauß

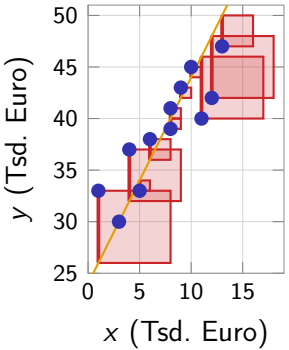
1. Residuen **quadrieren**: nichts hebt sich auf.
2. Quadrate **summieren**: $\sum \hat{u}_i^2$
3. Gerade mit der **kleinsten** Summe wählen.

Warum quadrieren?

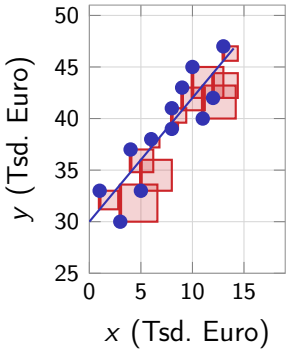
Große Abweichungen zählen stärker: $3^2 = 9$, aber $1^2 = 1$.

Entwickelt von Gauß ab 1795.

Quadrierte Residuen als Flächen



Gerade A: $\sum \hat{u}_i^2 = \mathbf{164{,}0}$



Gerade D: $\sum \hat{u}_i^2 = \mathbf{64{,}8}$

Konstruktion

Residuum = Seite eines Quadrats mit Fläche $\hat{u}_i^2$.

Kernaussage

Gesucht: die Gerade mit der **kleinsten Gesamtfläche**.

Das Minimierungsproblem

Residuenquadratsumme für beliebige β_0 und β_1

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i \big)^2$$

z. B. $S(23;\, 1) = 24$, $S(20;\, 2) = 14$ (Online-Shop); $S(30;\, 1{,}2) = 64{,}8$ (Filialen, D)

Gesucht

$$(\hat{\beta}_0, \hat{\beta}_1) \;=\; \underset{\beta_0,\, \beta_1}{\arg\min}\; S(\beta_0, \beta_1)$$

In Worten: die Werte β_0, β_1 mit der kleinsten Residuenquadratsumme.

Im Minimum ist die Ableitung nach β_0 (β_1 fest) und nach β_1 (β_0 fest) null: die *partiellen* Ableitungen.

Das Minimierungsproblem

Residuenquadratsumme für beliebige β_0 und β_1

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i \big)^2 = \sum_{i=1}^{n} \Big(y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{= \hat{y}_i} \Big)^2$$

z. B. $S(23;\, 1) = 24$, $S(20;\, 2) = 14$ (Online-Shop); $S(30;\, 1{,}2) = 64{,}8$ (Filialen, D)

Gesucht

$$(\hat{\beta}_0, \hat{\beta}_1) \;=\; \underset{\beta_0, \beta_1}{\arg\min}\; S(\beta_0, \beta_1)$$

In Worten: die Werte β_0, β_1 mit der kleinsten Residuenquadratsumme.

Im Minimum ist die Ableitung nach β_0 (β_1 fest) und nach β_1 (β_0 fest) null: die *partiellen* Ableitungen.

Das Minimierungsproblem

Residuenquadratsumme für beliebige β_0 und β_1

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} \big(y_i - \beta_0 - \beta_1 x_i \big)^2 = \sum_{i=1}^{n} \Big(y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{= \hat{y}_i} \Big)^2$$

$$= \sum_{i=1}^{n} \big(\underbrace{y_i - \hat{y}_i}_{= \hat{u}_i} \big)^2 = \sum_{i=1}^{n} \hat{u}_i^2$$

z. B. $S(23;\, 1) = 24$, $S(20;\, 2) = 14$ (Online-Shop); $S(30;\, 1{,}2) = 64{,}8$ (Filialen, D)

Gesucht

$$(\hat{\beta}_0, \hat{\beta}_1) = \underset{\beta_0, \beta_1}{\arg\min}\, S(\beta_0, \beta_1)$$

In Worten: die Werte β_0, β_1 mit der kleinsten Residuenquadratsumme.

Im Minimum ist die Ableitung nach β_0 (β_1 fest) und nach β_1 (β_0 fest) null: die *partiellen* Ableitungen.

Vom Minimierungsproblem zum KQ-Schätzer in vier Schritten

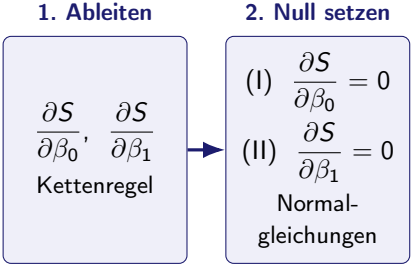
1. Ableiten

$$\frac{\partial S}{\partial \beta_0}, \quad \frac{\partial S}{\partial \beta_1}$$

Kettenregel

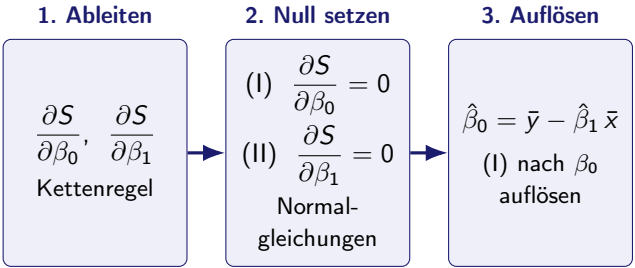
▸ Jeder Rechenschritt: Herleitung im Anhang

Vom Minimierungsproblem zum KQ-Schätzer in vier Schritten



▸ Jeder Rechenschritt: Herleitung im Anhang

Vom Minimierungsproblem zum KQ-Schätzer in vier Schritten



▸ Jeder Rechenschritt: Herleitung im Anhang

Vom Minimierungsproblem zum KQ-Schätzer in vier Schritten

1. Ableiten

$\frac{\partial S}{\partial \beta_0}, \frac{\partial S}{\partial \beta_1}$

Kettenregel

→

2. Null setzen

(I) $\frac{\partial S}{\partial \beta_0} = 0$

(II) $\frac{\partial S}{\partial \beta_1} = 0$

Normal-gleichungen

→

3. Auflösen

$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

(I) nach β_0 auflösen

→

4. Einsetzen

$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$

$\hat{\beta}_0$ in (II) einsetzen, nach β_1 auflösen

Schritt 4 genauer: Was heißt „in (II) einsetzen“?

(II) ausgeschrieben, durch -2 geteilt: $\sum x_i (y_i - \beta_0 - \beta_1 x_i) = 0$ – zwei Unbekannte, β_0 und β_1.

$\beta_0 = \bar{y} - \beta_1 \bar{x}$ aus Schritt 3 einsetzen: $\sum x_i \left(y_i - (\bar{y} - \beta_1 \bar{x}) - \beta_1 x_i\right) = 0$

Jetzt fehlt nur noch $\beta_1 \Rightarrow$ nach β_1 auflösen; das ergibt die Formel rechts oben.

▸ Jeder Rechenschritt: Herleitung im Anhang

Die Lösung des Minimierungsproblems: der KQ-Schätzer

KQ-Schätzer für die Steigung

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Zähler

Summe der Abweichungsprodukte:
positiv bei steigender Punktwolke

Nenner

Summe der Abweichungsquadrate von x:
Streuung von x, > 0 (nicht alle x_i gleich)

Leitfrage

Kommen Ihnen Zähler und Nenner bekannt vor?

Die Verbindung zu Kovarianz und Varianz

Empirische Kovarianz

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

Empirische Varianz von x

$$s_x^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Den Schätzer mit $1/(n-1)$ erweitern

$$\hat{\beta}_1 = \frac{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2} = \frac{s_{xy}}{s_x^2}$$

$$\boxed{\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}}$$

Steigung = Kovarianz durch Varianz

Kernaussage

Steigung = **Kovarianz** von x und y geteilt durch die **Varianz** von x.

Intuition

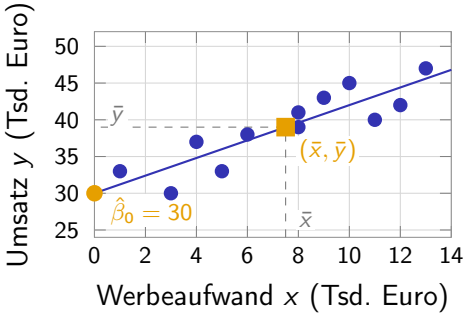
- s_{xy}: gemeinsame Variation
- s_x^2: Streuung von x selbst
- Verhältnis: Änderung von y je Einheit x

Zwölf Filialen

$$\hat{\beta}_1 = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x} = \frac{186}{155} = 1{,}2$$

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = \frac{186/11}{155/11} = \frac{16{,}91}{14{,}09} = 1{,}2$$

Achsenabschnitt, KQ-Gerade und Antwort



KQ-Schätzer: $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

Gerade durch den **Schwerpunkt** $(\bar{x}, \bar{y}) = (7{,}5;\ 39)$

Zwölf Filialen: beide Schätzer

Steigung: $\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x = 186/155 = \mathbf{1{,}2}$

Achsenabschnitt: $\hat{\beta}_0 = 39 - 1{,}2 \cdot 7{,}5 = \mathbf{30}$

Regressionsgerade: $\hat{y} = 30 + 1{,}2\,x$

Antwort auf die Ausgangsfrage

$+1$ Tsd. Euro Werbung bringt im Mittel $+1{,}2$ Tsd. Euro Umsatz.

Bei 7 Tsd. Euro Werbung: $\hat{y} = 30 + 1{,}2 \cdot 7 = \mathbf{38{,}4}$ Tsd. Euro.

Jede Gerade durch $(\bar{x}, \bar{y})$ hat die Residuensumme 0 – auch beide Geraden aus Übung (3).

Beide Schätzer im Überblick

Die KQ-Gerade

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} \qquad \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

Antwort auf die Ausgangsfrage

$\hat{y} = 30 + 1{,}2\,x$ (Gerade D)

$+1$ Tsd. Euro Werbung: $+1{,}2$ Tsd. Euro Umsatz

$x = 7$: $\hat{y} = 38{,}4$ Tsd. Euro

Eigenschaften

- durch $(\bar{x}, \bar{y})$
- $\sum \hat{u}_i = 0$ und $\sum x_i\,\hat{u}_i = 0$
  (aus den Ableitungen nach β_0 und β_1)

▸ Herleitung

Schritt für Schritt zur Regressionsgeraden

Rechenschema

1. Mittelwerte $\bar{x}$, $\bar{y}$
2. Kovarianz $s_{xy} = \sum(x_i - \bar{x})(y_i - \bar{y})/(n-1)$
3. Varianz $s_x^2 = \sum(x_i - \bar{x})^2/(n-1)$
4. Steigung $\hat{\beta}_1 = s_{xy}/s_x^2$
5. Achsenabschnitt $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$
6. Gerade $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

Bei vielen Daten: Rechenabkürzung über Summen (Anhang).

Arbeitstabelle für die Schritte 2 und 3

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1						
2						
$\vdots$						
n						
$\sum$			0	0	$\to s_{xy}$	$\to s_x^2$

Kontrolle: Spalten $x_i - \bar{x}$, $y_i - \bar{y}$ ergeben 0.

Übung Online-Shop (5): Die KQ-Gerade für einen zweiten Shop

Situation

Der Händler eröffnet einen zweiten Shop: fünf Monate, Werte in Tsd. Euro.

Aufgaben

a) $\bar{x}$, $\bar{y}$, SP_{xy} und SQ_x mit einer Arbeitstabelle berechnen.

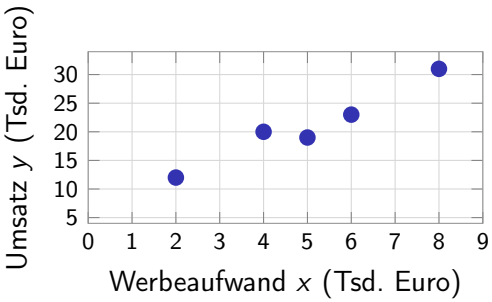
b) $\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x$ und $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$ bestimmen; Regressionsgerade angeben.

c) Die Steigung in Worten deuten.

d) $\hat{y}_i$ und $\hat{u}_i$ berechnen; $\sum \hat{u}_i = 0$ prüfen.

e) Gerade ins Streuungsdiagramm einzeichnen.

Monat i	1	2	3	4	5
Werbeaufwand x_i	2	4	5	6	8
Umsatz y_i	12	20	19	23	31



Lösung Online-Shop (5), Teil 1: Arbeitstabelle und KQ-Schätzer

a) Regel: Mittelwerte, dann Abweichungen, Produkte und Quadrate summieren

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	2	12	-3	-9	27	9
2	4	20	-1	-1	1	1
3	5	19	0	-2	0	0
4	6	23	1	2	2	1
5	8	31	3	10	30	9
$\sum$	25	105	0	0	$\mathrm{SP}_{xy} = \mathbf{60}$	$\mathrm{SQ}_x = \mathbf{20}$

$\bar{x} = 25/5 = \mathbf{5}$, $\bar{y} = 105/5 = \mathbf{21}$; Kontrolle: Die Abweichungen summieren sich zu 0.

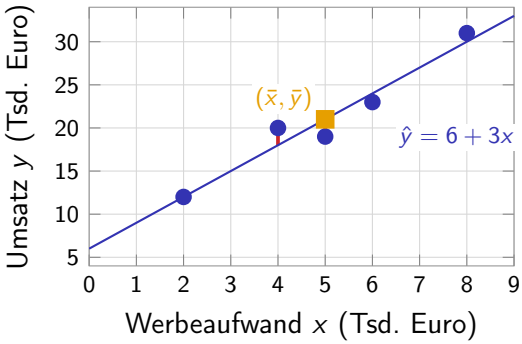
b) Regel: $\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x$, $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$

$\hat{\beta}_1 = 60/20 = \mathbf{3}$, $\hat{\beta}_0 = 21 - 3 \cdot 5 = \mathbf{6} \Rightarrow \hat{y} = 6 + 3x$

c) Deutung der Steigung

+1 Tsd. Euro Werbung: +3 Tsd. Euro Umsatz (im Mittel).

Lösung Online-Shop (5), Teil 2: Residuen und Grafik



e) Die Gerade geht durch den Schwerpunkt (5; 21).

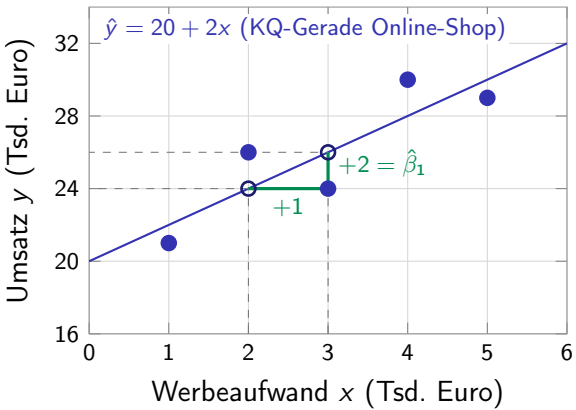
d) Regel: $\hat{y}_i = 6 + 3\,x_i$, $\hat{u}_i = y_i - \hat{y}_i$

i	x_i	y_i	$\hat{y}_i$	$\hat{u}_i$
1	2	12	$6 + 3 \cdot 2 = 12$	0
2	4	20	$6 + 3 \cdot 4 = 18$	2
3	5	19	$6 + 3 \cdot 5 = 21$	-2
4	6	23	$6 + 3 \cdot 6 = 24$	-1
5	8	31	$6 + 3 \cdot 8 = 30$	1
$\sum$				**0** ✓

Zum Vergleich: der erste Shop

$\hat{\beta}_1 = 20/10 = 2$, $\hat{\beta}_0 = 26 - 2 \cdot 3 = 20$:
$\hat{y} = 20 + 2\,x$ ist **Gerade 2** aus Übung (3).

Wie interpretieren wir die Steigung?



Steigung $\hat{\beta}_1 = 2$

x steigt um 1 $\Rightarrow$ $\hat{y}$ steigt um $\hat{\beta}_1$

Hier: $x = 2 \to 3$, $\hat{y} = 24 \to 26$

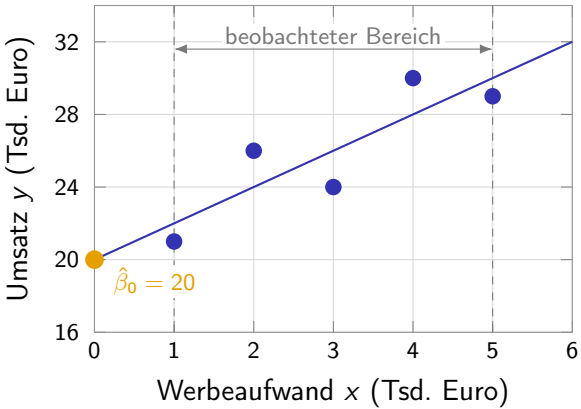
In Worten

2 Tsd. Euro mehr Umsatz je Tsd. Euro Werbung (laut Gerade).

Keine kausale Aussage

Statistischer Zusammenhang – kein Beweis für eine Wirkung.

Wie interpretieren wir den Achsenabschnitt?



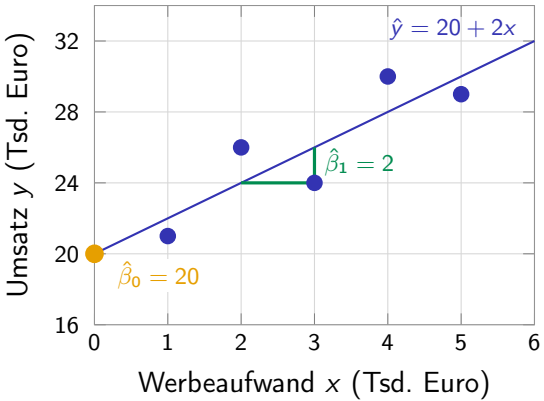
Achsenabschnitt $\hat{\beta}_0 = 20$

$\hat{y}$ bei $x = 0$: Umsatz ohne Werbung

Vorsicht

- $x = 0$ nicht beobachtet (Daten: 1 bis 5): *Extrapolation*
- weit außerhalb der Daten: oft ohne inhaltliche Bedeutung

Interpretation im Überblick – und Prognosen

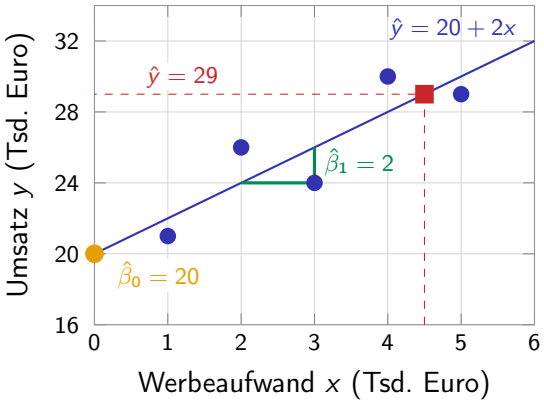


$\hat{y} = 20 + 2\,x$

$\hat{\beta}_0$ Höhe der Geraden bei $x = 0$

$\hat{\beta}_1$ $\Delta\hat{y} = \hat{\beta}_1 \cdot \Delta x$ (Δ: Änderung)

Interpretation im Überblick – und Prognosen



$\hat{y} = 20 + 2\,x$

$\hat{\beta}_0$ Höhe der Geraden bei $x = 0$

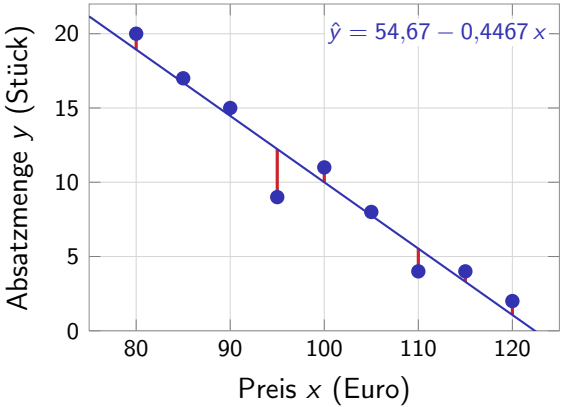
$\hat{\beta}_1$ $\Delta\hat{y} = \hat{\beta}_1 \cdot \Delta x$ (Δ: Änderung)

Prognose: x einsetzen

$x = 4{,}5$: $\hat{y} = 29$ – **Interpolation**

$x = 20$: $\hat{y} = 60$ – **Extrapolation**!

Zweites Beispiel: Preis und Absatz der Leuchte



Schritte 1–3: schon bekannt

$\bar{x} = 100, \quad \bar{y} = 10, \quad s_{xy} = -83{,}75,$
$s_x^2 = 187{,}5$

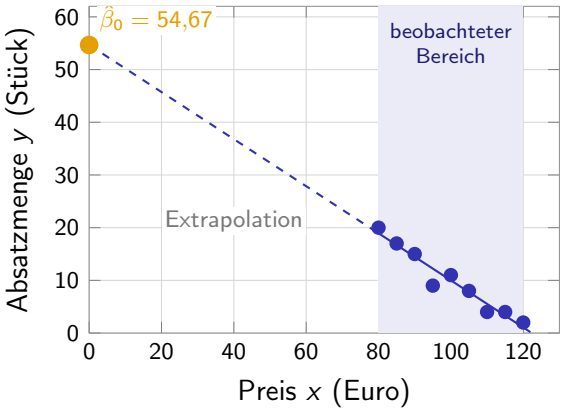
Schritte 4–6

$\hat{\beta}_1 = -83{,}75/187{,}5 = \mathbf{-0{,}4467}$
$\hat{\beta}_0 = 10 + 0{,}4467 \cdot 100 = \mathbf{54{,}67}$

Antwort auf die Frage vom Beginn

$+10$ Euro: $-4{,}5$ Stück $(10 \cdot 0{,}4467)$
Prognose bei 98 Euro: $\hat{y} = 10{,}89$ Stück

Preis und Absatz: Interpretation der Koeffizienten



Steigung $\hat{\beta}_1 = -0{,}4467$

+1 Euro Preis: 0,45 Stück weniger Absatz – eine fallende Preis-Absatz-Funktion

Achsenabschnitt $\hat{\beta}_0 = 54{,}67$

Absatz bei 0 Euro – weit außerhalb der Daten (80 bis 120 Euro): **nicht interpretierbar**

Lineare Regression mit R

Koeffizienten manuell (Schritte 2 bis 5)

```
(beta1 ← cov(preis, menge) / var(preis))
(beta0 ← mean(menge) - beta1 * mean(preis))
```

Dasselbe mit der Funktion `lm()` (*linear model*)

```
reg ← lm(menge ∼ preis)
coef(reg)                          # Achsenabschnitt und Steigung
```

Streuungsdiagramm mit Regressionsgeraden

```
plot(preis, menge, xlim = c(0, 125), ylim = c(0, 60))
abline(reg)
```

Übung Möbelhaus: Koeffizienten deuten und Prognosen ableiten

Möbelhaus, sechs Wochen (Tsd. Euro) – KQ-Gerade $\hat{y} = 40 + 2{,}5\,x$

Werbeausgaben x_i	2	4	6	8	10	12
Wochenumsatz y_i	44	49	58	62	61	71

Aufgaben

a) $\hat{\beta}_0$ und $\hat{\beta}_1$ mit Einheiten deuten. Ist $\hat{\beta}_0$ sinnvoll?

b) Prognose für $x = 5$ und $x = 30$ – wie belastbar?

c) Änderung von $\hat{y}$ bei $x = 4 \to 6$ und bei $x = 10 \to 12$?

d) x in Euro statt Tsd. Euro: neue $\hat{\beta}_0$, $\hat{\beta}_1$? Und zusätzlich y in Euro?
Tipp: $x = x_{\text{Euro}}/1000$ in die Gerade einsetzen.

Lösung Möbelhaus (1/3): Koeffizienten deuten und Änderungen berechnen

a) Regel: $\hat{\beta}_1$ = Änderung von $\hat{y}$ je Einheit x

$\hat{\beta}_1 = 2{,}5$: Je Tsd. Euro Werbung laut Gerade 2,5 **Tsd. Euro** mehr Wochenumsatz – kein Kausalbeweis.

a) Regel: $\hat{\beta}_0$ = Wert von $\hat{y}$ bei $x = 0$

$\hat{\beta}_0 = 40$: Umsatz ohne Werbung 40 **Tsd. Euro**.
$x = 0$ liegt knapp außerhalb der Daten (2 bis 12): Extrapolation, grobe Orientierung.

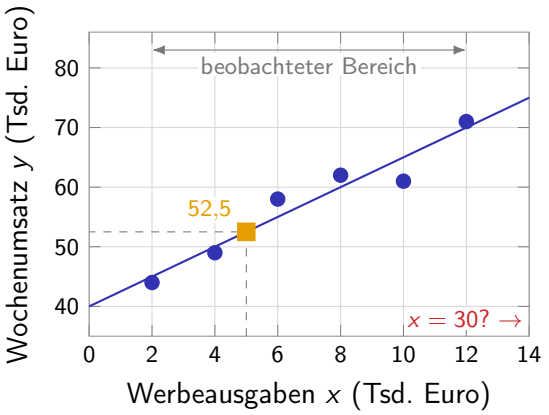
c) Regel: $\Delta\hat{y} = \hat{\beta}_1 \cdot \Delta x$

$\Delta x = 2$: $\Delta\hat{y} = 2{,}5 \cdot 2 = \mathbf{5}$ Tsd. Euro – in beiden Fällen:

$4 \to 6$: $\hat{y}$ von $40 + 2{,}5 \cdot 4 = 50$ auf 55
$10 \to 12$: $\hat{y}$ von 65 auf 70

Gleicher Zuwachs: Eine Gerade hat überall dieselbe Steigung.

Lösung Möbelhaus (2/3): Prognosen und ihre Grenzen



b) Regel: x in die Gerade einsetzen

$x = 5$: $\hat{y} = 40 + 2{,}5 \cdot 5 = \mathbf{52{,}5}$ Tsd. Euro

$x = 30$: $\hat{y} = 40 + 2{,}5 \cdot 30 = \mathbf{115}$ Tsd. Euro

$x = 5$: Interpolation

Im beobachteten Bereich (2 bis 12): plausibel – als Erwartung.

$x = 30$: Extrapolation

Weit außerhalb der Daten, Linearität dort unbekannt: **nicht belastbar**.

Lösung Möbelhaus (3/3): Andere Einheiten – und die Kontrolle mit R

d) Regel: Einheit von x ändert $\hat{\beta}_1$, Einheit von y beide Koeffizienten

x in Euro ($x = x_{\text{Euro}}/1000$): $\hat{y} = 40 + 2{,}5 \cdot x_{\text{Euro}}/1000 = 40 + 0{,}0025\, x_{\text{Euro}}$
$\Rightarrow \hat{\beta}_1 = \mathbf{0{,}0025}$ (Tsd. Euro je Euro), $\hat{\beta}_0 = \mathbf{40}$ unverändert

Zusätzlich y in Euro (mal 1000): $\hat{y}_{\text{Euro}} = \mathbf{40\,000} + \mathbf{2{,}5}\, x_{\text{Euro}}$
$\Rightarrow$ je Euro Werbung 2,50 Euro mehr Umsatz: **dieselbe Aussage**

Kontrolle mit R

```
werbung ← c(2, 4, 6, 8, 10, 12); umsatz ← c(44, 49, 58, 62, 61, 71)
reg ← lm(umsatz ~ werbung)
coef(reg)                                              # 40.0   2.5
predict(reg, newdata = data.frame(werbung = c(5, 30)))   # 52.5 115.0
coef(lm(umsatz ~ I(1000 * werbung)))                   # 40.0000   0.0025
```

Rückblick: Können Sie diese Fragen beantworten?

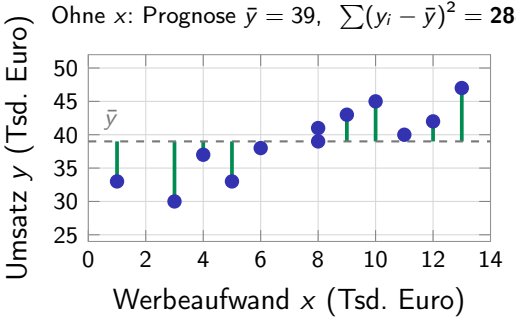
1. Was messen Kovarianz und Korrelation – und was nicht?
2. Was leistet die Regression, was die Korrelation nicht leistet?
3. Warum taugt die Summe der Residuen nicht als Kriterium?
4. Welche Idee steckt hinter der Methode der kleinsten Quadrate?
5. Wie berechnet man $\hat{\beta}_1$ und $\hat{\beta}_0$ von Hand?
6. Wie interpretiert man die Parameter – und was nicht?

Kernaussage

KQ-Gerade: kleinste Residuenquadratsumme, berechnet aus $\bar{x}$, $\bar{y}$, s_{xy} und s_x^2.

Wie viel erklärt die Gerade?

Ohne x: Prognose $\bar{y} = 39$, $\sum(y_i - \bar{y})^2 = \mathbf{288}$

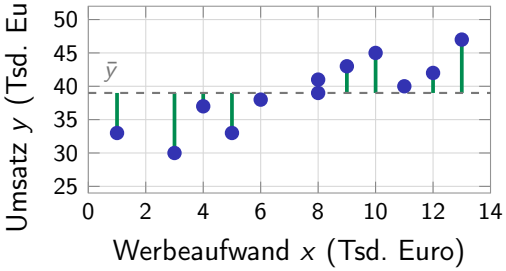


Leitfrage

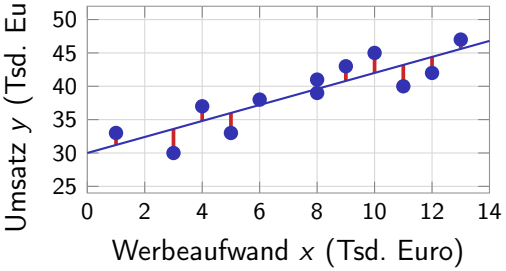
Ohne x ist $\bar{y}$ die beste Prognose. Wie viel besser wird es *mit* der Geraden?

Wie viel erklärt die Gerade?

Ohne x: Prognose $\bar{y} = 39$, $\sum(y_i - \bar{y})^2 = \mathbf{288}$



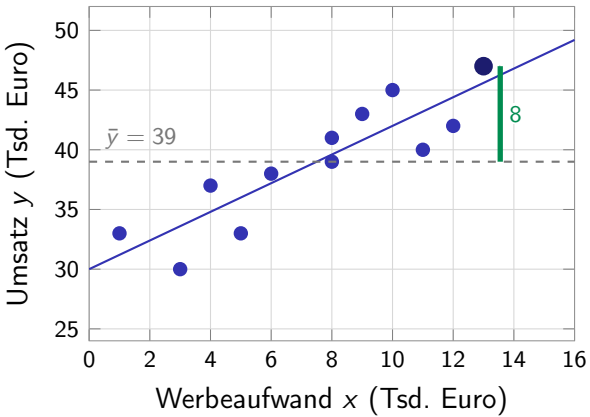
Mit x: Prognose $\hat{y}_i$, $\sum \hat{u}_i^2 = \mathbf{64{,}8}$



Kernaussage

Von 288 auf 64,8: Die Gerade erklärt $(288 - 64{,}8)/288 = \mathbf{77{,}5}\,\%$ der Streuung.

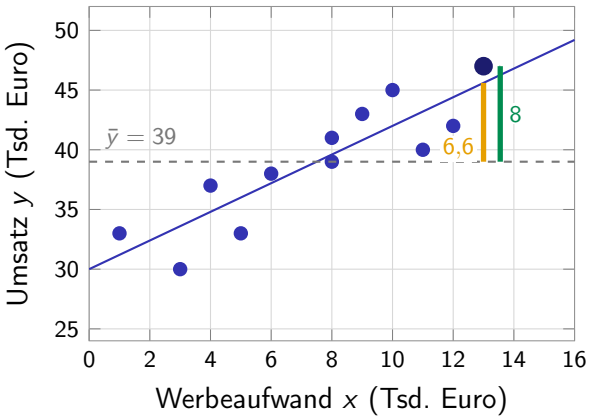
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- gesamt: $47 - 39 = 8$

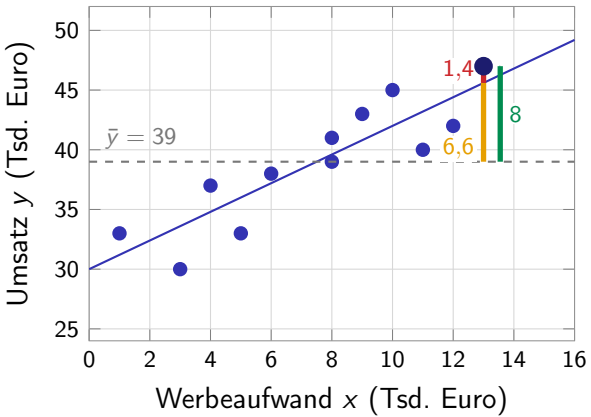
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- gesamt: $47 - 39 = 8$
- erklärt: $45{,}6 - 39 = 6{,}6$

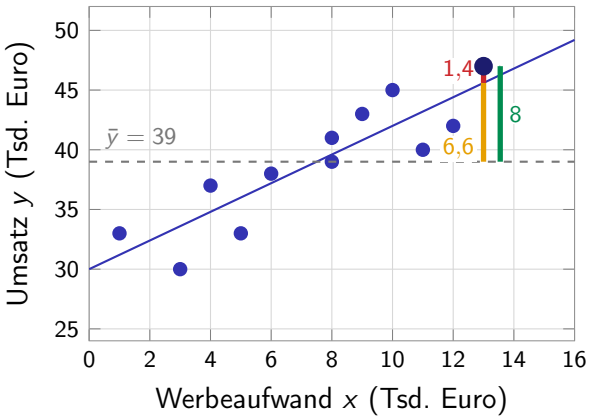
Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- gesamt: $47 - 39 = 8$
- erklärt: $45{,}6 - 39 = 6{,}6$
- Residuum: $47 - 45{,}6 = 1{,}4$

Eine Abweichung in zwei Teile zerlegen



Filiale 12: $x_{12} = 13$, $y_{12} = 47$

- gesamt: $47 - 39 = 8$
- erklärt: $45{,}6 - 39 = 6{,}6$
- Residuum: $47 - 45{,}6 = 1{,}4$

Allgemein

$$\underbrace{y_i - \bar{y}}_{\text{gesamt}} = \underbrace{\hat{y}_i - \bar{y}}_{\text{erklärt}} + \underbrace{y_i - \hat{y}_i}_{\text{Residuum}}$$

Streuungszerlegung: Quadrieren und summieren

Quadratsummenzerlegung (gilt für die KQ-Gerade)

$$\underbrace{\sum_{i=1}^{n}(y_i-\bar{y})^2}_{\text{SQT (total)}} = \underbrace{\sum_{i=1}^{n}(\hat{y}_i-\bar{y})^2}_{\text{SQE (erklärt)}} + \underbrace{\sum_{i=1}^{n}\hat{u}_i^2}_{\text{SQR (Residuen)}}$$

$\text{SQT} = \text{SQ}_y$; $\text{SQR} = S(\hat{\beta}_0, \hat{\beta}_1)$: die minimale Residuenquadratsumme der KQ-Methode

Filiale i	1	2	3	4	5	6	7	8	9	10	11	12	Summe
$(y_i-\bar{y})^2$	36	81	4	36	1	4	0	16	36	1	9	64	**288**
$(\hat{y}_i-\bar{y})^2$	60,84	29,16	17,64	9,00	3,24	0,36	0,36	3,24	9,00	17,64	29,16	43,56	**223,2**
$\hat{u}_i^2$	3,24	12,96	4,84	9,00	0,64	1,96	0,36	4,84	9,00	10,24	5,76	1,96	**64,8**

Zwölf Filialen

$288 = 223{,}2 + 64{,}8$ ✓

Achtung

Nur für Summen: Filiale 1: $36 \neq 60{,}84 + 3{,}24$

Übung Online-Shop (6): Die Streuungszerlegung nachrechnen

Bekannt

Übung (1): $\bar{y} = 26, \quad y_i - \bar{y}$: $-5,\ 0,\ -2,\ 4,\ 3$

KQ-Gerade $20 + 2x$: $\hat{y}_i$: $22,\ 24,\ 26,\ 28,\ 30, \quad \hat{u}_i$: $-1,\ 2,\ -2,\ 2,\ -1$

Aufgaben

a) SQT, SQE und SQR berechnen.

b) Prüfen: Gilt SQT = SQE + SQR?

$$\text{SQT} = \sum (y_i - \bar{y})^2 \qquad \text{SQE} = \sum (\hat{y}_i - \bar{y})^2 \qquad \text{SQR} = \sum \hat{u}_i^2$$

Lösung Online-Shop (6): Die Streuungszerlegung nachrechnen

a) Regel: Abweichungen quadrieren und summieren

Monat i	1	2	3	4	5	Summe
$y_i - \bar{y}$	-5	0	-2	4	3	
$(y_i - \bar{y})^2$	25	0	4	16	9	SQT $=$ **54**
$\hat{y}_i - \bar{y}$	-4	-2	0	2	4	
$(\hat{y}_i - \bar{y})^2$	16	4	0	4	16	SQE $=$ **40**
$\hat{u}_i$	-1	2	-2	2	-1	
$\hat{u}_i^2$	1	4	4	4	1	SQR $=$ **14**

b) Kontrolle

SQT $=$ SQE $+$ SQR: $54 = 40 + 14$ ✓ (SQT $= SQ_y = 54$ wie in Übung (2))

Streuungszerlegung und Kleinste Quadrate

Warum geht die Zerlegung auf?

$(a+b)^2 = a^2 + 2ab + b^2$ mit $b = \hat{u}_i$ und $a = \hat{y}_i - \bar{y} = \hat{\beta}_1(x_i - \bar{x})$ (Gerade durch den Schwerpunkt). Der gemischte Term fällt weg:

$$\sum(\hat{y}_i - \bar{y})\,\hat{u}_i = \hat{\beta}_1 \sum(x_i - \bar{x})\,\hat{u}_i = 0$$

wegen $\sum \hat{u}_i = 0$ und $\sum x_i \hat{u}_i = 0$ – beide *zusammen* gelten nur für die KQ-Gerade

Was die KQ-Methode bewirkt

$$\underbrace{\text{SQT}}_{\text{fest}} = \text{SQE} + \underbrace{\text{SQR}}_{\text{minimal}}$$

Kernaussage

SQR ist minimal – deshalb ist der erklärte Anteil $1 - \text{SQR}/\text{SQT}$ bei der KQ-Geraden am größten.

Das Bestimmtheitsmaß R^2

Definition

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = 1 - \frac{\text{SQR}}{\text{SQT}} \qquad 0 \leq R^2 \leq 1$$

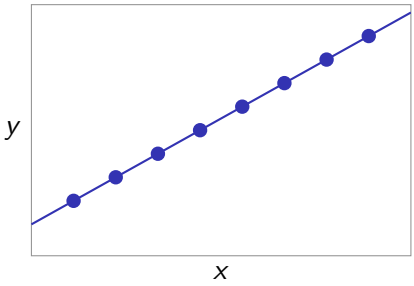
In Worten: der *Anteil* der Streuung von y, den die Gerade erklärt.

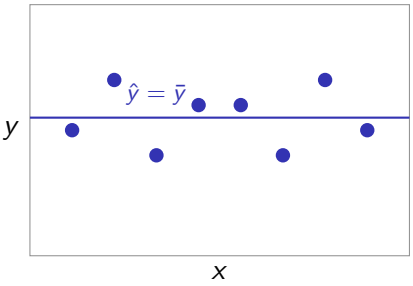
Zwölf Filialen

$$R^2 = \frac{223{,}2}{288} = 1 - \frac{64{,}8}{288} = \mathbf{0{,}775}$$

77,5 % der Streuung der Umsätze sind erklärt, 22,5 % nicht.

Die Extremfälle: $R^2 = 1$ und $R^2 = 0$





$R^2 = 1$: perfekte Anpassung

Alle Punkte auf der Geraden: SQR $= 0$.

$R^2 = 0$: nichts erklärt

Waagerechte Gerade ($\hat{\beta}_1 = 0$): SQE $= 0$.

Bestimmtheitsmaß und Korrelationskoeffizient

Schritt 1: erklärte Abweichung

$$\hat{y}_i - \bar{y} = \hat{\beta}_0 + \hat{\beta}_1 x_i - \bar{y} = \hat{\beta}_1 (x_i - \bar{x}) \quad \Longrightarrow \quad \mathrm{SQE} = \hat{\beta}_1^2 \, \mathrm{SQ}_x = \hat{\beta}_1 \, \mathrm{SP}_{xy}$$

Schritt 2: $\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x$ einsetzen

$$R^2 = \frac{\mathrm{SQE}}{\mathrm{SQT}} = \frac{\hat{\beta}_1^2 \, \mathrm{SQ}_x}{\mathrm{SQ}_y} = \frac{\mathrm{SP}_{xy}^2}{\mathrm{SQ}_x \, \mathrm{SQ}_y} = r_{xy}^2$$

Kernaussage

Einfachregression: $R^2 = r_{xy}^2$.

Zwölf Filialen

$r_{xy} = 0{,}8803, \quad r_{xy}^2 = 0{,}775 = R^2$ ✓

Beispiel Leuchte: Bestimmtheitsmaß berechnen

Bekannt

$\mathrm{SP}_{xy} = -670, \quad \mathrm{SQ}_x = 1500, \quad \mathrm{SQ}_y = 316$

Quadratsummen

$\mathrm{SQT} = \mathrm{SQ}_y = 316$

$\mathrm{SQE} = \hat{\beta}_1 \, \mathrm{SP}_{xy} = (-0{,}4467)(-670) = 299{,}27$

$\mathrm{SQR} = 316 - 299{,}27 = 16{,}73$

Bestimmtheitsmaß

$$R^2 = \frac{299{,}27}{316} = \mathbf{0{,}9470}$$

Kontrolle: $(-0{,}9732)^2 \approx 0{,}947$ ✓

Interpretation

94,7 % erklärt: **gute Anpassung**. Das Vorzeichen steckt in $\hat{\beta}_1$, nicht in R^2.

Was R^2 verrät – und was nicht

Keine Richtung

$\sqrt{R^2} = |r_{xy}|$: Das Vorzeichen zeigen nur r_{xy} und $\hat{\beta}_1$.

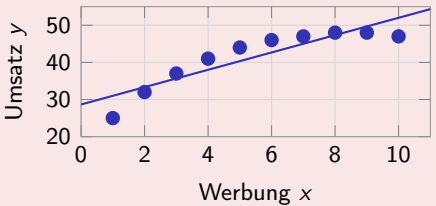
Nur linear

Kleines R^2 heißt nicht „kein Zusammenhang“ – er kann gekrümmt sein.

Keine Kausalität

Hohes R^2 ist kein Beweis für eine Wirkung.

Hohes R^2, falsches Modell



Sättigung: $R^2 = 0{,}81$ – trotzdem gekrümmt.

Kernaussage

Ein hohes R^2 ersetzt nicht den Blick auf die Daten (Residuenplot: Anhang).

Bestimmtheitsmaß beurteilen

Faustregel dieser Veranstaltung

Wert von R^2	**Beurteilung**
$R^2 < 0{,}6$	schwache Anpassung
$0{,}6 \leq R^2 < 0{,}8$	mäßige Anpassung
$R^2 \geq 0{,}8$	gute Anpassung

$r_{xy} = 0{,}7$ ergibt nur $R^2 = 0{,}49$.

Unsere Beispiele

Filialen	0,775	mäßig
Leuchte	0,947	gut
Sättigung	0,81	gut – aber gekrümmt!

Mit Augenmaß

Was „hoch“ ist, hängt vom Fach und den Daten ab.

Übung Online-Shop (7): Bestimmtheitsmaß berechnen und beurteilen

Bekannt

Übung (6): SQT $= 54$, SQE $= 40$, SQR $= 14$ Übung (2): $r_{xy} = 0{,}8607$

Aufgaben

a) R^2 auf beiden Wegen berechnen.

b) R^2 in Worten interpretieren und nach der Faustregel beurteilen.

c) Mit r_{xy} aus Übung (2) kontrollieren.

Lösung Online-Shop (7): Bestimmtheitsmaß berechnen und beurteilen

a) Regel: $R^2 = \text{SQE}/\text{SQT} = 1 - \text{SQR}/\text{SQT}$

$$R^2 = \frac{40}{54} = \mathbf{0{,}741} \qquad R^2 = 1 - \frac{14}{54} = 0{,}741$$

b) Interpretation und Beurteilung

74 % der Streuung der Monatsumsätze sind durch den Werbeaufwand erklärt, 26 % nicht.

$0{,}6 \leq 0{,}741 < 0{,}8$: **mäßige** Anpassung.

c) Regel: $R^2 = r_{xy}^2$

$0{,}8607^2 = 0{,}741$ ✓

Beachte: $r_{xy} = 0{,}86$ gilt als stark, $R^2 = 0{,}74$ nur als mäßig – verschiedene Faustregeln.

Bestimmtheitsmaß von R ausgeben lassen

Komplette Ausgabe

```
reg ← lm(menge ∼ preis)
summary(reg)                # Zeile "Multiple R-squared: 0.947"
```

Drei Wege zum selben Wert

```
summary(reg)$r.squared                                  # direkt
1 - sum(resid(reg)^2) / sum((menge - mean(menge))^2)    # 1 - SQR/SQT
cor(preis, menge)^2                                     # r^2 (Einfachregression)
```

Weitere Größen in `summary()` (Standardfehler, p-Werte): Teil 6.

Übung Heizkosten: Von den Quadratsummen zum Korrelationskoeffizienten

Daten: Heizkosten eines Ladenlokals in fünf Wochen

Woche i	1	2	3	4	5
Mittlere Außentemperatur x_i (°C)	0	3	6	9	12
Heizkosten y_i (Euro je Tag)	82	65	63	41	49

Aus R bekannt: KQ-Gerade $\hat{y} = 78 - 3\,x$, $\quad$ SQT $= 1000$, $\quad$ SQR $= 190$.

Aufgaben

a) SQE und R^2 berechnen und deuten.

b) r_{xy} aus R^2 (mit Vorzeichen) bestimmen.

c) Anpassung nach der Faustregel beurteilen.

d) Kontrolle: SQE $= \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$.

Lösung (1/2): Quadratsummen, R^2 und Korrelationskoeffizient

a) Regel: SQT = SQE + SQR

$\text{SQE} = \text{SQT} - \text{SQR} = 1000 - 190 = \mathbf{810}$

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = \frac{810}{1000} = 1 - \frac{190}{1000} = \mathbf{0{,}81}$$

81 % der Streuung der Heizkosten sind durch die Temperatur erklärt.

c) Beurteilung

$R^2 = 0{,}81 \geq 0{,}8$: **gute Anpassung**.
Bei $n = 5$ aber unsicher.

b) Regel: $R^2 = r_{xy}^2$, Vorzeichen von $\hat{\beta}_1$

$|r_{xy}| = \sqrt{R^2} = \sqrt{0{,}81} = 0{,}9$

r_{xy} und $\hat{\beta}_1$ haben stets dasselbe Vorzeichen;
$\hat{\beta}_1 = -3 < 0$, also $r_{xy} = \mathbf{-0{,}9}$.

Typischer Fehler

Aus R^2 folgt nur $|r_{xy}|$; das Vorzeichen steckt in $\hat{\beta}_1$: je wärmer, desto *niedriger* die Kosten.

Lösung (2/2): Kontrolle von Hand und mit R

d) Regel: SQE $= \hat{\beta}_1^2 \sum (x_i - \bar{x})^2$

$\bar{x} = 30/5 = 6$; $x_i - \bar{x}$: $-6,\ -3,\ 0,\ 3,\ 6$; $\sum (x_i - \bar{x})^2 = 36 + 9 + 0 + 9 + 36 = 90$

SQE $= (-3)^2 \cdot 90 = \mathbf{810}$ ✓ Ebenso SQT: $\bar{y} = 60$, $22^2 + 5^2 + 3^2 + (-19)^2 + (-11)^2 = 1000$ ✓

Mit R

```
temp ← c(0, 3, 6, 9, 12); kosten ← c(82, 65, 63, 41, 49)
reg ← lm(kosten ~ temp)
summary(reg)                  # Zeile "Multiple R-squared:  0.81"
summary(reg)$r.squared        # 0.81
cor(temp, kosten)             # -0.9
sum(resid(reg)^2)             # 190  (SQR)
```

Kernaussage

Drei Zahlen genügen: Aus SQT und SQR folgen SQE und R^2; mit dem Vorzeichen von $\hat{\beta}_1$ auch r_{xy}.

Rückblick Bestimmtheitsmaß

Können Sie diese Fragen beantworten?

1. In welche zwei Teile zerfällt die Abweichung $y_i - \bar{y}$?
2. Warum gilt $\mathrm{SQT} = \mathrm{SQE} + \mathrm{SQR}$ nur für die KQ-Gerade?
3. Was misst R^2 – und warum gilt $R^2 = r_{xy}^2$?
4. Warum reicht ein hohes R^2 nicht als Gütesiegel?

$$R^2 = \frac{\mathrm{SQE}}{\mathrm{SQT}} = 1 - \frac{\mathrm{SQR}}{\mathrm{SQT}} = r_{xy}^2$$

Übung: Körpergröße und Schuhgröße

Daten: $n = 15$ Personen

Person i	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
Körpergröße k_i (cm)	164	162	168	198	166	166	192	160	151	175	180	160	168	175	168
Schuhgröße s_i	39	38	39	46	40	39	45	37	36	42	43	38	41	40	39

Hilfssummen: $\sum k_i = 2553$, $\sum s_i = 602$, $\sum k_i s_i = 102\,932$, $\sum k_i^2 = 436\,643$, $\sum s_i^2 = 24\,272$
Verschiebungssatz (Anhang): $\mathrm{SP}_{ks} = \sum k_i s_i - n\,\bar{k}\,\bar{s}$, $\mathrm{SQ}_k = \sum k_i^2 - n\,\bar{k}^2$

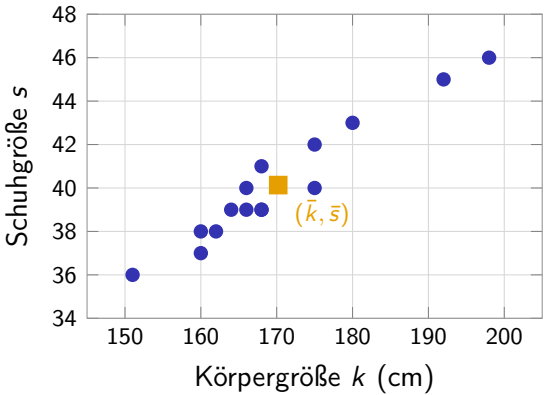
Aufgaben (KQ-Gerade $\hat{s} = \hat{\beta}_0 + \hat{\beta}_1 k$)

1. Streuungsdiagramm, Beschreibung
2. Kovarianz und Korrelation
3. KQ-Gerade schätzen und deuten
4. Bestimmtheitsmaß, Beurteilung

Im Anhang:

5. Residuenplot, Beurteilung
6. QQ-Plot der Residuen, Beurteilung

Lösung (1/4): Streuungsdiagramm und Mittelwerte



Mittelwerte

$$\bar{k} = \frac{2553}{15} = 170{,}2 \text{ cm}$$

$$\bar{s} = \frac{602}{15} = 40{,}1\overline{3}$$

1. Beschreibung

Deutlich **positiver**, nahezu **linearer** Zusammenhang mit geringer Streuung.

(168; 39) kommt zweimal vor: 15 Personen, 14 sichtbare Punkte.

Lösung (2/4): Kovarianz und Korrelationskoeffizient

Grundsummen mit dem Verschiebungssatz ($n\bar{k}\bar{s} = \sum k_i \sum s_i / n$: ohne Rundung)

$$\mathrm{SP}_{ks} = \sum k_i s_i - \frac{\sum k_i \sum s_i}{n} = 102\,932 - \frac{2553 \cdot 602}{15} = 102\,932 - 102\,460{,}4 = \mathbf{471{,}6}$$

$$\mathrm{SQ}_k = \sum k_i^2 - \frac{(\sum k_i)^2}{n} = 436\,643 - 434\,520{,}6 = \mathbf{2122{,}4}$$

$$\mathrm{SQ}_s = \sum s_i^2 - \frac{(\sum s_i)^2}{n} = 24\,272 - 24\,160{,}27 = \mathbf{111{,}73}$$

Regel: $s_{ks} = \mathrm{SP}_{ks}/(n-1)$

$s_{ks} = 471{,}6/14 = \mathbf{33{,}69}$ (cm · Schuhgröße)

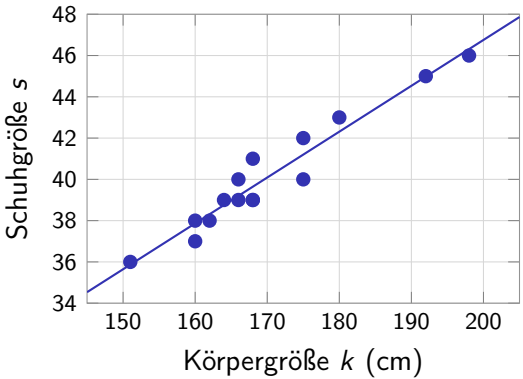
positiv: gleichläufig

Regel: $r_{ks} = \mathrm{SP}_{ks}/\sqrt{\mathrm{SQ}_k\,\mathrm{SQ}_s}$

$$r_{ks} = \frac{471{,}6}{\sqrt{2122{,}4 \cdot 111{,}73}} = \mathbf{0{,}9684}$$

stark positiv ($|r| > 0{,}8$)

Lösung (3/4): KQ-Gerade schätzen und interpretieren



Regel: $\hat{\beta}_1 = \mathrm{SP}_{ks}/\mathrm{SQ}_k, \quad \hat{\beta}_0 = \bar{s} - \hat{\beta}_1 \bar{k}$

$\hat{\beta}_1 = 471{,}6/2122{,}4 = \mathbf{0{,}2222}$

$\hat{\beta}_0 = 40{,}1\overline{3} - 0{,}2222 \cdot 170{,}2 = \mathbf{2{,}3147}$

(mit ungerundetem $\hat{\beta}_1$ gerechnet)

Interpretation

- Je cm Körpergröße ist eine um 0,22 größere Schuhgröße zu erwarten – eine Schuhgröße entspricht rund 4,5 cm.
- $\hat{\beta}_0$: Schuhgröße bei 0 cm Körpergröße – weit außerhalb der Daten, **nicht interpretierbar**.

Lösung (4/4): Bestimmtheitsmaß

Regel: $\mathrm{SQE} = \hat{\beta}_1 \, \mathrm{SP}_{ks}$, $R^2 = \mathrm{SQE}/\mathrm{SQT}$

$\mathrm{SQE} = \hat{\beta}_1 \cdot \mathrm{SP}_{ks} = 0{,}2222 \cdot 471{,}6 = 104{,}79$

$\mathrm{SQR} = 111{,}73 - 104{,}79 = 6{,}94$

$R^2 = 104{,}79/111{,}73 = \mathbf{0{,}9379}$

Kontrolle über die Korrelation

$R^2 = r_{ks}^2 = 0{,}9684^2 \approx 0{,}938$ ✓

Interpretation und Beurteilung

Rund 93,8 % der Streuung der Schuhgrößen werden durch die Körpergröße (linear) erklärt. $R^2 \geq 0{,}8$: **gute Anpassung**.

Kernaussage

Die Gerade erklärt fast die gesamte Streuung. Ob sie auch angemessen ist, zeigt der Residuenplot (Aufgabe 5 im Anhang).

Zusammenfassung 1: Zusammenhang zweier Merkmale

Streuungsdiagramm

Ein Punkt je Beobachtung: Richtung, Stärke, Form. Paare nie getrennt sortieren.

Maß	Formel	Lesart
Kovarianz	$s_{xy} = \frac{1}{n-1}\sum(x_i-\bar{x})(y_i-\bar{y}) = \frac{\mathrm{SP}_{xy}}{n-1}$	Vorzeichen = Richtung; Betrag hängt von den Einheiten ab
Korrelation	$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y}}$	$-1 \le r_{xy} \le 1$; $\lvert r_{xy}\rvert > 0{,}8$ stark, 0,5 bis 0,8 mittel, $< 0{,}5$ schwach

Grenzen der Korrelation

Misst nur *lineare* Zusammenhänge; symmetrisch und ohne Aussage über Ursache und Wirkung; Scheinkorrelation durch Drittvariablen möglich.

Zusammenfassung 2: Regression

Größe	über Kennzahlen	über Summen
Steigung	$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$	$\hat{\beta}_1 = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$
Achsenabschnitt	$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$	(gleich)
Bestimmtheitsmaß	$R^2 = \frac{\mathrm{SQE}}{\mathrm{SQT}} = 1 - \frac{\mathrm{SQR}}{\mathrm{SQT}} = r_{xy}^2$	$R^2 = \frac{\mathrm{SP}_{xy}^2}{\mathrm{SQ}_x \, \mathrm{SQ}_y}$
Erklärte Quadratsumme	$\mathrm{SQE} = \hat{\beta}_1^2 \, \mathrm{SQ}_x$	$\mathrm{SQE} = \hat{\beta}_1 \, \mathrm{SP}_{xy}$

Interpretation von $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$

$\hat{\beta}_1$: Änderung von $\hat{y}$ je Einheit x $\quad$ $\hat{\beta}_0$: $\hat{y}$ bei $x = 0$ (oft Extrapolation)
Prognosen nur im beobachteten Bereich – keine Kausalaussage

Verschiebungssatz: $\mathrm{SP}_{xy} = \sum x_i y_i - n\bar{x}\bar{y}$, $\mathrm{SQ}_x = \sum x_i^2 - n\bar{x}^2$

Zusammenfassung 3: Bestimmtheitsmaß und Modelldiagnostik

Bestimmtheitsmaß: Anteil der erklärten Streuung

$$R^2 = \frac{\text{SQE}}{\text{SQT}} = 1 - \frac{\text{SQR}}{\text{SQT}} = r_{xy}^2 \qquad \text{SQT} = \text{SQE} + \text{SQR (nur KQ-Gerade)}$$

$R^2 < 0{,}6$: schwach $\qquad 0{,}6 \leq R^2 < 0{,}8$: mäßig $\qquad R^2 \geq 0{,}8$: gut

Residuen

$\hat{u}_i = y_i - \hat{y}_i, \quad \sum \hat{u}_i = 0$

Ein hohes R^2 ersetzt die Modelldiagnostik nicht (Anhang)

Residuenplot strukturlos? Bogen: falsche Funktionsform, Trichter: Heteroskedastizität, Wellen: Autokorrelation

QQ-Plot: Punkte nahe der Referenzgeraden? (Normalverteilung)

Zusammenfassung: Wichtige R-Befehle (1/2)

Streuungsdiagramm

```
plot(x, y)                    # Streuungsdiagramm
```

Kovarianz, Varianz und Korrelation

```
cov(x, y)                     # Kovarianz
var(x)                        # Varianz
cor(x, y)                     # Korrelationskoeffizient
```

Zusammenfassung: Wichtige R-Befehle (2/2)

Regression

```
reg ← lm(y ∼ x)                    # Lineares Modell
coef(reg)                          # Achsenabschnitt und Steigung
abline(reg)                        # Gerade ins Streuungsdiagramm
predict(reg, data.frame(x = 5))    # Prognose für x = 5
summary(reg)                       # Ergebnisse inkl. R^2
```

Modelldiagnostik (Anhang)

```
plot(fitted(reg), resid(reg))      # Residuenplot
abline(h = 0, col = "red")         # Nulllinie
qqnorm(resid(reg))                 # QQ-Plot
qqline(resid(reg))                 # Referenzlinie
```

Überblick

2. Anhang
   - Herleitung KQ
   - Umformungen
   - Residuenanalyse
   - QQ-Plot

Anhang: Herleitung (1/7) – Ausgangspunkt und Plan

Woher kommen $\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x$ und $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$? Ausgangspunkt:

$$S(\beta_0, \beta_1) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \beta_1 x_i\right)^2 \;\to\; \min \qquad \Longrightarrow \qquad \frac{\partial S}{\partial \beta_0} = 0, \quad \frac{\partial S}{\partial \beta_1} = 0$$

β_0, β_1: beliebige Kandidaten, Lösung: $\hat{\beta}_0$, $\hat{\beta}_1$. *Partiell*: nach β_0 ableiten, β_1 als feste Zahl (und umgekehrt).

Plan – die vier Schritte aus dem Hauptteil

(2), (3)	Schritt 1: beide partiellen Ableitungen bilden
(4), (5)	Schritte 2–4: null setzen, nach β_0 auflösen, einsetzen
(6)	Ergebnis in die Abweichungsform bringen
(7)	prüfen, dass es wirklich ein Minimum ist

zurück

Anhang: Herleitung (2/7) – Ableitung nach β_0

Ein einzelner Summand: Kettenregel

$$\frac{\partial}{\partial \beta_0}\left(y_i - \beta_0 - \beta_1 x_i\right)^2 = \underbrace{2\left(y_i - \beta_0 - \beta_1 x_i\right)}_{\text{äußere}} \cdot \underbrace{(-1)}_{\text{innere}} = -2\left(y_i - \beta_0 - \beta_1 x_i\right)$$

Innere Funktion $y_i - \beta_0 - \beta_1 x_i$: Nach β_0 abgeleitet bleibt -1, denn y_i und $\beta_1 x_i$ hängen nicht von β_0 ab.

Alle Summanden: Summenregel

$$\frac{\partial S}{\partial \beta_0} = \sum_{i=1}^{n} -2\left(y_i - \beta_0 - \beta_1 x_i\right) = -2\sum_{i=1}^{n}\left(y_i - \beta_0 - \beta_1 x_i\right)$$

Die Ableitung einer Summe ist die Summe der Ableitungen; den konstanten Faktor -2 vor die Summe ziehen.

Anhang: Herleitung (3/7) – Ableitung nach β_1

Ein einzelner Summand: Kettenregel

$$\frac{\partial}{\partial \beta_1}\big(y_i - \beta_0 - \beta_1 x_i\big)^2 = \underbrace{2\big(y_i - \beta_0 - \beta_1 x_i\big)}_{\text{äußere}} \cdot \underbrace{(-x_i)}_{\text{innere}} = -2\,x_i\big(y_i - \beta_0 - \beta_1 x_i\big)$$

Nach β_1 abgeleitet: $\partial(-\beta_1 x_i)/\partial\beta_1 = -x_i$; y_i und β_0 hängen nicht von β_1 ab.

Alle Summanden: Summenregel

$$\frac{\partial S}{\partial \beta_1} = -2\sum_{i=1}^{n} x_i\big(y_i - \beta_0 - \beta_1 x_i\big)$$

Zwischenstand

Beide Ableitungen enthalten die Residuen $y_i - \beta_0 - \beta_1 x_i$ der jeweiligen Geraden.

Anhang: Herleitung (4/7) – Erste Bedingung: der Achsenabschnitt

$\partial S/\partial \beta_0 = 0$ Schritt für Schritt

$$
\begin{aligned}
-2\sum(y_i - \beta_0 - \beta_1 x_i) &= 0 && \mid \text{durch } (-2) \text{ teilen} \\
\sum(y_i - \beta_0 - \beta_1 x_i) &= 0 && \mid \text{Summe aufteilen} \\
\sum y_i - \sum \beta_0 - \sum \beta_1 x_i &= 0 && \mid \textstyle\sum_{i=1}^{n} \beta_0 = n\beta_0, \quad \sum \beta_1 x_i = \beta_1 \sum x_i \\
\sum y_i - n\beta_0 - \beta_1 \sum x_i &= 0 && \mid +n\beta_0 \\
n\beta_0 &= \sum y_i - \beta_1 \sum x_i && \mid \text{durch } n \text{ teilen} \\
\hat{\beta}_0 &= \bar{y} - \hat{\beta}_1 \bar{x} && \mid \text{wegen } \tfrac{1}{n}\sum y_i = \bar{y},\ \tfrac{1}{n}\sum x_i = \bar{x}
\end{aligned}
$$

Zeile 4 umgestellt ist die **erste Normalgleichung** $\sum y_i = n\beta_0 + \beta_1 \sum x_i$. Zeile 2 mit den KQ-Werten: $\sum \hat{u}_i = 0$ – die Residuensumme der KQ-Geraden ist null.

Anhang: Herleitung (5/7) – Zweite Bedingung: die Steigung

$\partial S/\partial \beta_1 = 0$ und den Achsenabschnitt einsetzen

$$
\begin{aligned}
-2\sum x_i(y_i - \beta_0 - \beta_1 x_i) &= 0 && \mid \text{durch } (-2) \text{ teilen} \\
\sum x_i(y_i - \beta_0 - \beta_1 x_i) &= 0 && \mid \text{ausmultiplizieren, Summe aufteilen} \\
\sum x_i y_i - \beta_0 \sum x_i - \beta_1 \sum x_i^2 &= 0 && \mid \text{umgestellt: 2. Normalgleichung} \\
\sum x_i y_i - (\bar{y} - \beta_1 \bar{x})\, n\bar{x} - \beta_1 \sum x_i^2 &= 0 && \mid \beta_0 = \bar{y} - \beta_1 \bar{x} \text{ (4/7)},\ \textstyle\sum x_i = n\bar{x} \\
\sum x_i y_i - n\bar{x}\bar{y} + \beta_1 n\bar{x}^2 - \beta_1 \sum x_i^2 &= 0 && \mid \text{Klammer auflösen} \\
\sum x_i y_i - n\bar{x}\bar{y} &= \beta_1 \left(\sum x_i^2 - n\bar{x}^2\right) && \mid \beta_1\text{-Terme nach rechts, ausklammern} \\
\hat{\beta}_1 &= \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} && \mid \text{durch die Klammer teilen } (= \mathrm{SQ}_x > 0)
\end{aligned}
$$

Zeile 2 mit den KQ-Werten: $\sum x_i \hat{u}_i = 0$ (siehe „Beide Schätzer im Überblick“). 2. Normalgleichung: $\sum x_i y_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2$.

Zusatzübung Online-Shop (A): Die Normalgleichungen lösen

Summen

$n = 5,\ \sum x_i = 15,\ \sum y_i = 130,\ \sum x_i^2 = 55$

$\sum x_i y_i = 21 + 52 + 72 + 120 + 145 = 410$

Normalgleichungen (Folien 4/7 und 5/7)

I: $\sum y_i = n\,\beta_0 + \beta_1 \sum x_i$

II: $\sum x_i y_i = \beta_0 \sum x_i + \beta_1 \sum x_i^2$

Aufgaben

a) Beide Normalgleichungen mit diesen Summen aufschreiben.

b) Das Gleichungssystem nach β_0 und β_1 lösen.

c) Mit Gerade 2 aus Übung (3) vergleichen.

Lösung Zusatzübung (A): Die Normalgleichungen lösen

a) Summen einsetzen

I: $130 = 5\,\beta_0 + 15\,\beta_1$

II: $410 = 15\,\beta_0 + 55\,\beta_1$

c) Vergleich

$\hat{y} = 20 + 2\,x$ – Gerade 2 aus Übung (3) ✓

b) Regel: I nach β_0 auflösen, in II einsetzen

I durch 5: $\beta_0 = 26 - 3\,\beta_1$

in II: $410 = 15\,(26 - 3\,\beta_1) + 55\,\beta_1$

$$410 = 390 - 45\,\beta_1 + 55\,\beta_1 = 390 + 10\,\beta_1$$

$10\,\beta_1 = 20 \;\Rightarrow\; \hat{\beta}_1 = \mathbf{2}$

$\hat{\beta}_0 = 26 - 3 \cdot 2 = \mathbf{20}$

Anhang: Herleitung (6/7) – Zurück zur Abweichungsform

Zähler aus (5/7): Abweichungsprodukte ausmultiplizieren

$$\begin{aligned}
\sum(x_i-\bar{x})(y_i-\bar{y}) &= \sum\big(x_i y_i - \bar{y}\,x_i - \bar{x}\,y_i + \bar{x}\bar{y}\big) && \text{| ausmultiplizieren}\\
&= \sum x_i y_i - \bar{y}\sum x_i - \bar{x}\sum y_i + n\,\bar{x}\bar{y} && \text{| Summe aufteilen, } \textstyle\sum_{i=1}^{n}\bar{x}\bar{y} = n\,\bar{x}\bar{y}\\
&= \sum x_i y_i - n\bar{x}\bar{y} - n\bar{x}\bar{y} + n\bar{x}\bar{y} && \text{| } \textstyle\sum x_i = n\bar{x},\ \sum y_i = n\bar{y}\\
&= \sum x_i y_i - n\,\bar{x}\bar{y} && \text{| zusammenfassen}
\end{aligned}$$

Nenner: ebenso (binomische Formel)

$$\sum(x_i-\bar{x})^2 = \sum\big(x_i^2 - 2\bar{x}\,x_i + \bar{x}^2\big) = \sum x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 = \sum x_i^2 - n\,\bar{x}^2$$

Ergebnis (Verschiebungssatz)

$$\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} = \frac{\sum(x_i-\bar{x})(y_i-\bar{y})}{\sum(x_i-\bar{x})^2} = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$$

Anhang: Herleitung (7/7) – Ist es wirklich ein Minimum?

Zweite partielle Ableitungen: (2) und (3) noch einmal ableiten

$$\frac{\partial^2 S}{\partial \beta_0^2} = -2\sum(-1) = 2n \qquad \frac{\partial^2 S}{\partial \beta_1^2} = -2\sum x_i(-x_i) = 2\sum x_i^2 \qquad \frac{\partial^2 S}{\partial \beta_0\,\partial \beta_1} = -2\sum(-x_i) = 2\sum x_i$$

Minimum bei zwei Variablen: beide Bedingungen erfüllt

(1) $$\frac{\partial^2 S}{\partial \beta_0^2} = 2n > 0$$

(2) $$\frac{\partial^2 S}{\partial \beta_0^2} \cdot \frac{\partial^2 S}{\partial \beta_1^2} - \left(\frac{\partial^2 S}{\partial \beta_0\,\partial \beta_1}\right)^2 = 2n \cdot 2\sum x_i^2 - \left(2\sum x_i\right)^2$$

$$= 4\left(n\sum x_i^2 - n^2\bar{x}^2\right) = 4n\left(\sum x_i^2 - n\bar{x}^2\right) = 4n\,\mathrm{SQ}_x > 0 \qquad \Big| \ \sum x_i = n\bar{x}$$

In Worten: S krümmt sich in jede Richtung nach oben – eine „Schüssel“ mit genau einem Minimum, sobald nicht alle x_i gleich sind ($\mathrm{SQ}_x > 0$).

zurück

Anhang: Rechenabkürzung – drei Summen genügen

Leitfrage

Warum dürfen wir überall mit SQ und SP statt mit Varianzen und Kovarianzen rechnen?

Die drei Grundsummen

$\mathrm{SQ}_x = \sum (x_i - \bar{x})^2$	Zähler der Varianz s_x^2, Nenner der Steigung
$\mathrm{SQ}_y = \sum (y_i - \bar{y})^2$	$= \mathrm{SQT}$
$\mathrm{SP}_{xy} = \sum (x_i - \bar{x})(y_i - \bar{y})$	Zähler der Kovarianz s_{xy}

Kernaussage

Alle Kennzahlen folgen aus SQ_x, SQ_y und SP_{xy} ($\hat{\beta}_0$: zusätzlich $\bar{x}$, $\bar{y}$) – die Faktoren $1/(n-1)$ kürzen sich.

Warum sich der Faktor $1/(n-1)$ herauskürzt

Steigung (bekannt)

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = \frac{\mathrm{SP}_{xy}/(n-1)}{\mathrm{SQ}_x/(n-1)} = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$$

Korrelationskoeffizient

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{\mathrm{SP}_{xy}/(n-1)}{\sqrt{\mathrm{SQ}_x/(n-1)} \cdot \sqrt{\mathrm{SQ}_y/(n-1)}}$$

Wurzeln zusammenziehen

$$\sqrt{\mathrm{SQ}_x/(n-1)} \cdot \sqrt{\mathrm{SQ}_y/(n-1)} = \sqrt{\mathrm{SQ}_x\, \mathrm{SQ}_y}\,/\,(n-1) \quad \Longrightarrow \quad r_{xy} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\, \mathrm{SQ}_y}}$$

In Worten: Derselbe Faktor steht oben und unten – er kürzt sich.

Alle Kennzahlen aus drei Summen

Größe	**über Kennzahlen**	**über Summen**
Steigung	$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2}$	$\hat{\beta}_1 = \frac{\mathrm{SP}_{xy}}{\mathrm{SQ}_x}$
Achsenabschnitt	$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$	(gleich)
Korrelation	$r_{xy} = \frac{s_{xy}}{s_x\, s_y}$	$r_{xy} = \frac{\mathrm{SP}_{xy}}{\sqrt{\mathrm{SQ}_x\, \mathrm{SQ}_y}}$
Bestimmtheitsmaß	$R^2 = r_{xy}^2$	$R^2 = \frac{\mathrm{SP}_{xy}^2}{\mathrm{SQ}_x\, \mathrm{SQ}_y}$
Erklärte Quadratsumme	$\mathrm{SQE} = \hat{\beta}_1^2\, \mathrm{SQ}_x$	$\mathrm{SQE} = \hat{\beta}_1\, \mathrm{SP}_{xy}$
Residuenquadratsumme	$\mathrm{SQR} = \mathrm{SQT} - \mathrm{SQE}$	$\mathrm{SQR} = \mathrm{SQ}_y - \hat{\beta}_1\, \mathrm{SP}_{xy}$

$\mathrm{SQE} = \hat{\beta}_1^2 \mathrm{SQ}_x = \hat{\beta}_1 \cdot (\mathrm{SP}_{xy}/\mathrm{SQ}_x) \cdot \mathrm{SQ}_x = \hat{\beta}_1 \mathrm{SP}_{xy}$. Die Formeln mit $R^2 = r_{xy}^2$ gelten nur in der Einfachregression.

Beispiel: Die zwölf Filialen aus drei Summen

Grundsummen

$$\mathrm{SP}_{xy} = 186$$
$$\mathrm{SQ}_x = 155$$
$$\mathrm{SQ}_y = 288$$
$$\bar{x} = 7{,}5, \quad \bar{y} = 39$$

Kernaussage

Dieselben Werte wie zuvor – ohne $1/(n-1)$-Faktoren und ohne Wurzeln aus gerundeten Varianzen.

Alles Weitere in wenigen Zeilen

$$\hat{\beta}_1 = 186/155 = \mathbf{1{,}2}$$
$$\hat{\beta}_0 = 39 - 1{,}2 \cdot 7{,}5 = \mathbf{30}$$
$$r_{xy} = 186/\sqrt{155 \cdot 288} = \mathbf{0{,}8803}$$
$$R^2 = 186^2/(155 \cdot 288) = 34\,596/44\,640 = \mathbf{0{,}775}$$
$$\mathrm{SQE} = 1{,}2 \cdot 186 = \mathbf{223{,}2}$$
$$\mathrm{SQR} = 288 - 223{,}2 = \mathbf{64{,}8}$$

Zusatzübung Online-Shop (B): Alle Kennzahlen aus drei Summen

Bekannt aus Übung (2)

$\mathrm{SQ}_x = 10, \quad \mathrm{SQ}_y = 54, \quad \mathrm{SP}_{xy} = 20, \quad \bar{x} = 3, \quad \bar{y} = 26$

Aufgabe

Berechnen Sie allein aus diesen Werten: $\hat{\beta}_1$, $\hat{\beta}_0$, r_{xy}, R^2, SQE und SQR.

Formeln: Tabelle „Alle Kennzahlen aus drei Summen“ (Spalte „über Summen“)

Lösung Zusatzübung (B): Alle Kennzahlen aus drei Summen

Regel: die Formeln „über Summen“

$$\hat{\beta}_1 = \mathrm{SP}_{xy}/\mathrm{SQ}_x = 20/10 = \mathbf{2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\,\bar{x} = 26 - 2\cdot 3 = \mathbf{20}$$

$$r_{xy} = \mathrm{SP}_{xy}/\sqrt{\mathrm{SQ}_x\,\mathrm{SQ}_y} = 20/\sqrt{540} = \mathbf{0{,}8607}$$

$$R^2 = \mathrm{SP}_{xy}^2/(\mathrm{SQ}_x\,\mathrm{SQ}_y) = 400/540 = \mathbf{0{,}741}$$

$$\mathrm{SQE} = \hat{\beta}_1\,\mathrm{SP}_{xy} = 2\cdot 20 = \mathbf{40}$$

$$\mathrm{SQR} = \mathrm{SQ}_y - \mathrm{SQE} = 54 - 40 = \mathbf{14}$$

Kernaussage

Dieselben Werte wie in den Übungen (2) bis (7) – in sechs Zeilen.

Korrelation als standardisierte Steigung

Umformung

$$r_{xy} = \frac{s_{xy}}{s_x\, s_y} = \frac{s_{xy}}{s_x^2} \cdot \frac{s_x}{s_y} = \hat{\beta}_1 \cdot \frac{s_x}{s_y}$$

In Worten

Misst man x und y in Standardabweichungen, ist die Steigung gleich r_{xy}.

Zwölf Filialen

$s_x/s_y = \sqrt{155/288} = 0{,}7336,$
$r_{xy} = 1{,}2 \cdot 0{,}7336 = 0{,}8803$ ✓

Folgerungen

- r_{xy} und $\hat{\beta}_1$: gleiches Vorzeichen
- $\hat{\beta}_1$ hängt von den Einheiten ab, r_{xy} nicht

Anhang: Vom Beschreiben der Daten zum Regressionsmodell

Modell: So entstehen die Daten

$$y_i = \underbrace{\beta_0 + \beta_1 x_i}_{\text{systematischer Teil}} + \underbrace{u_i}_{\text{Störterm}}$$

$\beta_0,\ \beta_1$ wahre, unbekannte Parameter – geschätzt durch $\hat{\beta}_0,\ \hat{\beta}_1$

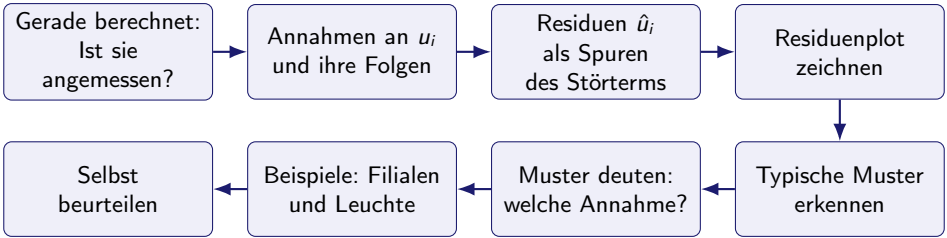
u_i alles, was x nicht erklärt; *nicht beobachtbar*

$\hat{u}_i$ Residuum: die Schätzung für u_i

Was folgt

Annahmen über u_i prüfen wir mit den Residuen: die **Residuenanalyse**.

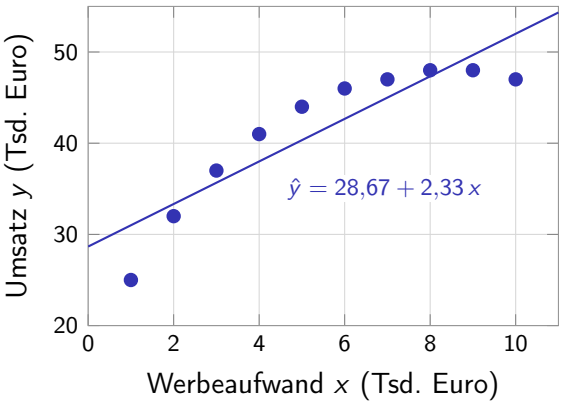
Fahrplan: Passt eine Gerade überhaupt zu den Daten?



Leitfrage

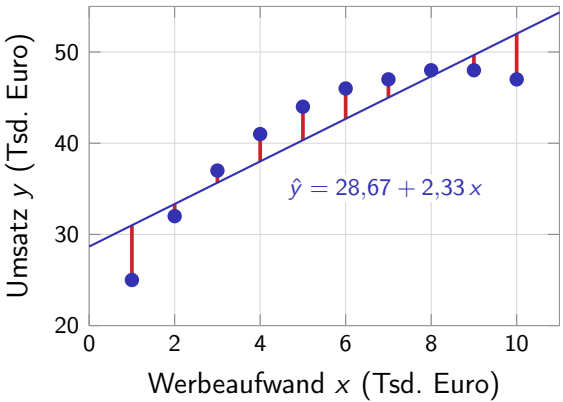
Woran erkennen wir, ob eine Gerade die Daten angemessen beschreibt?

Eine Gerade lässt sich immer berechnen – aber passt sie?



Aus „Was R^2 verrät“: $R^2 = 0{,}81$ – passt die Gerade?

Eine Gerade lässt sich immer berechnen – aber passt sie?

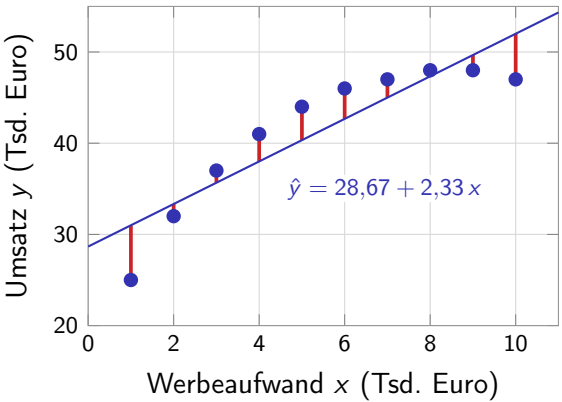


Beobachtung

Ränder *unter*, Mitte *über* der Geraden.

Aus „Was R^2 verrät“: $R^2 = 0{,}81$ – passt die Gerade?

Eine Gerade lässt sich immer berechnen – aber passt sie?



Aus „Was R^2 verrät“: $R^2 = 0{,}81$ – passt die Gerade?

Beobachtung

Ränder *unter*, Mitte *über* der Geraden.

Ursache

Sättigung: Zusätzliche Werbung wirkt immer schwächer.

Leitfrage

Wie erkennen wir das systematisch?

Was nehmen wir über den Störterm an?

Standardannahmen an den Störterm u_i:

Annahme	**Formal**	**In Worten**
Erwartungswert null	$E(u_i) = 0$	Kein systematischer Fehler: Im Mittel liegen die Beobachtungen auf der wahren Geraden, für jedes x.
Homoskedastizität	$\mathrm{Var}(u_i) = \sigma^2$	Die Streuung um die Gerade ist überall gleich groß (sonst: *Heteroskedastizität*).
Keine Autokorrelation	$\mathrm{Cov}(u_i, u_j) = 0 \ (i \neq j)$	Die Störungen hängen nicht voneinander ab (z. B. von Monat zu Monat).
Normalverteilung	$u_i \sim \mathcal{N}(0, \sigma)$	Die Störungen streuen glockenförmig um null.

Das Problem

u_i ist nicht beobachtbar: Wir prüfen die Annahmen über die **Residuen** $\hat{u}_i$.

E, Var, Cov und die Normalverteilung $\mathcal{N}(\mu, \sigma)$ folgen in Teil 5 – hier genügt die Idee.

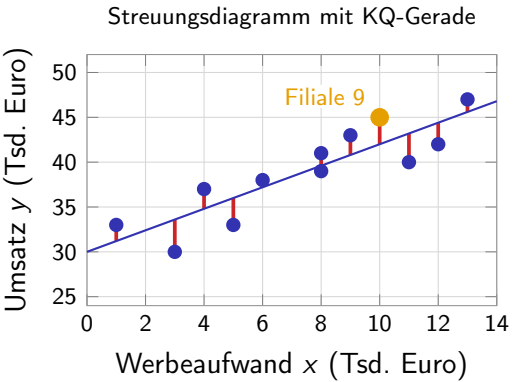
Was passiert, wenn eine Annahme verletzt ist?

Annahme	**Typisch verletzt bei**	**Folge**	**Prüfwerkzeug**
Erwartungswert null	nichtlinearem Zusammenhang, fehlender Einflussgröße	Gerade systematisch falsch, Schätzungen **verzerrt**	Residuenplot: **Bogen**
Homoskedastizität	mit x wachsender Streuung (große Filialen schwanken stärker)	Gerade im Mittel richtig, ihre Genauigkeit aber **falsch eingeschätzt** (Teil 6)	Residuenplot: **Trichter**
Keine Autokorrelation	Zeitreihen (Monatsumsätze)	wie bei Heteroskedastizität	Residuen über die Zeit: **Wellen**
Normalverteilung	schiefen Verteilungen, Ausreißern	Konfidenzintervalle und Tests (Teil 6) bei kleinem n unzuverlässig	**QQ-Plot**

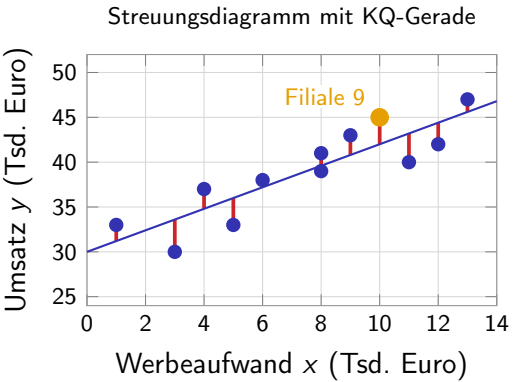
Kernaussage

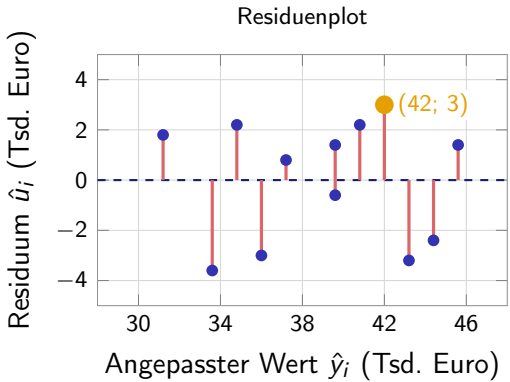
Die Annahmen entscheiden, wie verlässlich die Schlüsse auf β_0, β_1 sind.

Vom Streuungsdiagramm zum Residuenplot



Vom Streuungsdiagramm zum Residuenplot





Jeder Punkt wandert nach $(\hat{y}_i, \hat{u}_i)$ – **die Gerade wird zur Nulllinie**.

Der Residuenplot

Aufbau

- x-Achse angepasste Werte $\hat{y}_i$
- y-Achse Residuen $\hat{u}_i$
- Nulllinie die KQ-Gerade

Warum $\hat{y}_i$ statt x_i?

Gleiches Muster – funktioniert auch mit mehreren erklärenden Variablen.

Was immer gilt

$\sum \hat{u}_i = 0$: Die Punkte liegen insgesamt um die Nulllinie.

Kernaussage

Ideal: eine **strukturlose** Punktwolke in einem gleich breiten Band um die Nulllinie.

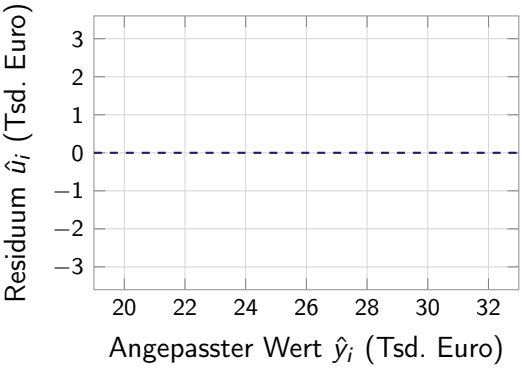
Übung Online-Shop (8): Den Residuenplot zeichnen

KQ-Gerade des Online-Shops:
$\hat{y} = 20 + 2\,x$

Monat i	1	2	3	4	5
$\hat{y}_i$	22	24	26	28	30
$\hat{u}_i$	-1	2	-2	2	-1

Aufgabe

Zeichnen Sie die Punkte $(\hat{y}_i,\ \hat{u}_i)$ in die Vorlage ein.



Vorlage zum Einzeichnen

Lösung Online-Shop (8): Der Residuenplot des Online-Shops

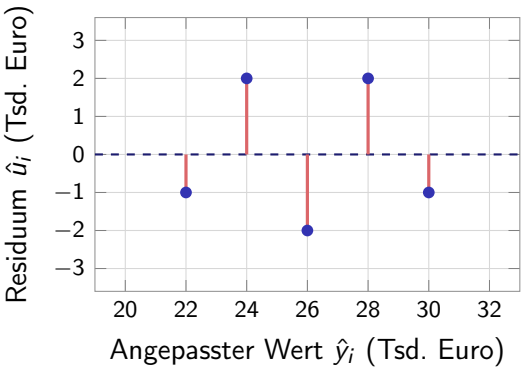
Regel: Punkte $(\hat{y}_i,\ \hat{u}_i)$ eintragen

$(22;\ -1),\ (24;\ 2),\ (26;\ -2),\ (28;\ 2),$
$(30;\ -1)$

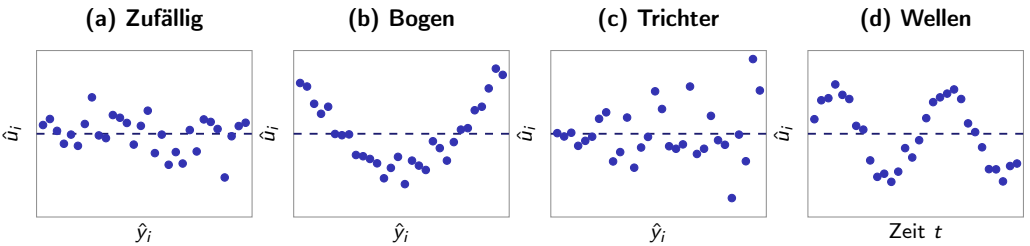
Bezug zum Streuungsdiagramm

Die KQ-Gerade wird zur Nulllinie: Jeder Punkt liegt so weit über oder unter null wie vorher über oder unter der Geraden.

Beurteilung nach den typischen Mustern: Übung „Residuenplots diagnostizieren“, Teil d).



Vier typische Muster im Residuenplot



gleichmäßiges Band

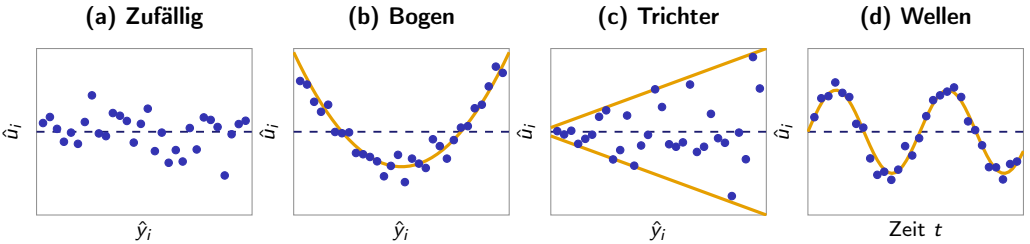
erst positiv, dann negativ, dann positiv

Streuung wächst mit $\hat{y}$

lange Phasen gleichen Vorzeichens

Wellen sieht man nur, wenn die Residuen in zeitlicher Reihenfolge gezeichnet werden.

Vier typische Muster im Residuenplot



gleichmäßiges Band	erst positiv, dann negativ, dann positiv	Streuung wächst mit $\hat{y}$	lange Phasen gleichen Vorzeichens
Modell passt	**falsche Funktionsform**	**Heteroskedastizität**	**Autokorrelation**

Wellen sieht man nur, wenn die Residuen in zeitlicher Reihenfolge gezeichnet werden.

Muster deuten: Was steckt dahinter?

Muster	Was man sieht	Hinweis auf	Mögliche Abhilfe (Ausblick)
Zufällig	unregelmäßige Wolke, überall gleich breit	Modell angemessen	–
Bogen	Residuen in Gruppen: erst über, dann unter, dann wieder über null (oder umgekehrt)	nichtlinearer Zusammenhang, fehlende Einflussgröße	andere Funktionsform, z. B. Logarithmus oder quadratischer Term
Trichter	Streuung wächst (oder schrumpft) mit $\hat{y}$	Heteroskedastizität	Transformation, robuste Standardfehler
Wellen	lange Phasen gleichen Vorzeichens in zeitlicher Folge	Autokorrelation	Zeitreihenmethoden

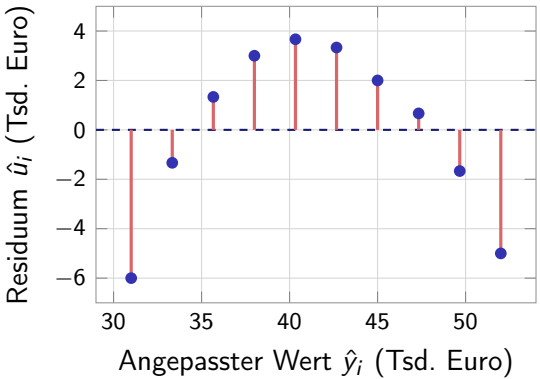
Einzelne Ausreißer

Ursache prüfen (Tippfehler? Sonderaktion?), *nicht* automatisch löschen.

Wenige Beobachtungen

Kleines n: nur deutliche Muster ernst nehmen – einzelne Punkte prägen das Bild stark.

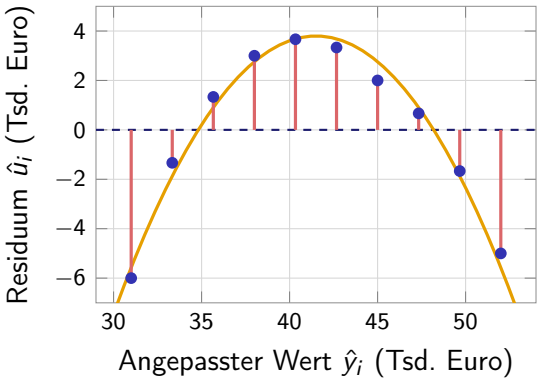
Zurück zum Sättigungsbeispiel



Befund

Deutlicher **Bogen**: negativ, positiv, negativ.

Zurück zum Sättigungsbeispiel



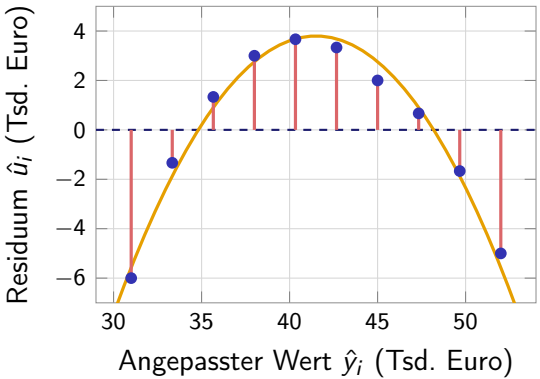
Befund

Deutlicher **Bogen**: negativ, positiv, negativ.

Deutung

Falsche Funktionsform – angemessen wäre eine Kurve mit abnehmendem Zuwachs.

Zurück zum Sättigungsbeispiel



Befund

Deutlicher **Bogen**: negativ, positiv, negativ.

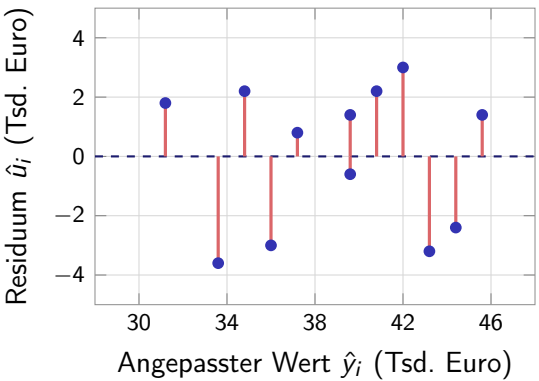
Deutung

Falsche Funktionsform – angemessen wäre eine Kurve mit abnehmendem Zuwachs.

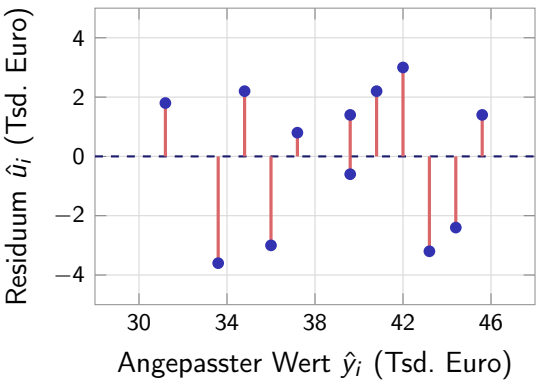
Kernaussage

Der Residuenplot zeigt, was die Gerade verbirgt.

Beispiel zwölf Filialen: Residuenplot beurteilen



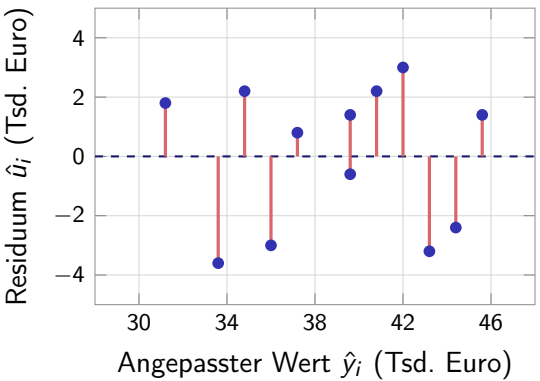
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein**

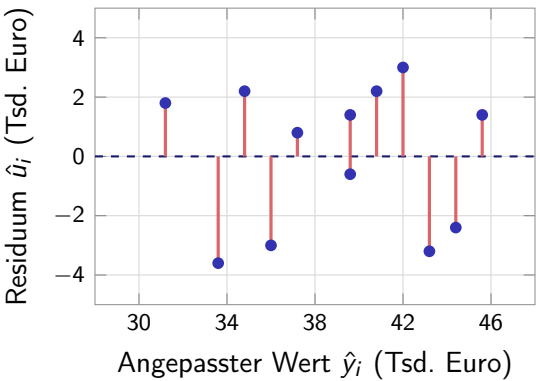
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein**
- Trichter? **Nein**

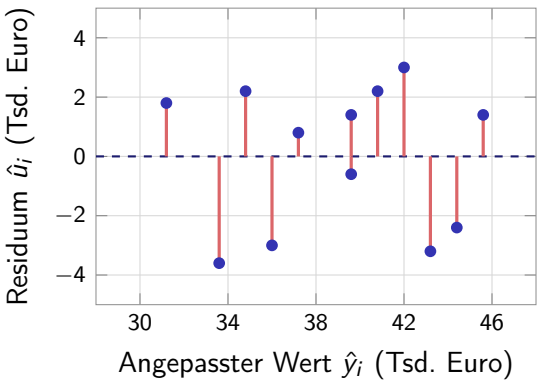
Beispiel zwölf Filialen: Residuenplot beurteilen



Prüfliste

- Bogen? **Nein**
- Trichter? **Nein**
- Ausreißer? **Nein** (größtes: $|\hat{u}_2| = 3{,}6$)

Beispiel zwölf Filialen: Residuenplot beurteilen



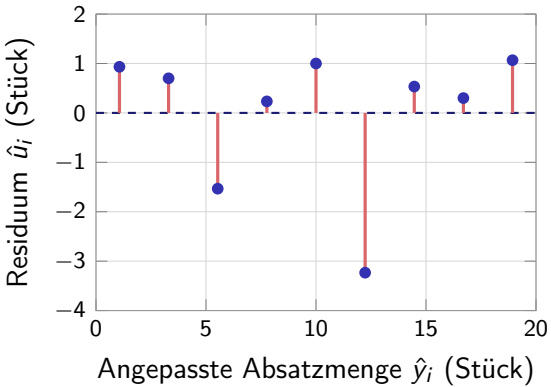
Prüfliste

- Bogen? **Nein**
- Trichter? **Nein**
- Ausreißer? **Nein** (größtes: $|\hat{u}_2| = 3{,}6$)

Fazit

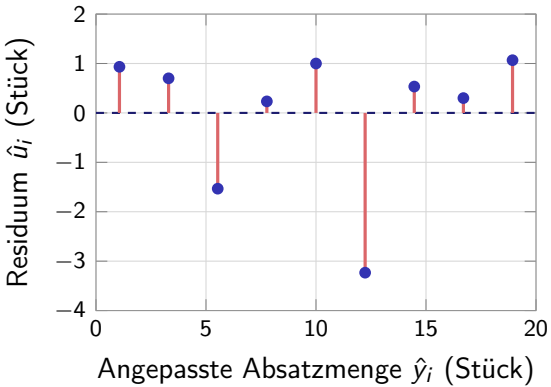
Keine Systematik: Gerade angemessen – bei $n = 12$ nur ein grobes Urteil.

Beispiel Leuchte: Residuenplot beurteilen



hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Beispiel Leuchte: Residuenplot beurteilen

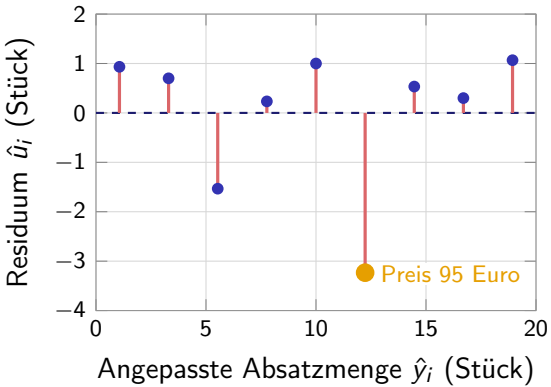


hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen, Trichter? **Nein**

Beispiel Leuchte: Residuenplot beurteilen

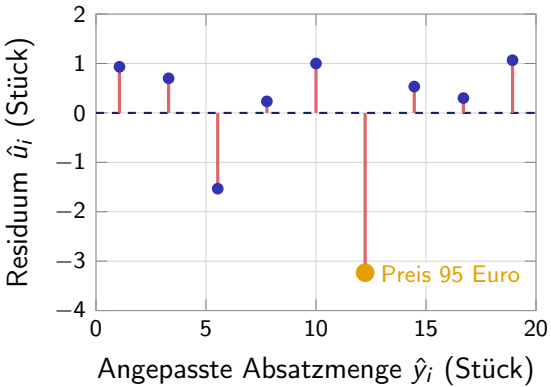


hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen, Trichter? **Nein**
- Ausreißer? Preis 95 Euro: 9 statt 12,2 Stück

Beispiel Leuchte: Residuenplot beurteilen



hohe Preise $\Rightarrow$ kleine $\hat{y}_i$ (links)

Prüfliste

- Bogen, Trichter? **Nein**
- Ausreißer? Preis 95 Euro: 9 statt 12,2 Stück

Fazit

Keine eindeutige Systematik; den auffälligen Wert inhaltlich prüfen.

Residuenplot mit R erstellen

R-Befehle (Beispiel Leuchte)

```
reg ← lm(menge ∼ preis)
plot(fitted(reg), resid(reg),
     xlab = "angepasste Werte", ylab = "Residuen", main = "Residuenplot")
abline(h = 0, lty = 2)                    # Nulllinie als Orientierung
```

Hilfsfunktionen

`fitted(reg)`	angepasste Werte $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ – Werte auf der x-Achse
`resid(reg)`	Residuen $\hat{u}_i = y_i - \hat{y}_i$ – Werte auf der y-Achse

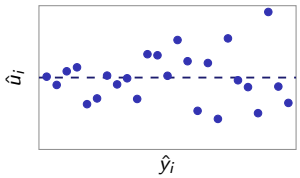
Kontrolle

```
sum(resid(reg))        # praktisch 0 (Rundung): Eigenschaft der KQ-Geraden
```

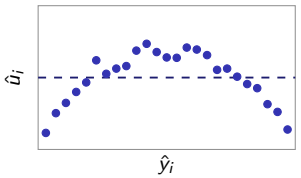
Übung: Residuenplots diagnostizieren

Drei Regressionen (jeweils $n = 25$): **(A)** Monatsmiete (Euro) auf Wohnfläche (m^2); **(B)** Tagesumsatz eines Cafés (Euro) auf Außentemperatur (°C); **(C)** Produktionskosten (Euro) auf Stückzahl.

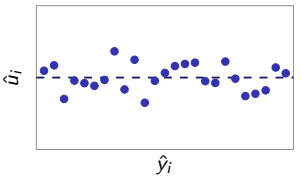
(A) Miete



(B) Café



(C) Produktion



Aufgaben

a) Welches Muster zeigt jeder Residuenplot?

b) Welche Annahme ist jeweils verletzt – oder keine? Inhaltlicher Grund?

c) Was folgt daraus für die Verlässlichkeit der KQ-Geraden, und was wäre zu tun?

d) Und Ihr Residuenplot des Online-Shops aus Übung (8)?

Lösung: Residuenplots diagnostizieren

Regel: Bogen $\rightarrow E(u_i) = 0$ verletzt; Trichter $\rightarrow$ Homoskedastizität verletzt.

Plot	a) Muster	b) Verletzte Annahme, Grund	c) Folge, Abhilfe
(A) Miete	**Trichter**: Streuung wächst mit $\hat{y}$	**Homoskedastizität** ($\text{Var}(u_i) = \sigma^2$): Mieten großer Wohnungen streuen stärker (Lage, Ausstattung).	Gerade im Mittel richtig, ihre Genauigkeit aber falsch eingeschätzt. Transformation (Logarithmus), robuste Standardfehler.
(B) Café	**Bogen**: negativ, positiv, negativ	**Erwartungswert null** ($E(u_i) = 0$): nicht linear – bei Hitze sinkt der Umsatz wieder; die Gerade unterschätzt die Mitte.	Gerade systematisch falsch, Schätzungen verzerrt. Andere Funktionsform, z. B. quadratischer Term.
(C) Produktion	**zufällig**: gleichmäßiges Band	**Keine** erkennbar verletzt: unsystematische Abweichungen.	Gerade angemessen; nichts zu ändern.

d) Online-Shop: kein Bogen, kein Trichter, keine Wellen – bei $n = 5$ aber **kein belastbares Urteil**.

Körper- und Schuhgröße, Aufgabe 5: Residuenplot

Ausgangspunkt: KQ-Gerade aus Aufgabe 3

$$\hat{s} = 2{,}3147 + 0{,}2222\, k \qquad (n = 15 \text{ Personen, Daten im Hauptteil})$$

Aufgaben

a) Angepasste Werte $\hat{s}_i$ und Residuen $\hat{u}_i = s_i - \hat{s}_i$ berechnen.

b) Den Residuenplot $(\hat{s}_i,\ \hat{u}_i)$ zeichnen.

c) Beurteilen: Bogen? Trichter? Auffällige Einzelwerte?

In R: `plot(fitted(reg), resid(reg))` mit `reg` $\leftarrow$ `lm(s` $\sim$ `k)`.

Lösung Aufgabe 5 (1/2): Angepasste Werte und Residuen

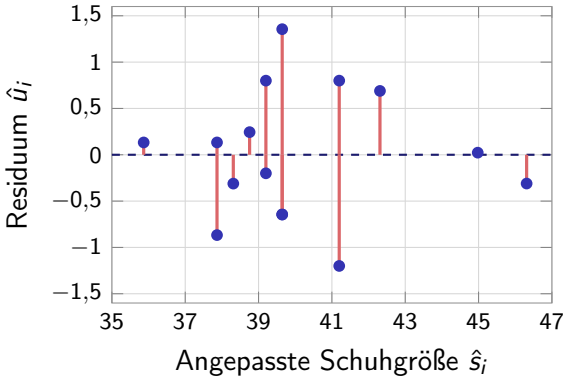
a) Regel: $\hat{s}_i = 2{,}3147 + 0{,}2222\, k_i, \quad \hat{u}_i = s_i - \hat{s}_i$

Person i	1	2	3	4	5	6	7	8
k_i (cm)	164	162	168	198	166	166	192	160
s_i	39	38	39	46	40	39	45	37
$\hat{s}_i$	38,76	38,31	39,64	46,31	39,20	39,20	44,98	37,87
$\hat{u}_i$	0,24	−0,31	−0,64	−0,31	0,80	−0,20	0,02	−0,87

Person i	9	10	11	12	13	14	15
k_i (cm)	151	175	180	160	168	175	168
s_i	36	42	43	38	41	40	39
$\hat{s}_i$	35,87	41,20	42,31	37,87	39,64	41,20	39,64
$\hat{u}_i$	0,13	0,80	0,69	0,13	1,36	−1,20	−0,64

Beispiel Person 13: $\hat{s}_{13} = 2{,}3147 + 0{,}2222 \cdot 168 = 39{,}64, \quad \hat{u}_{13} = 41 - 39{,}64 = 1{,}36$
Kontrolle: $\sum \hat{u}_i = 0$ ✓

Lösung Aufgabe 5 (2/2): Residuenplot und Beurteilung



Residuen $\hat{u}_i = s_i - \hat{s}_i$

Zwischen $-1{,}20$ (Person 14) und $1{,}36$ (Person 13) – also höchstens rund 1,4 Schuhgrößen.

Beurteilung

- kein Bogen, kein Trichter
- kein auffälliger Einzelwert

Keine Systematik erkennbar: Die Gerade ist angemessen.

Gleiche Körpergröße $\Rightarrow$ gleiches $\hat{s}_i$: Diese Punkte liegen senkrecht übereinander.

Rückblick Residuenanalyse

Können Sie diese Fragen beantworten?

1. Warum prüfen wir Annahmen über u_i mit $\hat{u}_i$?
2. Wie entsteht der Residuenplot aus dem Streuungsdiagramm?
3. Welche Annahme ist bei Bogen, Trichter und Wellen verletzt?
4. Was tun Sie mit einem auffälligen Einzelwert?

Kernaussage

Erst rechnen, dann prüfen: Nur ein strukturloser Residuenplot rechtfertigt die KQ-Gerade.

Anhang: Ist der Störterm normalverteilt? Der QQ-Plot

Ausgangslage

Vierte Annahme: $u_i \sim \mathcal{N}(0, \sigma)$ – gebraucht erst für Konfidenzintervalle und Tests (Teil 6).

Leitfrage

Wie prüft man, ob die Residuen aus einer Normalverteilung stammen könnten?

Histogramm?

Bei $n = 9$ oder 15 kaum beurteilbar – zu wenige Balken.

Besser: Quantile vergleichen

Der **QQ-Plot** vergleicht sortierte mit erwarteten Werten.

Die Idee: Quantile gegeneinander abtragen

Konstruktion

1. Von beiden Verteilungen gleich viele Quantile bestimmen (bei Stichproben: die **sortierten Werte**).
2. *i*-tes Quantil gegen *i*-tes Quantil als Punkt eintragen.

Lesart

Punkte auf einer **Geraden**: gleiche *Form* der Verteilungen.

Referenzgerade

durch die Punkte der **25 %**- und **75 %-Quantile**

Kernaussage

Systematische Abweichungen von der Geraden: unterschiedliche Verteilungsformen.

Einstiegsbeispiel: Preise und Absatzmengen der Leuchte

Plan: erst das Prinzip an zwei Stichproben – danach die Residuen gegen die Normalverteilung.

Daten aus dem Regressionsbeispiel

Preis x_i (Euro)	80	85	90	95	100	105	110	115	120
Absatz y_i (Stück)	20	17	15	9	11	8	4	4	2

Schritt 1: Jedes Merkmal *für sich* aufsteigend sortieren

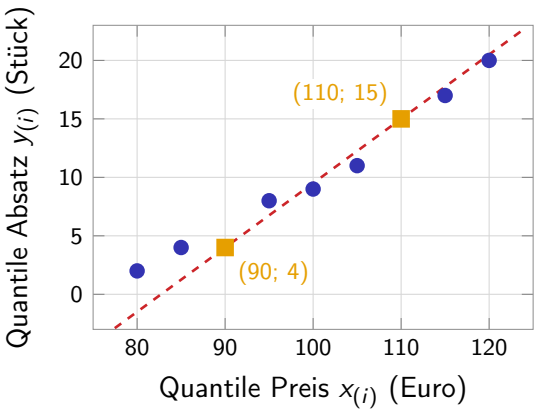
$x_{(i)}$	80	85	90	95	100	105	110	115	120
$y_{(i)}$	2	4	4	8	9	11	15	17	20

Schritt 2: die Paare $\left(x_{(i)}, y_{(i)}\right)$ eintragen.

Achtung: Die Paare werden aufgelöst

(80; 2) ist keine Beobachtung – gewollt: Verglichen werden nur die *Verteilungen*.

QQ-Plot: Preise gegen Absatzmengen



Referenzgerade

Quartile: Preis 90 und 110 Euro, Absatz 4 und 15 Stück. Gerade durch (90; 4) und (110; 15):

$$y = -45{,}5 + 0{,}55\,x$$

Lesart

Punkte nahe der Geraden: **ähnlich verteilt**. Unterschiedliche Lage und Streuung verschieben bzw. kippen nur die Gerade.

QQ-Plot zweier Stichproben mit R

QQ-Plot zeichnen

```
qqplot(preis, menge)
```

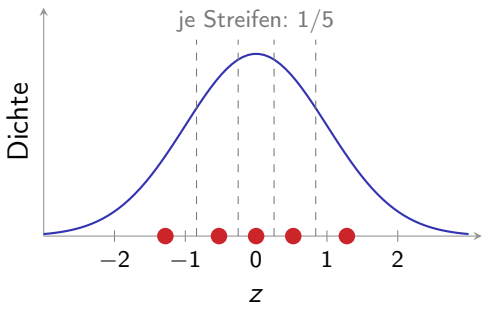
Referenzgerade durch die Quartile

```
qqline(menge,
       distribution = function(p) quantile(preis, prob = p),
       lty = 2)
```

Was die Befehle tun

`qqplot()` sortiert beide Stichproben und zeichnet die Paare $\left(x_{(i)}, y_{(i)}\right)$; `qqline()` legt die Gerade durch die Paare der 25 %- und 75 %-Quantile.

Residuen gegen die Normalverteilung: theoretische Quantile



$n = 5$: fünf Streifen mit je Wahrscheinlichkeit $1/5$; z_i (rot) halbiert jeden Streifen.
Φ: Verteilungsfunktion der $\mathcal{N}(0,1)$; $z_i = \Phi^{-1}(p_i)$, in R `qnorm(p)`

Vorgehen

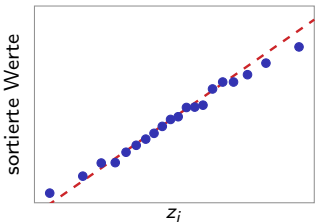
1. Residuen sortieren: $\hat{u}_{(1)} \leq \ldots \leq \hat{u}_{(n)}$.
2. Rang i: Anteil $p_i = (i - 0{,}5)/n$.
3. Theoretisches Quantil der Standardnormalverteilung: $z_i = \Phi^{-1}(p_i)$, d. h. $P(Z \leq z_i) = p_i$.
4. Punkte $\left(z_i,\ \hat{u}_{(i)}\right)$ zeichnen.

In Worten

z_i: wo der i-kleinste von n Werten bei Normalverteilung „zu erwarten“ wäre. Unbekanntes σ ändert nur die Steigung der Geraden.

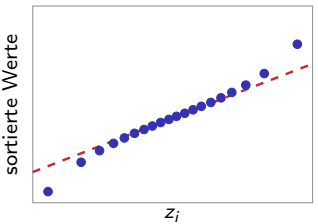
Typische Abweichungen im QQ-Plot

(a) Normalverteilt



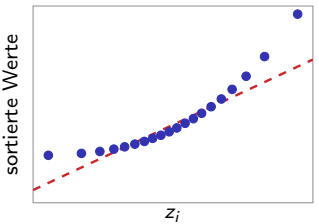
Punkte nahe der Geraden

(b) Schwere Ränder



S-Form: mehr extreme Werte

(c) Rechtsschief



Bogen: langer oberer Rand
(linksschief: spiegelbildlich)

Kernaussage

Ernst zu nehmen sind nur *systematische* Formen wie S oder Bogen.

Beispiel Leuchte: Quantile berechnen

Rang i	$\hat{u}_{(i)}$	Preis	$p_i = \frac{i-0{,}5}{9}$	$z_i = \Phi^{-1}(p_i)$
1	−3,2333	95	0,0556	−1,5932
2	−1,5333	110	0,1667	−0,9674
3	0,2333	105	0,2778	−0,5895
4	0,3000	85	0,3889	−0,2822
5	0,5333	90	0,5000	0,0000
6	0,7000	115	0,6111	0,2822
7	0,9333	120	0,7222	0,5895
8	1,0000	100	0,8333	0,9674
9	1,0667	80	0,9444	1,5932

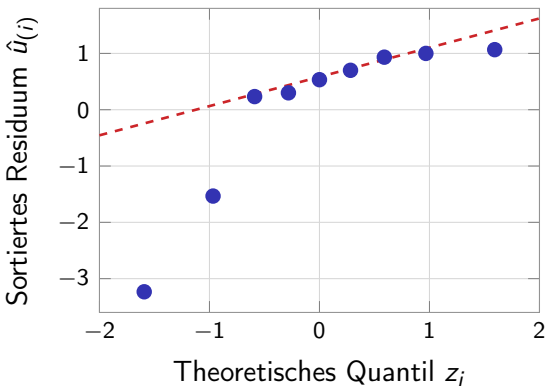
Residuen

aus $\hat{y} = 54{,}67 - 0{,}4467\,x$, z. B. Preis 95: $\hat{u} = 9 - 12{,}23 = -3{,}23$.

Symmetrie

z_i ist symmetrisch um 0: $z_9 = -z_1$, $z_8 = -z_2$, ... Die Werte stammen aus der Tabelle der Standardnormalverteilung oder aus R: `qnorm(p)`.

Beispiel Leuchte: QQ-Plot der Residuen

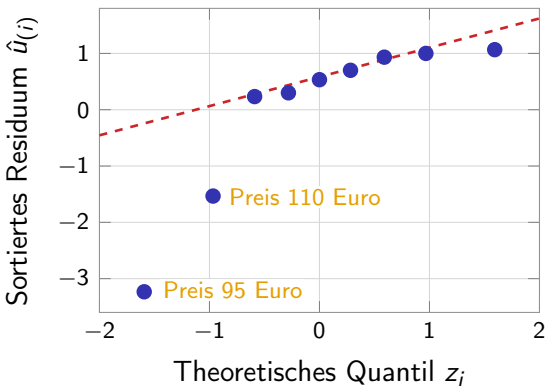


Referenzgerade durch $(-0{,}674;\ 0{,}233)$ und $(0{,}674;\ 0{,}933)$: $0{,}5833 + 0{,}5189\,z$

Beobachtung

- **Mitte**: nahe der Geraden

Beispiel Leuchte: QQ-Plot der Residuen

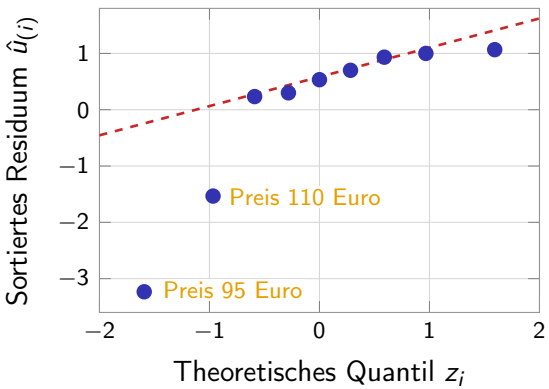


Referenzgerade durch $(-0{,}674;\ 0{,}233)$ und $(0{,}674;\ 0{,}933)$: $0{,}5833 + 0{,}5189\,z$

Beobachtung

- **Mitte**: nahe der Geraden
- **unterer Rand**: die zwei kleinsten Residuen deutlich darunter

Beispiel Leuchte: QQ-Plot der Residuen



Referenzgerade durch $(-0{,}674;\ 0{,}233)$ und $(0{,}674;\ 0{,}933)$: $0{,}5833 + 0{,}5189\,z$

Beobachtung

- **Mitte**: nahe der Geraden
- **unterer Rand**: die zwei kleinsten Residuen deutlich darunter

Fazit

Unterer Rand zu lang – vor allem durch den auffälligen Wert bei 95 Euro (vgl. Residuenplot); bei $n = 9$ **unsicher**.

Übung Online-Shop (9): QQ-Plot der Residuen

KQ-Gerade $20 + 2x$ des Online-Shops

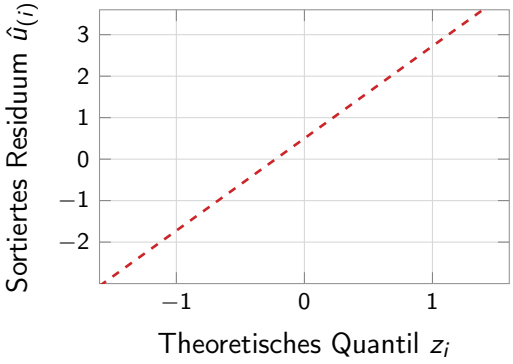
Residuen: $-1,\ 2,\ -2,\ 2,\ -1$

Aufgaben

a) Sortieren; $p_i = (i - 0{,}5)/5$ und $z_i = \Phi^{-1}(p_i)$ bestimmen.

b) QQ-Plot zeichnen; Referenzgerade (wie in R): $0{,}5 + 2{,}224\, z$.

c) Was lässt sich bei $n = 5$ über die Verteilung sagen?



Vorlage mit Referenzgerade

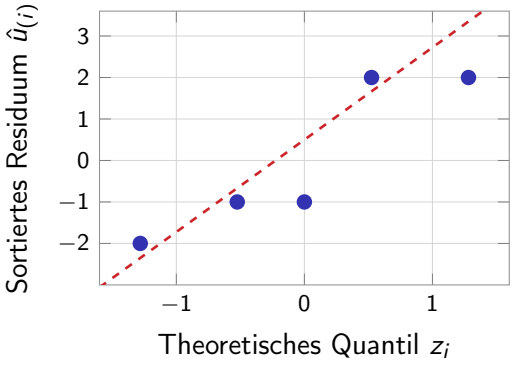
Lösung Online-Shop (9): QQ-Plot der Residuen

a) Regel: $p_i = (i - 0{,}5)/n$, $z_i = \Phi^{-1}(p_i)$

Rang i	$\hat{u}_{(i)}$	p_i	z_i
1	-2	0,1	$-1{,}2816$
2	-1	0,3	$-0{,}5244$
3	-1	0,5	0,0000
4	2	0,7	0,5244
5	2	0,9	1,2816

c) Bei $n = 5$ kein Urteil möglich

Zwei Stufen durch die doppelten Werte – für die Verteilungsform zu wenige Daten.



b) Punkte $(z_i,\ \hat{u}_{(i)})$ und Referenzgerade

QQ-Plot der Residuen gegen die Normalverteilung in R

QQ-Plot erzeugen

```
reg ← lm(menge ∼ preis)
qqnorm(resid(reg))
```

Referenzgerade durch die Quartile

```
qqline(resid(reg))
```

Was die Befehle tun

`qqnorm()` sortiert die Residuen, berechnet die Normalquantile z_i und zeichnet die Paare $\left(z_i,\ \hat{u}_{(i)}\right)$. `qqline()` legt die Gerade durch das 25 %- und das 75 %-Quantil.

Für $n \leq 10$ verwendet R leicht andere Anteile, $p_i = (i - 3/8)/(n + 1/4)$; das Bild ändert sich dadurch kaum.

Körper- und Schuhgröße, Aufgabe 6: QQ-Plot der Residuen

Ausgangspunkt

Die Residuen $\hat{u}_i = s_i - \hat{s}_i$ aus Aufgabe 5 ($n = 15$).

Aufgaben

a) Residuen sortieren und $p_i = (i - 0{,}5)/15$ sowie $z_i = \Phi^{-1}(p_i)$ bestimmen.

b) Den QQ-Plot zeichnen; Referenzgerade (wie in R): $-0{,}0056 + 0{,}7002\, z$.

c) Beurteilen: Spricht etwas gegen die Normalverteilungsannahme?

In R: `qqnorm(resid(reg)); qqline(resid(reg));` z_i: `qnorm(((1:15) - 0.5) / 15)`. `qqline` interpoliert die Quartile der Residuen (Positionen 4,5 und 11,5).

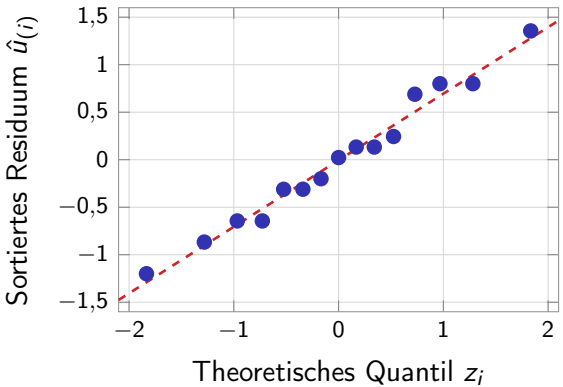
Lösung Aufgabe 6 (1/2): Sortierte Residuen und Normalquantile

i	$\hat{u}_{(i)}$	p_i	z_i
1	−1,1999	0,0333	−1,8339
2	−0,8669	0,1000	−1,2816
3	−0,6445	0,1667	−0,9674
4	−0,6445	0,2333	−0,7279
5	−0,3113	0,3000	−0,5244
6	−0,3105	0,3667	−0,3407
7	−0,2001	0,4333	−0,1679
8	0,0227	0,5000	0,0000

i	$\hat{u}_{(i)}$	p_i	z_i
9	0,1329	0,5667	0,1679
10	0,1331	0,6333	0,3407
11	0,2443	0,7000	0,5244
12	0,6891	0,7667	0,7279
13	0,7999	0,8333	0,9674
14	0,8001	0,9000	1,2816
15	1,3555	0,9667	1,8339

Kleinstes Residuum: Person 14 (175 cm, Schuhgröße 40); größtes: Person 13 (168 cm, Schuhgröße 41).

Lösung Aufgabe 6 (2/2): QQ-Plot und Beurteilung



Referenzgerade durch die Quartile: $-0{,}0056 + 0{,}7002\,z$

Beobachtung

Alle 15 Punkte liegen nahe der Geraden; weder S-Form noch Bogen. Kleine Stufen entstehen, weil Schuhgrößen ganze Zahlen sind.

Fazit

Kein Hinweis gegen die Normalverteilung der Störterme. Ein Beweis ist das nicht – mit $n = 15$ lassen sich nur deutliche Abweichungen erkennen.